

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



BÁO CÁO ĐỒ ÁN

Đề tài: ANIMAL CLASSIFICATION IN IMAGES

MÔN: NHẬP MÔN THỊ GIÁC MÁY TÍNH

HỌC KỲ I - NĂM HỌC: 2025-2026

Lớp: CS231.Q11

GV hướng dẫn: TS. Mai Tiến Dũng

Nhóm thực hiện

Họ và tên	MSSV
Nguyễn Bá Long	23520880
Nguyễn Công Thiết	23521491

Tp. Hồ Chí Minh, ngày 17 tháng 01 năm 2026

[illegible]

Người nhận xét

2 | Page

MỤC LỤC

PHÂN CÔNG VÀ ĐÁNH GIÁ	5
CHƯƠNG 1. TẦM QUAN TRỌNG CỦA BÀI TOÁN	6
CHƯƠNG 2. PHÁT BIỂU BÀI TOÁN.....	7
2.1 Input	7
2.1.1. Tập dữ liệu huấn luyện (Training Dataset) D	7
2.1.2. Dữ liệu cần dự đoán x	7
2.2 Output.....	7
2.3 Mục tiêu bài toán	7
CHƯƠNG 3. PHƯƠNG PHÁP GIẢI QUYẾT	8
3.1. Tổng quan quy trình (Pipeline).....	8
3.2 Tiền xử lý ảnh	8
3.2.1. Phân chia dữ liệu (Data Splitting)	8
3.2.2. Xử lý ảnh (Image Processing)	8
3.3 Trích xuất đặc trưng.....	9
3.3.1. Histogram of Oriented Gradients (HOG)	9
3.3.2. Local Binary Patterns (LBP)	11
3.3.3. Scale-Invariant Feature Transform (SIFT)	12
3.3.4. Tổng hợp đặc trưng (Feature Fusion)	14
3.4 Mô hình phân loại (RF and SVM)	15
3.4.1 Random Forest (RF)	15
3.4.2 Support Vector Machine (SVM)	17
3.5 Ngôn ngữ & thư viện	19
CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM.....	21
4.1 Bộ dữ liệu và môi trường thực nghiệm.....	21
4.1.1. Bộ dữ liệu (Dataset).....	21
4.1.2. Môi trường và Cấu hình thực nghiệm (Experimental Setup).....	22
4.2 Độ đo.....	22
4.3 Kết quả	22
4.3.1 Kết quả trích xuất đặc trưng bằng LBP	22
4.3.2. Thực nghiệm với đặc trưng HOG.....	24
4.3.3 Kết quả trích xuất đặc trưng bằng HOG và LBP.....	27
4.3.4 Kết quả trích xuất đặc trưng bằng SIFT	28

4.4. So sánh và Đánh giá tổng quan.....	33
4.4.1. Bảng tổng hợp kết quả thực nghiệm.....	33
4.4.2. Phân tích so sánh	33
4.5. Kết luận chương.....	34
CHƯƠNG 5. ĐÁNH GIÁ VÀ NHẬN XÉT	35
5.1 Ưu điểm.....	35
5.2 Hạn chế	35
5.3 Hướng phát triển	35
TÀI LIỆU THAM KHẢO	37

PHÂN CÔNG VÀ ĐÁNH GIÁ

STT	Họ và tên	Mã số sinh viên	Phân công công việc	Đánh giá % đóng góp (tổng 100%)
1	Nguyễn Bá Long	23520880	Thực hiện cùng nhóm: lựa chọn đề tài, khảo sát tài liệu, xây dựng pipeline tiền xử lý–trích đặc trưng, huấn luyện và đánh giá mô hình, viết báo cáo, làm slide và thuyết trình;phát triển web demo	55%
2	Nguyễn Công Thiết	23521491	Thực hiện cùng nhóm: lựa chọn đề tài, khảo sát tài liệu, xây dựng pipeline tiền xử lý–trích đặc trưng, huấn luyện & đánh giá mô hình, viết báo cáo, làm slide và thuyết trình.	45%

CHƯƠNG 1. TẦM QUAN TRỌNG CỦA BÀI TOÁN

Trong kỷ nguyên số, hình ảnh đã trở thành một trong những nguồn dữ liệu phong phú và tăng trưởng nhanh nhất. Việc tự động phân tích và hiểu nội dung hình ảnh không chỉ giúp giảm chi phí nhân lực, mà còn là nền tảng để xây dựng nhiều hệ thống thông minh trong thị giác máy tính. Trong đó, phân loại hình ảnh (image classification) là bài toán cốt lõi, đóng vai trò nền tảng cho các nhiệm vụ nâng cao như phát hiện đối tượng, nhận dạng, truy xuất và giám sát tự động.

Bài toán phân loại ảnh động vật là một ví dụ điển hình cho giá trị ứng dụng thực tiễn của phân loại ảnh, bởi nó tác động trực tiếp đến nhiều lĩnh vực quan trọng:

- **Bảo tồn đa dạng sinh học:** Hệ thống có thể hỗ trợ phân loại động vật hoang dã từ ảnh bẫy camera, giúp theo dõi quần thể, phân tích hành vi và hỗ trợ bảo vệ các loài có nguy cơ tuyệt chủng.
- **Nông nghiệp và chăn nuôi thông minh:** Tự động nhận diện/giám sát vật nuôi giúp theo dõi sức khỏe, hành vi và năng suất trong mô hình trang trại hiện đại.
- **Tìm kiếm và truy xuất thông tin:** Hỗ trợ người dùng tìm kiếm ảnh theo loài trong kho dữ liệu lớn (thư viện ảnh cá nhân, nền tảng mạng xã hội).
- **Kiểm soát nội dung:** Hỗ trợ hệ thống mạng xã hội lọc/nhận diện nhóm nội dung liên quan đến động vật nhằm phân loại và quản trị nội dung hiệu quả hơn.
- **Giáo dục và nghiên cứu:** Xây dựng ứng dụng học tập tương tác và hỗ trợ nghiên cứu khoa học (thu thập, phân loại, thống kê dữ liệu hình ảnh theo chủ đề).

Từ các động lực trên, việc xây dựng một mô hình có khả năng phân loại chính xác ảnh động vật không chỉ mang ý nghĩa học thuật mà còn có giá trị ứng dụng rõ ràng. Trong phạm vi đề án này, nhóm tập trung vào hướng tiếp cận thị giác máy tính và máy học cổ điển nhằm đảm bảo tính trực quan, khả năng giải thích, chi phí tính toán hợp lý và phù hợp triển khai thực tế. Cụ thể, nhóm khai thác các đặc trưng thủ công (HOG, LBP, ...) kết hợp các mô hình phân loại (Random Forest, SVM) để nhận dạng khuôn mặt động vật thuộc ba nhãn: Cat, Dog và Wild.

CHƯƠNG 2. PHÁT BIỂU BÀI TOÁN

2.1 Input

2.1.1. Tập dữ liệu huấn luyện (Training Dataset) D

Một tập hợp D gồm N cặp dữ liệu (ảnh, nhãn) đã được gán nhãn thủ công.

$$D = \{(x_i, y_i)\}_{i=1}^N$$

Trong đó:

- N : là tổng số lượng mẫu trong tập dữ liệu huấn luyện.
- L : là tập hợp hữu hạn các nhãn (lớp) mà một mẫu có thể thuộc về. Trong đề án này, $L = \{\text{Cat, Dog, Wild}\}$.
- (x_i, y_i) là một cặp dữ liệu thứ i :
 - x_i : Ban đầu là một ảnh kỹ thuật số. Sau khi qua quy trình tiền xử lý và trích xuất đặc trưng, x_i là một vector đặc trưng có d chiều: $x_i \in R^d$ đại diện mẫu dữ liệu thứ i trong tập huấn luyện
 - y_i : là nhãn thực tế (ground-truth label) được gán cho x_i , với $y_i \in L$.

2.1.2. Dữ liệu cần dự đoán x

Một ảnh x mới, chưa được gán nhãn. Ảnh này cũng được xử lý qua cùng quy trình (tiền xử lý, trích xuất đặc trưng) tương tự như tập huấn luyện, kết quả là một vector đặc trưng thuộc cùng không gian d chiều, với $x_i \in R^d$.

2.2 Output

Đầu ra của hệ thống là một giá trị nhãn dự đoán (predicted label), ký hiệu là $\hat{y}$, dành cho vector đầu vào x . Giá trị dự đoán này phải thuộc tập nhãn đã được định nghĩa:

$$\hat{y} \in L$$

2.3 Mục tiêu bài toán

Mục tiêu là xây dựng một mô hình phân loại (classifier) $f : x \rightarrow y$, sao cho cực đại hóa độ chính xác của nhãn dự đoán $\hat{y} = f(x)$ so với nhãn thật y trên dữ liệu chưa từng thấy (tập Test). Đồng thời, quy trình đánh giá phải đảm bảo tính khách quan và có thể tái lập (reproducible).

CHƯƠNG 3. PHƯƠNG PHÁP GIẢI QUYẾT

3.1. Tổng quan quy trình (Pipeline)

Nhóm xây dựng hệ thống theo pipeline chuẩn trong thị giác máy tính cổ điển:

1. Tiền xử lý ảnh
2. Trích xuất đặc trưng (HOG / LBP / SIFT-BoVW / Fusion)
3. Chuẩn hoá đặc trưng (Standardization)
4. Huấn luyện mô hình phân loại (Random Forest, SVM)
5. Tối ưu siêu tham số bằng GridSearchCV + Cross-Validation
6. Đánh giá cuối cùng trên tập test bằng các độ đo chuẩn

Pipeline này giúp tách bạch rõ ràng phần trích xuất thông tin thị giác và phần học mô hình phân lớp, đồng thời thuận lợi cho so sánh/ablation.

3.2 Tiền xử lý ảnh

Giai đoạn tiền xử lý đóng vai trò then chốt để chuẩn hóa dữ liệu đầu vào cho các mô hình.

3.2.1. Phân chia dữ liệu (Data Splitting)

- **Quy trình chung:** Cả hai phương pháp đều sử dụng cùng một cấu trúc dữ liệu đã được phân chia sẵn thành hai thư mục riêng biệt: Train và Test.
- **Tỷ lệ:** Dựa trên số lượng ảnh thực tế được nạp vào mô hình (Train: ~12.642 ảnh, Test: ~3.162 ảnh), tỷ lệ phân chia là 80% Huấn luyện - 20% Kiểm tra.
 - *Lý do:* Tỷ lệ 80/20 đảm bảo cung cấp đủ dữ liệu cho việc xây dựng từ điển thị giác (trong SIFT-BoVW) và huấn luyện các bộ phân loại phức tạp, đồng thời giữ lại tập Test đủ lớn để đánh giá tin cậy.

3.2.2. Xử lý ảnh (Image Processing)

Tại bước này, có sự khác biệt trong cách xử lý kích thước ảnh giữa hai phương pháp:

3.2.2.1. Đối với nhóm phương pháp HOG và LBP (HOG_LBP):

- **Resize:** Toàn bộ ảnh được giảm kích thước về 128x128 pixels.

- *Mục đích:* Giảm chiều dữ liệu vector đặc trưng (tránh hiện tượng "bùng nổ" số chiều khi nối vector HOG và LBP), đồng thời tăng tốc độ tính toán mà vẫn giữ được cấu trúc biên dạng chính.
- **Grayscale:** Chuyển đổi sang ảnh xám để loại bỏ thông tin màu, tập trung vào cường độ sáng (intensity) cho việc tính gradient và kết cấu.

3.2.2.2. Đối với phương pháp SIFT & BoVW (SIFT)

- **Resize:** Giữ nguyên kích thước gốc (hoặc kích thước ảnh đầu vào), không thực hiện resize ép buộc về 128x128.
 - *Mục đích:* Thuật toán SIFT (Scale-Invariant Feature Transform) có khả năng tự động phát hiện đặc trưng ở nhiều tỉ lệ khác nhau (scale-invariant). Việc giữ nguyên độ phân giải giúp SIFT tìm được nhiều điểm đặc trưng (keypoints) chi tiết và chất lượng hơn so với ảnh bị thu nhỏ.
- **Grayscale:** Chuyển đổi sang ảnh xám trước khi trích xuất keypoints và descriptors.

3.3 Trích xuất đặc trưng

Thay vì đưa trực tiếp điểm ảnh vào mô hình, chúng em đã trích xuất các đặc trưng cao cấp hơn để mô tả nội dung của ảnh. Sự kết hợp giữa đặc trưng về hình dạng và màu sắc giúp mô hình có cái nhìn toàn diện hơn.

Thay vì đưa trực tiếp giá trị điểm ảnh (raw pixels) vào mô hình máy học, nhóm thực hiện trích xuất các đặc trưng cao cấp để mô tả nội dung hình ảnh một cách hiệu quả hơn. Chiến lược của nhóm là kết hợp các đặc trưng mô tả hình dáng (Shape) và kết cấu (Texture) để cung cấp cái nhìn toàn diện cho mô hình phân loại.

3.3.1. Histogram of Oriented Gradients (HOG)


a. Ý tưởng cốt lõi

HOG là bộ mô tả đặc trưng được thiết kế để nắm bắt thông tin về hình dạng và biên dạng của vật thể thông qua sự phân bố của hướng gradient (intensity gradients) và hướng biên (edge directions). Theo các nghiên cứu (ví dụ: Dalal & Triggs), HOG đặc biệt hiệu quả trong việc mô tả các đối tượng có cấu trúc hình học rõ ràng nhờ khả năng chịu đựng được những biến đổi nhỏ về hình dáng và ánh sáng.

b. Nguyên lý hoạt động

Quy trình trích xuất đặc trưng HOG được thực hiện qua các bước chính:

1. **Tính toán Gradient:** Ảnh đầu vào (đã chuyển sang ảnh xám) được tính toán đạo hàm theo hai hướng x và y để xác định cường độ và hướng của biên tại mỗi điểm ảnh.
2. **Xây dựng Histogram trên các Cell:** Ảnh được chia thành các ô nhỏ gọi là **cell** (cấu hình: 8x8 pixels). Tại mỗi cell, một histogram hướng gradient được xây dựng (thường gồm 9 bin).
3. **Chuẩn hóa theo Block:** Các cell được nhóm lại thành các khối lớn hơn gọi là **block** (2x2 cells) để chuẩn hóa độ sáng cục bộ.



Hình 3.3.1 Minh họa quy trình trích xuất đặc trưng HOG.

c. Ưu điểm

- **Mô tả hình dáng mạnh mẽ:** HOG cực kỳ hiệu quả trong việc nắm bắt cấu trúc biên dạng và hình dáng tổng thể của đối tượng (như dáng đứng, khuôn mặt), điều này rất quan trọng trong bài toán phân loại động vật.
- **Bền vững với ánh sáng:** Nhờ bước chuẩn hóa theo block (Block Normalization), đặc trưng HOG ít bị ảnh hưởng bởi sự thay đổi cường độ sáng và độ tương phản cục bộ của ảnh.
- **Chịu được biến đổi nhỏ:** HOG cho phép đối tượng có thể dịch chuyển hoặc biến đổi hình dáng nhỏ trong phạm vi của các cell mà không làm thay đổi quá nhiều vector đặc trưng.

d. Hạn chế

- **Nhạy cảm với phép xoay và tỷ lệ:** HOG truyền thống không có tính bất biến với phép xoay (Rotation) hoặc thay đổi kích thước lớn (Scale). Nếu ảnh đầu vào bị nghiêng hoặc phóng to/thu nhỏ quá mức, vector HOG sẽ thay đổi hoàn toàn.
- **Mất thông tin về kết cấu và màu sắc:** HOG chỉ tập trung vào biên dạng (Shape) mà bỏ qua các thông tin về độ mịn, độ thô ráp của bề mặt (Texture) hoặc màu sắc lông của động vật. Đây chính là lý do cần kết hợp HOG với các phương pháp khác như LBP.
- **Số chiều vector lớn:** Với ảnh kích thước 128x128, vector HOG có số chiều khá cao, đòi hỏi chi phí tính toán và lưu trữ lớn hơn so với các đặc trưng đơn giản.

3.3.2. Local Binary Patterns (LBP)


a. Ý tưởng cốt lõi

Nếu HOG mạnh về mô tả hình dáng biên dạng, thì LBP (Local Binary Patterns) là một bộ mô tả đặc trưng mạnh mẽ về kết cấu (texture) bề mặt. LBP hoạt động dựa trên việc so sánh cường độ sáng của pixel trung tâm với các pixel lân cận để mã hóa cấu trúc cục bộ của ảnh (như các chấm, cạnh, góc, vùng phẳng).

b. Nguyên lý hoạt động

Quy trình LBP được thực hiện như sau:

1. **So sánh với lân cận:** Với mỗi pixel trung tâm, so sánh giá trị cường độ sáng của nó với các pixel lân cận (trong đề án này sử dụng bán kính $R=2$ và số điểm lân cận $P=16$).
2. **Mã hóa nhị phân:** Nếu điểm lân cận lớn hơn hoặc bằng điểm tâm, gán bit 1; ngược lại gán bit 0. Các bit này tạo thành chuỗi nhị phân mô tả kết cấu.
3. **Xây dựng Histogram:** Tính toán tần suất xuất hiện của các mã nhị phân này (thường sử dụng biến thể Uniform LBP để giảm số chiều) trên toàn bộ ảnh để tạo thành vector đặc trưng.



Hình 3.3.2 Minh họa quy trình trích xuất đặc trưng LBP.

c. Ưu điểm

- **Bất biến với độ sáng:** LBP có khả năng chống lại sự thay đổi ánh sáng đơn điệu (monotonic illumination changes) vì nó chỉ quan tâm đến sự chênh lệch tương đối (lớn hơn/nhỏ hơn) giữa các pixel chứ không phụ thuộc giá trị tuyệt đối.
- **Hiệu quả tính toán:** Thuật toán đơn giản, tốc độ trích xuất đặc trưng rất nhanh.
- **Mô tả chi tiết bề mặt:** Rất nhạy bén trong việc phân biệt các loại bề mặt khác nhau (ví dụ: lông mượt vs lông xù), điều mà HOG thường bỏ qua.

d. Hạn chế

- **Nhạy cảm với nhiễu:** Do so sánh trực tiếp mức xám của từng pixel, LBP dễ bị ảnh hưởng bởi nhiễu hạt (noise) trong ảnh.
- **Thiếu thông tin hình dáng:** LBP không nắm bắt được cấu trúc hình học tổng thể của đối tượng (như hình dạng tai, mõm).

3.3.3. Scale-Invariant Feature Transform (SIFT)


a. Ý tưởng cốt lõi

SIFT (Scale-Invariant Feature Transform) là giải pháp cho vấn đề thay đổi tỷ lệ (scale) và phép xoay (rotation). SIFT tìm kiếm các "điểm đặc trưng" (keypoints) nổi bật và mô tả chúng theo cách không đổi ngay cả khi ảnh bị phóng to, thu nhỏ hay xoay.

b. Nguyên lý hoạt động

Quy trình được thực hiện kết hợp với mô hình Bag of Visual Words (BoVW):

1. **Phát hiện cực trị (Keypoint Detection):** Sử dụng Difference of Gaussians (DoG) để tìm các điểm đặc trưng ổn định qua nhiều mức tỷ lệ (scale-space).
2. **Mô tả đặc trưng (Descriptor):** Tại mỗi keypoint, trích xuất thông tin hướng gradient của vùng lân cận để tạo ra vector 128 chiều, đảm bảo tính bất biến với phép xoay.
3. **Bag of Visual Words (BoVW):** Các đặc trưng SIFT từ tập huấn luyện được gom cụm (sử dụng thuật toán **K-Means**) để tạo thành "từ điển thị giác". Mỗi ảnh sau đó được biểu diễn bằng một histogram thống kê tần suất xuất hiện của các từ này.



Hình 3.3.3 Minh họa các điểm đặc trưng SIFT (Keypoints) được phát hiện trên ảnh động vật và quy trình tạo từ điển thị giác (BoVW).

c. Ưu điểm

- **Tính bất biến mạnh mẽ:** SIFT rất mạnh trong việc nhận diện đối tượng khi ảnh bị thay đổi tỷ lệ (phóng to/thu nhỏ) hoặc xoay nghiêng – điều mà HOG cố định thường gặp khó khăn.
- **Chống nhiễu tốt:** Các đặc trưng cục bộ của SIFT tương đối bền vững với nhiễu và thay đổi độ sáng.

d. Hạn chế

- **Mất thông tin không gian (Spatial Information Loss):** Kỹ thuật BoVW gom các đặc trưng lại thành histogram, làm mất đi vị trí tương đối giữa các bộ phận (ví dụ: biết ảnh có "mắt" và "miệng" nhưng không biết mắt có nằm trên miệng hay không). Đây là lý do chính khiến SIFT hoạt động kém hơn HOG trên bộ dữ liệu khuôn mặt đã được căn chỉnh (aligned) .
- **Chi phí tính toán cao:** Việc phát hiện keypoint và tính toán descriptor trên không gian đa tỷ lệ tốn nhiều tài nguyên tính toán hơn so với HOG hay LBP.

3.3.4. Tổng hợp đặc trưng (Feature Fusion)

a. Ý tưởng

Nhận thấy HOG và LBP khai thác hai khía cạnh thông tin hoàn toàn khác biệt nhưng bổ sung cho nhau:

- **HOG:** Mạnh về mô tả hình dáng và cấu trúc biên dạng (Shape/Structure).
- **LBP:** Mạnh về mô tả chi tiết bề mặt và độ thô ráp (Texture).

Do đó, nhóm quyết định thực hiện chiến lược **Feature Fusion** (kết hợp đặc trưng) nhằm tận dụng ưu thế bù trừ, giúp mô hình có cái nhìn toàn diện nhất về đối tượng.

b. Phương pháp thực hiện

Quá trình tổng hợp được thực hiện qua 2 bước:

- Ghép nối vector (Concatenation):

Vector đặc trưng cuối cùng x_{fusion} được tạo thành bằng cách nối tiếp vector đặc trưng HOG (x_{hog}) và vector đặc trưng LBP(x_{lbp}) theo chiều ngang:

$$x_{fusion} = \{x_{hog}, x_{lbp}\}$$

Trong đó, $x_{fusion} \in R^{d_{hog}+d_{lbp}}$, tạo nên một không gian đặc trưng giàu thông tin hơn.

- Chuẩn hóa dữ liệu (Standardization):

Vì HOG và LBP có thang đo giá trị (scale) và phân phối khác nhau, việc ghép nối trực tiếp có thể khiến mô hình bị thiên lệch. Nhóm sử dụng kỹ thuật StandardScaler để đưa vector tổng hợp về phân phối chuẩn (mean=0, variance=1):

$$z = \frac{x - \mu}{\sigma}$$

Bước này đặc biệt quan trọng giúp thuật toán SVM hội tụ nhanh hơn và tìm được siêu phẳng tối ưu chính xác hơn.

3.4 Mô hình phân loại (RF and SVM)

Sau khi trích xuất đặc trưng, nhóm sử dụng hai thuật toán phân loại mạnh mẽ. Các siêu tham số (hyperparameters) được lựa chọn dựa trên quá trình thực nghiệm để đảm bảo sự cân bằng giữa độ chính xác và khả năng tổng quát hóa.

3.4.1 Random Forest (RF)


a. Ý tưởng cốt lõi

Random Forest (RF) là một thuật toán học có giám sát thuộc nhóm Ensemble Learning (Học tập kết hợp). Thay vì chỉ dựa vào một Cây quyết định (Decision Tree) duy nhất – vốn dễ bị nhạy cảm với nhiễu và có phương sai cao (high variance), RF xây dựng một "khu rừng" gồm rất nhiều cây quyết định song song để cùng đưa ra dự đoán.

b. Quy trình hoạt động

Cơ chế hoạt động của RF dựa trên phương pháp Bagging (Bootstrap Aggregating), bao gồm 4 bước chính:

- **Bootstrap Sampling (Lấy mẫu có hoàn lại):** Từ tập dữ liệu gốc D , thuật toán tạo ra K tập dữ liệu con bằng cách lấy mẫu ngẫu nhiên có hoàn lại (sampling with replacement). Điều này giúp mỗi cây có một cái nhìn khác nhau về dữ liệu.
- **Building the Trees (Xây dựng cây):** Các cây quyết định được xây dựng độc lập trên từng tập dữ liệu con.
- **Random Feature Selection (Chọn đặc trưng ngẫu nhiên):** Tại mỗi nút phân chia của cây, thay vì xem xét toàn bộ đặc trưng, thuật toán chỉ chọn ngẫu nhiên một tập con các đặc trưng. Kỹ thuật này giúp giảm sự tương quan (correlation) giữa các cây, làm cho mô hình mạnh mẽ hơn.
- **Aggregation (Tổng hợp kết quả):** RF sử dụng cơ chế "Majority Voting" (Bỏ phiếu đa số). Nhân nào nhận được nhiều phiếu bầu nhất từ tập hợp các cây sẽ là kết quả dự đoán cuối cùng.



Hình 3.4.1 Sơ đồ minh họa kiến trúc của Random Forest

c. Cấu hình tham số thực nghiệm

Dựa trên kết quả Grid Search, nhóm đã thiết lập cấu hình tối ưu cho mô hình Random Forest như sau (áp dụng cho cả HOG_LBP và SIFT):

- **Số lượng cây ($n_estimators = 500$):**
 - *Lý do:* Số lượng cây lớn (500) giúp mô hình ổn định hơn và bao quát được nhiều biến thể dữ liệu. Điều này đặc biệt quan trọng khi làm việc với các đặc trưng thủ công (HOG, LBP) vốn có độ nhiễu nhất định.
- **Độ sâu tối đa ($max_depth = 25$):**
 - *Lý do:* Giới hạn độ sâu giúp kiểm soát độ phức tạp của từng cây, ngăn chặn hiện tượng quá khớp (overfitting) – nơi cây cố gắng "học thuộc lòng" các nhiễu trong tập huấn luyện thay vì học quy luật chung.
- **Trọng số lớp ($class_weight = 'balanced'$):**
 - *Lý do:* Tham số này tự động điều chỉnh trọng số phạt, buộc mô hình chú ý nhiều hơn đến các mẫu thuộc lớp khó phân loại hoặc lớp thiểu số, giúp cải thiện độ chính xác cho các lớp dễ bị nhầm lẫn như 'Wild'.
- **Số mẫu tối thiểu tại nút lá ($min_samples_leaf = 2$):**
 - *Lý do:* Yêu cầu mỗi nút lá phải có ít nhất 2 mẫu giúp làm "trơn" (smooth) mô hình, tránh việc tạo ra các nhánh cây rẽ nhánh quá chi tiết chỉ để khớp với một mẫu dị biệt duy nhất.

d. Ưu điểm

- **Giảm thiểu Overfitting:** Nhờ cơ chế lấy mẫu ngẫu nhiên (Bootstrap) và chọn đặc trưng ngẫu nhiên, Random Forest giảm đáng kể phương sai (variance) của mô hình, khắc phục được nhược điểm "học vẹt" (overfitting) thường thấy ở cây quyết định đơn lẻ.
- **Hoạt động tốt trên dữ liệu hỗn hợp:** RF xử lý tốt các vector đặc trưng tổng hợp (như HOG kết hợp LBP) mà không cần giả định dữ liệu tuân theo phân phối chuẩn, đồng thời ít bị ảnh hưởng bởi các giá trị ngoại lai (outliers).
- **Xử lý mất cân bằng dữ liệu:** Thông qua tham số `class_weight='balanced'`, thuật toán có khả năng tự động điều chỉnh để không bỏ sót các lớp thiểu số hoặc các ca khó.


e. Hạn chế

- **Độ phức tạp và Tài nguyên:** Với cấu hình 500 cây (`n_estimators=500`), mô hình trở nên khá nặng, tiêu tốn nhiều bộ nhớ để lưu trữ và thời gian dự đoán lâu hơn so với các mô hình tuyến tính hay SVM.
- **Khả năng phân tách ở không gian chiều cao:** Mặc dù mạnh mẽ, nhưng trong không gian đặc trưng rất nhiều chiều (high-dimensional) tạo ra bởi HOG và LBP, Random Forest đôi khi gặp khó khăn trong việc tìm ra ranh giới phân lớp siêu phẳng tối ưu so với SVM (sử dụng Kernel Trick) .

3.4.2 Support Vector Machine (SVM)

a. Ý tưởng cốt lõi:

Siêu phẳng (Hyperplane) Support Vector Machine (SVM) là một thuật toán phân loại mạnh mẽ, hoạt động dựa trên nguyên lý tìm ra một siêu phẳng (hyperplane) tối ưu trong không gian nhiều chiều để phân tách các lớp dữ liệu. Mục tiêu là tìm ra siêu phẳng có lề (margin) lớn nhất – tức là khoảng cách xa nhất đến các điểm dữ liệu gần nhất (gọi là *Support Vectors*) của các lớp. Việc tối đa hóa lề này giúp mô hình đạt được khả năng tổng quát hóa tốt nhất trên dữ liệu mới.



Hình 3.4.2 Minh họa khái niệm siêu phẳng và lề tối ưu của SVM.

b. Giải quyết vấn đề phi tuyến

Trong thực tế, dữ liệu hình ảnh động vật (đặc biệt là sự tương đồng giữa Chó và Sói) rất phức tạp và thường không thể phân tách bằng một đường thẳng hay mặt phẳng tuyến tính. Để giải quyết vấn đề này, nhóm sử dụng kỹ thuật "Kernel Trick" với hàm nhân RBF (Radial Basis Function) .

Kỹ thuật này ánh xạ dữ liệu đầu vào từ không gian gốc (nơi các lớp bị trộn lẫn) sang một không gian đặc trưng (Feature space) có số chiều cao hơn, nơi mà dữ liệu trở nên phân tách được tuyến tính (linearly separable).

c. Cấu hình tham số thực nghiệm

Dựa trên kết quả thực nghiệm Grid Search, nhóm đã thiết lập cấu hình tối ưu cho mô hình SVM (khi kết hợp với đặc trưng HOG_LBP) như sau:

- **Tham số điều chuẩn ($C = 100$):**
 - *Ý nghĩa:* Nhóm chọn giá trị C lớn (100) thay vì giá trị mặc định (thường là 1.0). Giá trị C lớn đồng nghĩa với việc mô hình áp dụng mức phạt nặng hơn đối với các điểm bị phân loại sai trong tập huấn luyện.
 - *Lý do:* Điều này cho thấy mô hình chấp nhận biên "cứng" hơn để cố gắng tách biệt triệt để các đặc trưng HOG/LBP vốn có độ chồng lấn (overlap) cao giữa lớp 'Dog' và 'Wild'.
- **Hệ số Kernel ($\gamma = 0.001$):**
 - *Ý nghĩa:* Giá trị γ kiểm soát độ ảnh hưởng của một điểm dữ liệu huấn luyện đơn lẻ.

- *Lý do*: Mức 0.001 là một lựa chọn cân bằng, giúp tạo ra đường biên quyết định đủ linh hoạt để bao quanh các cụm dữ liệu phức tạp mà không quá uồn lượn gây ra hiện tượng overfitting.
- **Xác suất (probability = True):**
 - *Ý nghĩa*: Kích hoạt tính năng tính xác suất (sử dụng *Platt scaling*) để hệ thống trả về độ tin cậy (confidence score) cho mỗi dự đoán, hỗ trợ đắc lực cho việc phân tích các trường hợp nhầm lẫn (confusion analysis) ở chương sau.

d. Ưu điểm

- **Hiệu quả trong không gian chiều cao**: SVM đặc biệt mạnh mẽ khi số chiều của vector đặc trưng lớn (như trường hợp ghép nối HOG và LBP). Đây là lý do chính giúp SVM đạt độ chính xác cao hơn Random Forest trong bài toán này (95% so với 91%) .
- **Tính tổng quát hóa cao**: Nhờ cơ chế tối đa hóa lề (margin), SVM ít bị ảnh hưởng bởi nhiễu cục bộ hơn so với các thuật toán khác nếu chọn được tham số C phù hợp.

e. Hạn chế

- **Chi phí huấn luyện**: Thời gian huấn luyện của SVM tăng theo hàm bậc 2 hoặc bậc 3 của số lượng mẫu, do đó sẽ chậm hơn Random Forest khi tập dữ liệu rất lớn (tuy nhiên với ~15.000 ảnh của AFHQ thì vẫn trong mức chấp nhận được).
- **Khó diễn giải**: Khác với cây quyết định có thể trích xuất luật if-then dễ hiểu, mô hình SVM (đặc biệt với kernel RBF) hoạt động như một "hộp đen" khó diễn giải trực quan.

3.5 Ngôn ngữ & thư viện

Để thực hiện đồ án, nhóm sử dụng ngôn ngữ lập trình Python 3 trên môi trường Jupyter Notebook. Các thư viện mã nguồn mở đóng vai trò nòng cốt bao gồm:

- **Scikit-learn (sklearn)**: Thư viện cốt lõi cung cấp các thuật toán Machine Learning (Random Forest, SVM), các kỹ thuật tiền xử lý dữ liệu (StandardScaler, LabelEncoder), hỗ trợ phân chia tập dữ liệu (train_test_split), tối ưu tham số (GridSearchCV) và tính toán các độ đo đánh giá hiệu năng (classification_report, confusion_matrix).


- **Scikit-image (skimage):** Thư viện chuyên dụng cho xử lý ảnh, đóng vai trò quan trọng trong việc trích xuất các đặc trưng thủ công là **HOG** và **LBP**.
- **OpenCV (cv2):** Sử dụng cho các tác vụ đọc ảnh, thay đổi kích thước (resize) và chuyển đổi không gian màu (RGB sang Grayscale).
- **NumPy & Pandas:** Dùng để xử lý mảng đa chiều, thao tác trên ma trận số học và quản lý cấu trúc dữ liệu bảng.
- **Matplotlib & Seaborn:** Bộ công cụ trực quan hóa dữ liệu, được sử dụng để vẽ biểu đồ phân phối dữ liệu và hiển thị trực quan Ma trận nhầm lẫn (Confusion Matrix).
- **KaggleHub:** Tiện ích hỗ trợ tải và quản lý bộ dữ liệu AFHQ trực tiếp từ kho lưu trữ Kaggle.

CHƯƠNG 4. KẾT QUẢ THỰC NGHIỆM

4.1 Bộ dữ liệu và môi trường thực nghiệm

4.1.1. Bộ dữ liệu (Dataset)

- **Tên bộ dữ liệu:** Animal Faces-HQ (AFHQ).
- **Nguồn:** <https://www.kaggle.com/datasets/dimensi0n/afhq-512>.
- **Mô tả:** Bộ dữ liệu bao gồm 15,803 ảnh màu chất lượng cao, được gán nhãn vào 3 lớp:
 - **Cat (Mèo):** 5,558 ảnh.
 - **Dog (Chó):** 5,169 ảnh.
 - **Wild (Động vật hoang dã):** 5,076 ảnh.
 - *Nhận xét:* Số lượng ảnh giữa các lớp khá cân bằng về mặt số học.
- **Phân chia dữ liệu (Data Splitting):** Khác với các tiếp cận truyền thống, nhóm quyết định phân chia dữ liệu theo tỷ lệ 80% Huấn luyện (Train) và 20% Kiểm tra (Test).
 - Tập Train (12,642 ảnh): Dùng để huấn luyện mô hình và thực hiện kiểm chứng chéo (Cross-Validation) nhằm tìm tham số tối ưu.
 - Tập Test (3,161 ảnh): Dữ liệu hoàn toàn mới, chỉ được dùng một lần duy nhất để đánh giá hiệu năng cuối cùng.



Hình 4.1.1 Số ảnh theo các lớp trong dataset

4.1.2. Môi trường và Cấu hình thực nghiệm (Experimental Setup)

Để đảm bảo tính khách quan và khả năng tái lập kết quả (reproducibility), các thực nghiệm được triển khai trên môi trường thống nhất:

- **Môi trường:** Google Colab (GPU T4 Runtime).
- **Ngôn ngữ & Thư viện:** Python 3.10, Scikit-learn 1.2.2, OpenCV 4.8, Scikit-image 0.19.
- **Thiết lập tái lập:** Tất cả các hàm có yếu tố ngẫu nhiên (train_test_split, RandomForest, SVM probability) đều được cố định tham số random_state=42.
- **Mã nguồn:** Toàn bộ mã nguồn thực nghiệm được lưu trữ tại:
[NBasLongz/AnimalClassification](https://github.com/NBasLongz/AnimalClassification)

4.2 Độ đo

Để đánh giá hiệu năng của các mô hình, chúng em sử dụng các độ đo tiêu chuẩn trong bài toán phân loại:

- **Confusion Matrix (Ma trận nhầm lẫn):** Một bảng cho thấy số lượng dự đoán đúng và sai cho từng lớp, giúp nhận diện lớp nào mô hình đang gặp khó khăn.
- **Accuracy:** Tỷ lệ số điểm dữ liệu được dự đoán đúng trên tổng số điểm dữ liệu.
$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$
- **Precision, Recall, F1-Score:** Các độ đo này cung cấp cái nhìn chi tiết hơn về hiệu năng trên từng lớp, đặc biệt hữu ích khi dữ liệu mất cân bằng. Chúng em sử dụng trung bình macro để đánh giá tổng thể mô hình mà không thiên vị các lớp có số lượng mẫu lớn.
 - **Macro F1-Score:** Trung bình cộng của F1-Score trên tất cả các lớp.


4.3 Kết quả

4.3.1 Kết quả trích xuất đặc trưng bằng LBP


Đầu tiên, nhóm thiết lập mô hình chỉ sử dụng đặc trưng **Local Binary Patterns (LBP)**. Mục tiêu là đánh giá xem thông tin về "kết cấu bề mặt" (như độ mịn của lông, độ sần sùi của da) đóng góp bao nhiêu phần trăm vào khả năng nhận diện động vật.

a. Kết quả định lượng (Quantitative Results)

Nhóm đã tiến hành thử nghiệm trên cả hai mô hình phân loại là Random Forest và SVM để có cái nhìn khách quan.



Hình 4.3.1a Kết quả thực nghiệm của mô hình Random Forest với đặc trưng LBP.



Hình 4.3.1b Kết quả thực nghiệm của mô hình SVM với đặc trưng LBP.

b. Phân tích và Nhận xét

- **Hiệu năng tổng thể:**

- Với độ chính xác đạt khoảng 68% đối với SVM và 67% đối với Random Forest, đặc trưng LBP cho thấy khả năng phân loại tốt hơn đáng kể so với mức ngẫu nhiên (33%). Tuy nhiên, mức hiệu năng này vẫn còn khá hạn chế nếu so với yêu cầu của một hệ thống nhận diện thị giác máy tính có độ tin cậy cao trong thực tế.
- Mô hình SVM cho kết quả nhỉnh hơn Random Forest khoảng 1%, cho thấy SVM phù hợp hơn với dạng không gian đặc trưng mà LBP tạo ra, vốn là các vector histogram có chiều cao và phân bố thưa. Khả năng tối ưu siêu

phẳng phân tách của SVM giúp mô hình khai thác tốt hơn các khác biệt nhỏ trong phân bố kết cấu giữa các lớp.


- **Hạn chế cốt lõi:**

- Do LBP chỉ mô tả kết cấu cục bộ và không mã hóa thông tin về hình dáng hay bố cục không gian, mô hình gần như “mù” trước các đặc trưng cấu trúc quan trọng của khuôn mặt như hình dạng mắt, mũi, tai hay tỷ lệ các bộ phận.
 - Điều này dẫn đến hiện tượng nhầm lẫn cao giữa các lớp có kết cấu lông tương tự, đặc biệt là giữa *Dog* và *Wild*, khi nhiều giống chó và các loài thuộc nhóm hoang dã (sói, cáo) có họa tiết lông và mật độ kết cấu gần giống nhau do đó vượt quá khả năng phân biệt của LBP khi không có thông tin biên dạng hỗ trợ.
- **Kết luận bước đầu:** LBP không đủ mạnh để được sử dụng như một đặc trưng độc lập cho bài toán phân loại khuôn mặt động vật. Tuy nhiên, phương pháp này vẫn cung cấp các thông tin quan trọng về kết cấu bề mặt (texture cues) – một loại tín hiệu mà các phương pháp dựa trên hình dạng có thể bỏ sót. Do đó, LBP đóng vai trò phù hợp như một đặc trưng bổ trợ khi kết hợp với các phương pháp dựa trên cấu trúc toàn cục như HOG trong các mô hình lai (hybrid features).


4.3.2. Thực nghiệm với đặc trưng HOG

Sau khi nhận thấy hạn chế của LBP trong việc mô tả hình dáng, nhóm tiến hành thử nghiệm với đặc trưng Histogram of Oriented Gradients (HOG). Đây là phương pháp tập trung vào việc mô tả cấu trúc biên dạng và hình dáng của đối tượng (Shape & Structure).

a. Kết quả định lượng (Quantitative Results)



Hình 4.3.2a Kết quả thực nghiệm của mô hình Random Forest với đặc trưng HOG.



Hình 4.3.2b. Kết quả thực nghiệm của mô hình Random Forest với đặc trưng HOG.

b. Phân tích và Lý luận (Reasoning & Discussion)

Kết quả cho thấy HOG đạt độ chính xác rất cao, khoảng 90% với Random Forest và lên đến 94% với SVM, vượt đáng kể so với các phương pháp trích xuất đặc trưng cổ điển thông thường. Nhóm đưa ra các lý giải sau:

- Sự phù hợp với bộ dữ liệu AFHQ (Dataset Alignment Bias):

- Bộ dữ liệu AFHQ bao gồm các ảnh chất lượng cao đã được căn chỉnh (aligned) chặt chẽ, trong đó các bộ phận khuôn mặt như mắt, mũi và miệng luôn xuất hiện ở các vị trí gần như cố định trong khung hình 128×128 .
- Do HOG biểu diễn ảnh thông qua các histogram gradient trên các ô lưới (grid cells), sự ổn định về vị trí này giúp các đặc trưng biên dạng (tai, sống mũi, viền mặt) luôn rơi vào cùng các cell tương ứng giữa các ảnh khác nhau. Điều này làm cho không gian đặc trưng trở nên rất nhất quán và dễ phân tách đối với các mô hình học máy.
- Nhận định: nếu áp dụng mô hình này cho ảnh chụp tự nhiên không căn chỉnh (nghiêng, xoay, lệch tâm), độ chính xác của HOG nhiều khả năng sẽ suy giảm đáng kể.
- **Sức mạnh của thông tin Hình dáng (Shape):**
 - Sự cải thiện mạnh mẽ từ LBP (~68%) lên HOG (~90–94%) cho thấy trong bài toán phân loại động vật, thông tin hình dáng (tai nhọn/cúp, độ dài mõm, cấu trúc khuôn mặt) mang giá trị định danh cao hơn so với kết cấu bề mặt của lông.
 - Đặc biệt, lớp Cat đạt độ chính xác rất cao (recall và precision > 95%) nhờ cấu trúc khuôn mặt khác biệt rõ rệt so với hai lớp còn lại.
- **Điểm yếu còn tồn tại (The Remaining Gap):**
 - Mặc dù độ chính xác tổng thể cao, sự nhầm lẫn giữa hai lớp Dog và Wild vẫn tương đối đáng kể. Nguyên nhân là do về mặt hình học, nhiều giống chó (ví dụ Husky) và sói có cấu trúc hộp sọ, vị trí tai và đường viền khuôn mặt gần như tương đồng.
 - HOG chỉ mô tả thông tin biên dạng mà không phản ánh được sự khác biệt về mật độ hay chất liệu lông, do đó khó phân biệt hai lớp này trong các trường hợp biên.

c. Kết luận


HOG đóng vai trò là thành phần then chốt giúp hệ thống đạt độ chính xác cao nhờ tận dụng tốt đặc điểm căn chỉnh của bộ dữ liệu AFHQ. Tuy nhiên, những nhầm lẫn còn tồn tại giữa Dog và Wild cho thấy việc kết hợp thêm thông tin kết cấu từ LBP là cần thiết để xây dựng một mô hình phân loại ổn định và tổng quát hơn.

4.3.3 Kết quả trích xuất đặc trưng bằng HOG và LBP


Sau khi đánh giá riêng lẻ từng loại đặc trưng, nhóm tiến hành chiến lược Feature Fusion: kết nối (concatenate) vector đặc trưng hình dáng (HOG) và vector đặc trưng kết cấu (LBP Histogram) thành một vector duy nhất để huấn luyện mô hình. Đây là bước quan trọng nhằm tận dụng ưu điểm bù trừ của cả hai phương pháp.

a. Kết quả định lượng (Quantitative Results)

Kết quả thực nghiệm cho thấy sự cải thiện rõ rệt về độ ổn định và chỉ số tổng thể.



Hình 4.3.3a Kết quả thực nghiệm phương pháp Fusion với Random Forest.



Hình 4.3.3b Kết quả thực nghiệm phương pháp Fusion với SVM.

b. Phân tích chuyên sâu (Deep Dive Analysis)

Tại sao việc kết hợp lại mang lại kết quả tối ưu như vậy?

1. Sự cộng hưởng (Synergy Effect):

- HOG cung cấp "khung xương": Giúp mô hình phân biệt rất nhanh các loài có cấu trúc mặt khác nhau (như Mèo vs. Chó).
- LBP cung cấp "da thịt": Giúp mô hình soi kỹ vào chất liệu bề mặt để phân xử các ca khó mà khung xương giống nhau.
- *Minh chứng*: Hãy nhìn vào chỉ số của lớp Wild trong bảng SVM. Precision và Recall đều tăng vọt lên mức >93%. Điều này chứng tỏ mô hình không còn bị nhầm lẫn giữa Chó nhà và Sói hoang đã nhiều như khi chỉ dùng HOG đơn lẻ.

2. Khắc phục điểm mù:

- Nếu chỉ dùng HOG, một con chó Husky và một con Sói có thể có vector đặc trưng giống nhau đến 90%.
- Nhưng khi thêm LBP, sự khác biệt về độ xù của lông và chi tiết vùng mắt/mồm được bổ sung vào vector đặc trưng, giúp SVM tìm ra được siêu phẳng phân tách (hyperplane) chính xác hơn hẳn.

3. So sánh hiệu năng mô hình (RF vs. SVM):

- SVM vượt trội hơn Random Forest trong bài toán này (95% so với 91%).
- *Lý do*: Vector đặc trưng tổng hợp (HOG+LBP) có số chiều rất lớn. SVM với Kernel RBF có khả năng xử lý dữ liệu chiều cao (High-dimensional data) tốt hơn và ít bị nhiễu hơn so với cơ chế cây quyết định của Random Forest.

c. Kết luận

Chiến lược kết hợp HOG + LBP cùng mô hình SVM là giải pháp tối ưu nhất cho bài toán này trên tập dữ liệu AFHQ, đạt độ chính xác ấn tượng (~95%) mà không cần sử dụng đến các mạng nơ-ron tích chập (CNN) phức tạp, đảm bảo cân bằng giữa hiệu năng và chi phí tính toán.


Điều này cho thấy các phương pháp cổ điển, khi được thiết kế đặc trưng phù hợp, vẫn có thể đạt hiệu năng cạnh tranh trong các bài toán phân loại thị giác quy mô vừa.

4.3.4 Kết quả trích xuất đặc trưng bằng SIFT


Ngoài hai phương pháp chính là HOG và LBP, nhóm cũng tiến hành thực nghiệm với phương pháp Scale-Invariant Feature Transform (SIFT) kết hợp mô hình Bag of

Visual Words (BoVW). Đây là phương pháp tiếp cận dựa trên các điểm đặc trưng cục bộ (keypoints), khác biệt hoàn toàn với cách tiếp cận "cửa sổ trượt" của HOG.

a. Kết quả định lượng (Quantitative Results)



Hình 4.3.4a Kết quả thực nghiệm phương pháp SIFT với RF.



Hình 4.3.4b Kết quả thực nghiệm phương pháp SIFT với SVM.

b. Phân tích và So sánh (Analysis & Comparison)

- **Hiệu năng khá tốt nhưng chưa tối ưu:**
 - Với độ chính xác 87% (SVM), SIFT chứng tỏ khả năng nhận diện tốt hơn LBP đơn lẻ (68%) nhưng vẫn thấp hơn HOG, vốn đạt từ 90% (Random Forest) đến 94% (SVM) trên cùng bộ dữ liệu.

- *Nguyên nhân*: SIFT hoạt động bằng cách tìm các điểm đặc trưng cục bộ (góc mắt, chóp mũi) và gom nhóm chúng lại (BoVW). Quá trình gom nhóm này (Quantization) làm mất đi thông tin về vị trí không gian của các điểm đó. Ví dụ: SIFT biết ảnh có "mắt" và "mũi", nhưng không biết chắc chắn mắt có nằm trên mũi hay không. Trong khi đó, HOG bảo toàn cấu trúc hình học này rất tốt.
- **Ưu điểm về tính bất biến (Invariance):**
 - Mặc dù thấp hơn HOG trên tập dữ liệu chuẩn (AFHQ), SIFT có ưu điểm lý thuyết là mạnh mẽ hơn khi đối mặt với các biến thể xoay (rotation) hoặc thay đổi tỷ lệ (scale) lớn – những điều mà HOG cố định (fixed grid) thường gặp khó khăn.
- **Phân loại nhầm những ảnh chó, mèo “gần giống nhau”**
 - Bộ dataset có một số tấm ảnh có một số đặc điểm khá tương đồng giữa hai lớp chó và mèo như màu lông, khuôn mặt.
 - Các mẫu mèo trong nhóm này thường sở hữu mật độ kết cấu lông dày, tạo ra các độ dốc gradient (gradient magnitudes) mạnh và phức tạp tương tự như lớp Chó. Điều này khiến các SIFT Descriptors cục bộ rơi vào cùng một cụm Visual Words (từ điển thị giác) trong không gian đặc trưng.
 - Hơn nữa, sự tương đồng về cấu trúc hình học cục bộ (mồm ngấn, mắt tròn, khoảng cách gian nhãn hẹp) dẫn đến sự trùng lặp trong phân bố các Keypoints. Khi kết hợp với mô hình BoVW vốn lược bỏ thông tin vị trí toàn cục, sự chồng lấn giữa các vector đặc trưng của hai lớp trở nên trầm trọng, làm giảm khả năng tìm ranh giới phân tách tối ưu của bộ phân loại SVM trong việc xác định ranh giới quyết định chính xác.



Hình 4.3.4c: Những hình ảnh nổi bật nhằm mèo thành chó.

- Những mẫu chó trong nhóm này có khuôn mặt tròn, mắt to và mõm ngắn, tạo hình thái tổng thể tương đối giống với mèo. Đồng thời, vùng lông mặt dày và có kết cấu phức tạp sinh ra nhiều gradient cục bộ, khiến các descriptor SIFT trích xuất được có xu hướng tương đồng với các mẫu mèo lông dài.
- Do mô hình BoVW chỉ biểu diễn ảnh thông qua phân bố các “visual words” cục bộ mà không nắm bắt rõ cấu trúc hình học toàn cục của khuôn mặt, nên các vector đặc trưng của những mẫu chó này dễ chồng lấn với lớp mèo, dẫn đến hiện tượng phân loại nhầm.



Hình 4.3.4d: Những hình ảnh nổi bật nhằm chó thành mèo.

- Sự tương đồng này không chỉ nằm ở cảm quan, mà nằm ở không gian đặc trưng (Feature Space). Trong kỹ thuật Bag of Visual Words, các 'từ vựng thị giác' được tạo ra từ việc gom cụm (Clustering) các descriptor. Khi kết cấu lông mèo và chó quá giống nhau, chúng được gom vào chung một 'từ vựng'. Vì BoVW không quan tâm đến việc 'từ vựng' đó nằm ở vị trí nào trên mặt, nên chỉ cần ảnh chó có nhiều 'từ vựng kết cấu' giống mèo, mô hình sẽ đưa ra kết quả sai.
- Tuy nhiên, không hề phủ nhận có rất nhiều bức hình chứa những ảnh rất đặc trưng của chó, mèo nhưng mô hình nhận diện sai. Cho thấy hạn chế đối với các cách trích xuất đặc trưng mang tính rõ ràng hơn. Bên cạnh đó, mô hình có thể đã bỏ sót một lượng đặc trưng nhất định làm cho mô hình gặp khó khăn trong phân loại.
- **Kết luận:**
 - SIFT là một phương pháp mạnh, nhưng đối với bộ dữ liệu khuôn mặt đã được căn chỉnh (aligned) như AFHQ, phương pháp dựa trên cấu trúc toàn cục như HOG (và đặc biệt là HOG+LBP) vẫn là lựa chọn vượt trội hơn về độ chính xác.

4.4. So sánh và Đánh giá tổng quan

Sau khi thực hiện các thí nghiệm riêng lẻ, nhóm tổng hợp kết quả của cả 4 phương pháp tiếp cận: LBP (Kết cấu), SIFT-BoVW (Điểm đặc trưng cục bộ), HOG (Hình dáng) và HOG + LBP (Kết hợp).

4.4.1. Bảng tổng hợp kết quả thực nghiệm

Bảng dưới đây so sánh các chỉ số đánh giá chính trên tập kiểm thử (Test Set) của 4 phương pháp.

Bảng 4.4.1. So sánh hiệu năng giữa các phương pháp trích xuất đặc trưng

STT	Phương pháp trích xuất	Mô hình phân loại	Accuracy (%)
1	LBP (Baseline)	RF	67
2	LBP (Baseline)	SVM	68
3	SIFT (BoVW)	RF	80
4	SIFT (BoVW)	SVM	87
5	HOG	RF	90
6	HOG	SVM	94
7	HOG + LBP (Fusion)	RF	91
8	HOG + LBP (Fusion)	SVM	95

4.4.2. Phân tích so sánh

Dựa trên bảng số liệu trên, nhóm rút ra những nhận định quan trọng sau:

- **Về thứ bậc hiệu năng (Performance Hierarchy):**

Rõ ràng có sự phân cấp hiệu năng theo thứ tự tăng dần:

$$\text{LBP} < \text{SIFT} < \text{HOG} < \text{HOG} + \text{LBP}$$

- **LBP (Thấp nhất):** Do chỉ dựa vào vi mô kết cấu (lông, da) mà bỏ qua cấu trúc tổng thể, LBP gặp khó khăn lớn trong việc phân biệt các loài có chất liệu lông tương đồng.
- **SIFT (Trung bình):** SIFT cải thiện hơn LBP nhờ các điểm đặc trưng mạnh, nhưng kỹ thuật Bag of Visual Words (BoVW) làm mất đi thông tin vị trí không

gian (spatial info) của các bộ phận khuôn mặt, khiến nó kém hiệu quả hơn HOG trên tập dữ liệu này.

- **HOG (Cao):** HOG vượt trội hơn hẳn hai phương pháp trên nhờ khả năng mô tả "khung xương" khuôn mặt. Do bộ dữ liệu AFHQ đã được căn chỉnh (aligned), các đặc trưng biên dạng của HOG trở nên cực kỳ mạnh mẽ.

- **Hiệu quả của chiến lược kết hợp (Feature Fusion):**

Phương pháp HOG + LBP đạt kết quả cao nhất, chứng minh giả thuyết ban đầu của nhóm là đúng:

- **Tính bù trừ:** HOG giúp định hình đối tượng là "Chó" hay "Mèo" dựa trên tai, mắt. LBP giúp xác định đó là "Chó nhà" hay "Chó sói" dựa trên độ thô ráp của bộ lông.
- **Tính bền vững:** Việc kết hợp giúp mô hình không bị phụ thuộc hoàn toàn vào một loại thông tin duy nhất, giảm thiểu rủi ro khi một trong hai đặc trưng bị nhiễu.

- Về lựa chọn mô hình phân loại (RF vs. SVM):

Trong hầu hết các thực nghiệm, Support Vector Machine (SVM) luôn cho kết quả nhỉnh hơn hoặc bằng Random Forest (RF).

- *Lý do:* Các vector đặc trưng (đặc biệt là HOG và Fusion) có số chiều rất lớn (High-dimensional space). SVM với Kernel RBF có khả năng tìm kiếm siêu phẳng phân tách trong không gian chiều cao tốt hơn và ít bị quá khớp (overfitting) hơn so với mô hình cây quyết định của Random Forest.

4.5. Kết luận chương

Từ các kết quả thực nghiệm, nhóm quyết định lựa chọn phương pháp **Feature Fusion (HOG + LBP) kết hợp với mô hình SVM** làm giải pháp cuối cùng cho bài toán. Đây là sự lựa chọn cân bằng tốt nhất giữa việc tận dụng tri thức chuyên gia (thông qua thiết kế đặc trưng thủ công) và khả năng tổng quát hóa của thuật toán máy học.

CHƯƠNG 5. ĐÁNH GIÁ VÀ NHẬN XÉT

5.1 Ưu điểm

- **Hiệu năng ấn tượng:** Cả hai mô hình (đặc biệt là SVM với sự kết hợp HOG+LBP) đều đạt độ chính xác trên 94%, thậm chí lên tới 95%. Đây là một kết quả rất tích cực đối với phương pháp học máy truyền thống trên tập dữ liệu đa dạng như AFHQ.
- **Quy trình thực nghiệm chuẩn mực:** Đồ án đã tuân thủ chặt chẽ quy trình khoa học: từ tiền xử lý, trích xuất đặc trưng, tối ưu tham số (Grid Search) đến đánh giá đa chiều (Accuracy, F1-Score, Confusion Matrix).
- **Khả năng diễn giải (Interpretability):** So với các mô hình Deep Learning "hộp đen", phương pháp sử dụng đặc trưng thủ công giúp nhóm hiểu rõ lý do tại sao mô hình hoạt động tốt (ví dụ: HOG nắm bắt hình dáng) hoặc tại sao thất bại (ví dụ: LBP nhiễu do nền phức tạp).

5.2 Hạn chế

- **Phụ thuộc vào chất lượng đặc trưng:** Hiệu năng hệ thống bị giới hạn bởi khả năng biểu diễn của HOG và LBP. Các đặc trưng này được thiết kế thủ công nên khó thích nghi với các biến thể phức tạp (như chó sói có hình dáng quá giống chó nhà nhưng khác môi trường sống).
- **Nhạy cảm với dữ liệu đầu vào:** Mô hình gặp khó khăn khi ảnh bị thay đổi góc chụp lớn, bị che khuất hoặc điều kiện ánh sáng kém. Đặc biệt, phương pháp HOG yêu cầu ảnh phải được căn chỉnh (align) tốt, nếu không hiệu quả sẽ giảm sút.
- **Giới hạn về khả năng mở rộng:** Nếu mở rộng bài toán lên hàng trăm, hàng nghìn loài động vật khác nhau, việc chỉ dựa vào HOG/LBP/SIFT sẽ không đủ sức phân biệt các đặc điểm tinh tế, dẫn đến độ chính xác giảm mạnh.

5.3 Hướng phát triển

- **Áp dụng Deep Learning (CNN):** Đây là hướng đi tiềm năng nhất. Thay vì trích xuất đặc trưng thủ công, nhóm đề xuất sử dụng các mạng Neural tích chập (như ResNet, VGG16, EfficientNet) kết hợp kỹ thuật **Transfer Learning** để mô hình

tự động học các đặc trưng phức tạp từ dữ liệu, hứa hẹn cải thiện độ chính xác lên mức 98-99%.

- **Tăng cường dữ liệu (Data Augmentation):** Trong tương lai, cần áp dụng các kỹ thuật như xoay, lật, cắt ngẫu nhiên (Random Crop) hoặc thay đổi độ sáng ngay trong quá trình huấn luyện để tăng tính tổng quát hóa, giúp mô hình "bền" hơn với ảnh thực tế.
- **Xây dựng ứng dụng thực tế:** Triển khai mô hình tốt nhất (Best Model) lên môi trường Web hoặc Mobile App để người dùng có thể tải ảnh lên và nhận kết quả dự đoán theo thời gian thực.

TÀI LIỆU THAM KHẢO

- [1] A. Sen, G. Maiti, B. K. Parida, B. P. Mishra, M. Arya và D. I. Bondar, “Feature Engineering is Not Dead: Reviving Classical Machine Learning with Entropy, HOG, and LBP Feature Fusion for Image Classification,” *arXiv preprint arXiv:2507.13772*, 2025, doi: 10.48550/arXiv.2507.13772. [Trực tuyến]. Có tại: <https://arxiv.org/abs/2507.13772>
- [2] G. Cheng, J. Chen, Y. Wei, S. Chen và Z. Pan, “A Coal Gangue Identification Method Based on HOG Combined with LBP Features and Improved Support Vector Machine,” *Symmetry*, tập 15, số 1, tr. 202, 01/2023. [Trực tuyến]. Có tại: <https://www.mdpi.com/2073-8994/15/1/202>
- [3] Z. Sedaghatjoo, H. Hosseinzadeh và B. S. Bigham, "Local Binary Pattern (LBP) Optimization for Feature Extraction," *arXiv preprint arXiv:2407.18665*, 2024. [Trực tuyến]. Có tại: <https://arxiv.org/abs/2407.18665>
- [4] A. Sukanya, "Histogram of Oriented Gradients (HOG) in Computer Vision," *Towards Data Science*, 2023. [Trực tuyến]. Có tại: <https://towardsdatascience.com/histogram-of-oriented-gradients-hog-in-computer-vision-a2ec66f6e671/>
- [5] A. Vina, “What is the Scale-Invariant Feature Transform (SIFT)?,” *Ultralytics Blog*, 09/09/2025. [Trực tuyến]. Có tại: <https://www.ultralytics.com/blog/what-is-the-scale-invariant-feature-transform-sift>
- [6] N. Donges, “Random Forest: A Complete Guide for Machine Learning,” *Built In*, cập nhật 26/11/2024. [Trực tuyến]. Có tại: <https://builtin.com/data-science/random-forest-algorithm>
- [7] Scikit-learn Developers, “Scikit-learn User Guide v1.5: Ensemble Methods (Random Forest) & SVM Implementation,” *Scikit-learn.org*, 2024. [Trực tuyến]. Có tại: https://scikit-learn.org/stable/user_guide.html
- [8] Kaggle Dataset, “Animal Faces-HQ (AFHQ) - 512x512 Resized,” *Kaggle.com*. [Trực tuyến]. Có tại: <https://www.kaggle.com/datasets/dimensi0n/afhq-512>