

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH**



CÁC KỸ THUẬT HỌC SÂU VÀ ỨNG DỤNG (CS431)

RAG-based Lecture Video Q&A System

GVHD: TS. Nguyễn Vinh Tiệp
Sinh viên: Lương Quang Duy - 23520368
Nguyễn Bá Long - 23520880
Dương Thái Ý Nhi - 23521106

Ngày 20 tháng 04 năm 2026

Mục lục

1	Giới thiệu đề tài	2
1.1	Bối cảnh và Lý do chọn đề tài	2
1.2	Phát biểu bài toán	2
1.2.1	Mô hình hóa không gian dữ liệu đầu vào	2
1.2.2	Hàm mục tiêu và Ràng buộc hệ thống	3
1.3	Đóng góp cốt lõi của đề tài	3
2	Bộ dữ liệu	4
2.1	Tổng quan không gian tri thức	4
2.2	Quy trình xây dựng dữ liệu (Data Ingestion)	4
2.2.1	Trích xuất luồng dữ liệu (Data Extraction)	4
2.2.2	Xử lý đa phương thức (Multimodal Processing)	4
2.2.3	Tiền xử lý và Chuẩn hóa văn bản (Text Preprocessing)	5
2.2.4	Hợp nhất và Phân đoạn theo thời gian (Merge & Chunking)	5
2.2.5	Lập chỉ mục và Lưu trữ (Indexing & Storage)	5
3	Kiến trúc hệ thống	6
3.1	Tổng quan kiến trúc phần mềm	6
3.2	Luồng xử lý đa phương thức (Pipeline)	6
3.3	Cơ chế kiểm duyệt và Biến đổi truy vấn	7
3.4	Hệ thống truy xuất lai (Hybrid Retrieval Engine)	7
3.5	Kiến trúc xếp hạng lại và Tạo sinh ngôn ngữ	7
4	Phương pháp	9
4.1	Tổng quan khung thuật toán	9
4.2	Định tuyến và Biến đổi Truy vấn (Routing & Query Transformation)	9
4.3	Công cụ truy xuất lai (Hybrid Retrieval)	9
4.3.1	Phép truy xuất từ vụng (Sparse Retrieval)	10
4.3.2	Phép truy xuất đặc tuyến (Dense Retrieval)	10
4.3.3	Thuật toán hợp nhất (Reciprocal Rank Fusion)	10
4.4	Xếp hạng lại bằng mã hóa chéo (Cross-Encoder Reranking)	11
4.5	Tạo sinh ngôn ngữ tăng cường truy xuất	11
5	Thực nghiệm	12
5.1	Phương pháp đánh giá và Các chỉ số đo lường	12
5.2	Thiết lập thực nghiệm	13
5.3	Kết quả và Thảo luận	13
6	Kết luận	15
6.1	Tổng kết quá trình nghiên cứu và kết quả đạt được	15
6.2	Hạn chế của hệ thống	15
	Tài liệu tham khảo	16

1 Giới thiệu đề tài

1.1 Bối cảnh và Lý do chọn đề tài

Trong bối cảnh giáo dục hiện đại, video bài giảng ngày càng trở thành một nguồn tài nguyên học tập quan trọng, đặc biệt đối với các môn học mang tính kỹ thuật cao. Đối với học phần CS431 (Các kỹ thuật học sâu và ứng dụng), nội dung bài giảng thường được truyền tải thông qua các video có thời lượng dài và chứa mật độ thông tin lớn. Điều này vô hình trung tạo ra rào cản cho sinh viên khi cần tìm kiếm nhanh một nội dung cụ thể, đặc biệt là trong quá trình ôn tập hoặc giải quyết các thắc mắc chi tiết liên quan đến bài học. Các phương pháp thủ công như tua video hoặc tìm kiếm dựa trên từ khóa đơn giản thường không mang lại hiệu quả cao, đồng thời tiêu tốn đáng kể thời gian của người học.

Bên cạnh đó, phần lớn các hệ thống tìm kiếm hiện nay vẫn dựa trên cơ chế đối sánh từ khóa, thiếu khả năng hiểu ngữ nghĩa của truy vấn và không tận dụng được các nguồn thông tin đa phương tiện như âm thanh lời giảng và nội dung trên slide. Điều này dẫn đến khoảng cách đáng kể giữa cách sinh viên đặt câu hỏi bằng ngôn ngữ tự nhiên và cách tri thức được lưu trữ trong dữ liệu bài giảng.

Xuất phát từ những hạn chế đó, đề tài này hướng đến việc xây dựng một hệ thống Hỏi-Đáp (Q&A) thông minh, được thiết kế dành riêng cho dữ liệu video bài giảng của môn CS431. Hệ thống cho phép người dùng đặt câu hỏi bằng ngôn ngữ tự nhiên và nhận lại câu trả lời có cấu trúc, đi kèm với các trích dẫn cụ thể (ID video và mốc thời gian) trở trực tiếp đến các phân đoạn liên quan trong video. Cách tiếp cận này không chỉ giúp rút ngắn thời gian tìm kiếm thông tin mà còn hỗ trợ người học kiểm chứng lại nội dung một cách trực quan.

Để hiện thực hóa mục tiêu trên, hệ thống được xây dựng dựa trên kiến trúc Retrieval-Augmented Generation (RAG), kết hợp với các kỹ thuật xử lý dữ liệu đa phương thức như nhận dạng giọng nói (ASR) và nhận dạng ký tự quang học (OCR). Sự kết hợp này cho phép chuyển đổi dữ liệu video sang dạng văn bản có cấu trúc, đồng thời giảm thiểu hiện tượng sinh thông tin không chính xác (hallucination) thường gặp ở các mô hình ngôn ngữ lớn.

1.2 Phát biểu bài toán

1.2.1 Mô hình hóa không gian dữ liệu đầu vào

Để mô tả bài toán một cách hình thức, không gian dữ liệu đầu vào của hệ thống được biểu diễn dưới dạng một tập hợp các video bài giảng $V = \{v_1, v_2, \dots, v_N\}$. Mỗi phần tử $v_i \in V$ là một luồng dữ liệu đa phương tiện liên tục, bao gồm tín hiệu âm thanh và chuỗi hình ảnh theo thời gian.

Trọng tâm của giai đoạn tiền xử lý là chuyển đổi dữ liệu phi cấu trúc này thành dạng biểu diễn rời rạc, phục vụ cho các tác vụ truy xuất về sau. Cụ thể, mỗi video v_i được phân rã thành một tập các phân đoạn thông tin T_i , được biểu diễn dưới dạng:

$$v_i \rightarrow T_i = \{(s_{i1}, e_{i1}, x_{i1}), \dots, (s_{iM}, e_{iM}, x_{iM})\}$$

Trong đó, s_{ij} và e_{ij} lần lượt là thời điểm bắt đầu và kết thúc của phân đoạn thứ j , còn x_{ij} là nội dung văn bản tương ứng. Nội dung này được tổng hợp từ hai nguồn chính: văn bản bóc băng từ tín hiệu âm thanh (ASR) và nội dung trích xuất từ slide (OCR). Việc ánh xạ dữ liệu về dạng phân đoạn có cấu trúc không chỉ giúp giảm độ phức tạp trong lưu trữ và xử lý mà còn tạo điều kiện thuận lợi cho việc lập chỉ mục trong cơ sở dữ liệu vector.



Bên cạnh đó, hệ thống tiếp nhận truy vấn đầu vào dưới dạng một chuỗi ký tự q trong ngôn ngữ tự nhiên, phản ánh nhu cầu thông tin của người dùng.

1.2.2 Hàm mục tiêu và Ràng buộc hệ thống

Bài toán cốt lõi của hệ thống có thể được mô tả như việc xây dựng một hàm ánh xạ f , có khả năng kết hợp thông tin từ tập dữ liệu $T = \bigcup_{i=1}^N T_i$ và truy vấn q để sinh ra kết quả phù hợp:

$$f : (T, q) \rightarrow (\hat{a}, R)$$

Trong đó, đầu ra của hệ thống bao gồm hai thành phần. Thành phần thứ nhất $\hat{a}$ là câu trả lời dưới dạng ngôn ngữ tự nhiên, được tổng hợp dựa trên các phân đoạn thông tin liên quan trong dữ liệu bài giảng. Thành phần thứ hai R là tập các tham chiếu nguồn, được biểu diễn dưới dạng $R = \{(v_k, s_k, e_k)\}$, cho phép xác định chính xác vị trí của thông tin trong video thông qua định danh video và các mốc thời gian tương ứng.

Một yêu cầu quan trọng đặt ra đối với hệ thống là câu trả lời phải bám sát nội dung từ dữ liệu gốc, hạn chế tối đa việc sinh ra thông tin không có trong nguồn. Đồng thời, hệ thống cần đáp ứng các ràng buộc phi chức năng về hiệu năng, trong đó độ trễ phản hồi (latency) phải đủ thấp để đảm bảo trải nghiệm tương tác gần thời gian thực. Điều này đòi hỏi việc thiết kế hệ thống phải tận dụng các cơ chế xử lý bất đồng bộ và tối ưu hóa luồng I/O nhằm tránh các điểm nghẽn khi truy xuất dữ liệu.

1.3 Đóng góp cốt lõi của đề tài

Nghiên cứu này tập trung vào việc giải quyết bài toán hỏi-đáp trên dữ liệu video bài giảng đa phương thức, đồng thời mang lại một số đóng góp quan trọng ở cả khía cạnh hệ thống và phương pháp.

Trước hết, công trình đề xuất và hiện thực hóa một pipeline Multimodal RAG hoàn chỉnh, cho phép tích hợp và đồng bộ hóa dữ liệu từ nhiều nguồn khác nhau, bao gồm âm thanh lời giảng và nội dung hình ảnh từ slide. Thông qua việc kết hợp các kỹ thuật ASR và OCR, hệ thống chuyển đổi dữ liệu video sang dạng văn bản có cấu trúc theo thời gian, tạo nền tảng cho các tác vụ truy xuất ngữ nghĩa.

Bên cạnh đó, nghiên cứu giải quyết hiệu quả bài toán trộn lẫn ngôn ngữ Anh - Việt thường gặp trong các bài giảng kỹ thuật. Hệ thống áp dụng cơ chế truy xuất lai, kết hợp giữa phương pháp truy xuất ngữ nghĩa dựa trên embedding đa ngôn ngữ và phương pháp truy xuất từ vựng dựa trên BM25. Cách tiếp cận này giúp cải thiện khả năng đối sánh trong các truy vấn chứa thuật ngữ chuyên ngành, đồng thời duy trì độ chính xác trong các trường hợp yêu cầu đối sánh từ khóa.

Cuối cùng, nghiên cứu xây dựng một khung đánh giá định lượng nhằm đo lường chất lượng của hệ thống một cách nhất quán. Bộ dữ liệu kiểm thử gồm 90 truy vấn được thiết kế để bao phủ nhiều dạng câu hỏi khác nhau, cho phép đánh giá đồng thời cả khả năng truy xuất và khả năng tạo sinh của mô hình. Việc chuẩn hóa quy trình đánh giá này góp phần nâng cao tính minh bạch và tạo cơ sở cho việc so sánh với các phương pháp khác trong tương lai.

2 Bộ dữ liệu

2.1 Tổng quan không gian tri thức

Nền tảng dữ liệu của hệ thống được xây dựng từ một kho ngữ liệu (*corpus*) đa phương tiện, trích xuất trực tiếp từ các video bài giảng của môn học CS431. Về mặt mô hình hóa, toàn bộ dữ liệu được biểu diễn dưới dạng một tập hợp $V = \{v_1, v_2, \dots, v_{52}\}$, bao gồm 55 video trải dài xuyên suốt 10 chương học.

Mỗi video $v_i \in V$ bao gồm hai thành phần chính: tín hiệu âm thanh và chuỗi khung hình theo thời gian. Đặc thù của dữ liệu bài giảng là mật độ thông tin cao nhưng phân bố rời rạc theo thời gian, gây khó khăn cho việc truy xuất bằng các phương pháp tìm kiếm truyền thống dựa trên từ khóa.

Để phục vụ cho việc đánh giá hệ thống, một bộ dữ liệu kiểm thử độc lập được xây dựng, bao gồm 90 truy vấn phân bố đều từ chương 2 đến chương 10.

Mỗi điểm dữ liệu trong tập đánh giá được biểu diễn dưới dạng một bộ *tuple* $(q, \hat{a}, R)$, trong đó q là câu hỏi truy vấn, $\hat{a}$ là câu trả lời tham chiếu, và $R = \{(v_k, s_k, e_k)\}$ là tập các phân đoạn video liên quan kèm theo mốc thời gian. Cấu trúc này cho phép đo lường một cách nhất quán hiệu năng của hệ thống trong cả hai khía cạnh truy xuất và tạo sinh.

2.2 Quy trình xây dựng dữ liệu (Data Ingestion)

Do các mô hình ngôn ngữ lớn không thể trực tiếp xử lý dữ liệu video thô, hệ thống cần một quy trình tiền xử lý để chuyển đổi dữ liệu đa phương tiện sang dạng văn bản có cấu trúc. Quy trình này bao gồm các bước chính: trích xuất luồng dữ liệu, xử lý đa phương thức, chuẩn hóa văn bản, hợp nhất và phân đoạn theo thời gian, lập chỉ mục.

2.2.1 Trích xuất luồng dữ liệu (Data Extraction)

Mỗi video v_i được phân tách thành hai luồng tín hiệu độc lập: hình ảnh và âm thanh.

Đối với luồng hình ảnh, hệ thống áp dụng thuật toán lọc khung hình trùng lặp (*deduplication*) nhằm loại bỏ các frame có nội dung tương tự, chỉ giữ lại các *keyframes* đại diện cho những thay đổi quan trọng (ví dụ: chuyển slide). Tiêu chí lọc dựa trên khoảng cách cosine giữa các đặc trưng hình ảnh, với một ngưỡng ϵ xác định trước.

Đối với luồng âm thanh, dữ liệu được trích xuất bằng thư viện **ffmpeg**, sau đó chuyển đổi từ định dạng *stereo* sang *mono* và chuẩn hóa tần số lấy mẫu về 16 kHz để phù hợp với đầu vào của các mô hình nhận dạng giọng nói.

2.2.2 Xử lý đa phương thức (Multimodal Processing)

Sau khi tách hai luồng tín hiệu, hệ thống tiến hành xử lý độc lập từng luồng bằng các mô hình học sâu chuyên biệt.

Luồng âm thanh được chuyển thành văn bản thông qua mô hình ASR **openai/whisper-large-v3**. Mô hình sử dụng cơ chế *beam search* với kích thước chùm $b = 5$ nhằm cân bằng giữa độ chính xác và chi phí tính toán.

Song song đó, các *keyframes* được xử lý bằng mô hình thị giác - ngôn ngữ **Qwen2-VL-2B-Instruct** để thực hiện nhận dạng ký tự quang học (OCR). Quá trình này giúp trích xuất nội dung văn bản từ slide bài giảng.

Kết quả của bước này là hai nguồn văn bản: transcript từ lời giảng và nội dung từ slide.



2.2.3 Tiền xử lý và Chuẩn hóa văn bản (Text Preprocessing)

Văn bản thu được từ ASR và OCR thường chứa nhiều như lỗi ký tự, khoảng trắng không đồng nhất hoặc ký tự thừa. Để làm sạch dữ liệu, hệ thống áp dụng các kỹ thuật chuẩn hóa nhẹ dựa trên Biểu thức chính quy (*Regular Expression*).

Cụ thể, pipeline thực hiện loại bỏ ký tự nhiễu, chuẩn hóa khoảng trắng, đồng nhất bảng mã và đưa văn bản về định dạng chuẩn. Cách tiếp cận này giúp duy trì tốc độ xử lý cao trong khi vẫn bảo toàn các thuật ngữ chuyên ngành, đặc biệt là các cụm từ tiếng Anh xuất hiện trong ngữ cảnh tiếng Việt.

2.2.4 Hợp nhất và Phân đoạn theo thời gian (Merge & Chunking)

Sau khi chuẩn hóa, hai nguồn văn bản từ ASR và OCR được hợp nhất và căn chỉnh theo trục thời gian. Hệ thống sử dụng cơ chế *sliding window* kết hợp với các vector embedding ngữ nghĩa (ví dụ: multilingual embedding models) để đo lường sự thay đổi nội dung giữa các đoạn liên tiếp.

Khi độ tương đồng giữa hai cửa sổ giảm xuống dưới một ngưỡng xác định, hệ thống thực hiện chia đoạn (*chunking*) tại vị trí đó. Đồng thời, các mốc thời gian bắt đầu s_{ij} và kết thúc e_{ij} được nội suy để gán cho từng đoạn văn bản.

Kết quả là mỗi video v_i được chuyển đổi thành một tập hợp các đoạn thông tin có cấu trúc:

$$T_i = \{(s_{i1}, e_{i1}, x_{i1}), \dots, (s_{iM}, e_{iM}, x_{iM})\}$$

trong đó x_{ij} là nội dung văn bản tương ứng với đoạn thời gian $[s_{ij}, e_{ij}]$.

2.2.5 Lập chỉ mục và Lưu trữ (Indexing & Storage)

Các đoạn dữ liệu sau khi xử lý được lưu trữ dưới dạng JSON. Hệ thống sử dụng hai loại cơ sở dữ liệu để tối ưu hiệu năng:

- **PostgreSQL**: lưu trữ siêu dữ liệu (metadata) và quản lý quan hệ giữa các video và phân đoạn.
- **Vector Database (Chroma)**: lưu trữ embedding của các đoạn văn bản để phục vụ truy xuất ngữ nghĩa.

Cấu trúc lưu trữ này cho phép hệ thống thực hiện tìm kiếm láng giềng gần nhất (*Approximate Nearest Neighbor - ANN*) với độ trễ thấp, đóng vai trò nền tảng cho pipeline truy xuất trong giai đoạn suy luận.

3 Kiến trúc hệ thống

3.1 Tổng quan kiến trúc phần mềm

Kiến trúc phần mềm của hệ thống được thiết kế theo hướng microservices, tách biệt rõ ràng giữa tầng giao tiếp API, tầng lưu trữ dữ liệu và tầng suy luận trí tuệ nhân tạo. Cách tiếp cận này giúp hệ thống đảm bảo tính mô-đun, cho phép từng thành phần có thể được phát triển, thay thế hoặc mở rộng một cách độc lập mà không ảnh hưởng đến toàn bộ pipeline.


Luồng xử lý của hệ thống được điều phối thông qua framework **LangGraph**, cho phép mô hình hóa pipeline dưới dạng một đồ thị có hướng. Trong đó, mỗi nút (*node*) đại diện cho một tác vụ xử lý độc lập, bao gồm các bước như biến đổi truy vấn, truy xuất dữ liệu hoặc tổng hợp câu trả lời. Cách biểu diễn này giúp hệ thống linh hoạt trong việc điều hướng luồng thực thi (*control flow*), cho phép rẽ nhánh động dựa trên đặc trưng của truy vấn đầu vào.

Tầng API được xây dựng dựa trên **FastAPI** và vận hành trên nền **Uvicorn**. Việc sử dụng cơ chế bất đồng bộ (*asynchronous event loop*) giúp hệ thống xử lý hiệu quả các tác vụ I/O nặng, đặc biệt trong các tình huống cần truy xuất đồng thời nhiều đoạn dữ liệu từ cơ sở dữ liệu vector, từ đó giảm thiểu độ trễ tổng thể của hệ thống.

3.2 Luồng xử lý đa phương thức (Pipeline)

Hệ thống được xây dựng theo mô hình Retrieval-Augmented Generation (RAG), trong đó tri thức được truy xuất từ cơ sở dữ liệu trước khi được sử dụng để hỗ trợ mô hình ngôn ngữ trong quá trình sinh câu trả lời.

Toàn bộ pipeline được chia thành hai pha chính: pha xử lý ngoại tuyến (*offline data ingestion*) và pha suy luận trực tuyến (*online inference*). Hai pha này được liên kết chặt chẽ thông qua không gian lưu trữ embedding, đóng vai trò cầu nối giữa dữ liệu thô và quá trình truy xuất tri thức.



Hình 3.1: Sơ đồ luồng xử lý (Pipeline) của hệ thống RAG-based Lecture Video Q&A System

Trong pha ngoại tuyến, dữ liệu video thô được chuyển đổi sang dạng văn bản có cấu trúc thông



qua các bước tiền xử lý bao gồm tách luồng âm thanh và hình ảnh, nhận dạng giọng nói (ASR) và nhận dạng ký tự quang học (OCR). Kết quả của quá trình này là các đoạn văn bản được gắn mốc thời gian chính xác, sau đó được ánh xạ sang không gian vector thông qua các mô hình embedding và lưu trữ trong cơ sở dữ liệu vector.

Khi người dùng gửi truy vấn q , hệ thống chuyển sang pha suy luận trực tuyến. Tại đây, **LangGraph** kích hoạt một chuỗi các tác vụ xử lý nhằm truy xuất các đoạn dữ liệu liên quan nhất trong không gian embedding. Các kết quả truy xuất ban đầu tiếp tục được tinh lọc thông qua bước xếp hạng lại (*reranking*), trước khi được đưa vào mô hình ngôn ngữ lớn để tổng hợp thành câu trả lời cuối cùng.

3.3 Cơ chế kiểm duyệt và Biến đổi truy vấn

Quá trình xử lý truy vấn bắt đầu tại nút kiểm duyệt nội dung (*Guardrail*). Thành phần này có nhiệm vụ đánh giá mức độ liên quan giữa truy vấn đầu vào và miền tri thức của hệ thống, từ đó lọc bỏ các truy vấn không phù hợp hoặc ngoài phạm vi học thuật nhằm tiết kiệm tài nguyên tính toán.

Đối với các truy vấn hợp lệ, hệ thống áp dụng kỹ thuật HyDE (*Hypothetical Document Embeddings*) để biến đổi truy vấn. Cụ thể, một mô hình sinh được sử dụng để tạo ra một đoạn văn bản giả định dựa trên truy vấn ban đầu. Đoạn văn bản này thường có mật độ thông tin cao hơn và mang cấu trúc gần với tài liệu trong cơ sở dữ liệu, giúp cải thiện khả năng đối sánh ngữ nghĩa trong bước truy xuất.

Cách tiếp cận này đặc biệt hiệu quả trong các trường hợp truy vấn ngắn, mơ hồ hoặc thiếu ngữ cảnh, nơi mà biểu diễn ban đầu của truy vấn chưa đủ để truy xuất chính xác các tài liệu liên quan.

3.4 Hệ thống truy xuất lai (Hybrid Retrieval Engine)

Để đảm bảo hiệu năng truy xuất ổn định trong nhiều loại truy vấn khác nhau, hệ thống triển khai cơ chế truy xuất lai (*hybrid retrieval*), kết hợp giữa truy xuất ngữ nghĩa và truy xuất dựa trên từ khóa.

- **Truy xuất đặc tuyến (Dense Retrieval):** Sử dụng mô hình `multilingual-e5-large` để ánh xạ truy vấn và tài liệu vào không gian vector liên tục. Phương pháp này cho phép hệ thống nắm bắt các mối quan hệ ngữ nghĩa tiềm ẩn, đặc biệt hữu ích trong các truy vấn mang tính diễn giải hoặc không chứa từ khóa chính xác.
- **Truy xuất từ vựng (Sparse Retrieval):** Áp dụng thuật toán *BM25* để thực hiện đối sánh dựa trên tần suất và độ quan trọng của từ khóa. Cách tiếp cận này giúp đảm bảo các thuật ngữ chuyên ngành hoặc danh từ riêng được truy xuất chính xác.

Kết quả từ hai phương pháp được hợp nhất thông qua thuật toán *Reciprocal Rank Fusion (RRF)*. Thay vì phụ thuộc vào điểm số tuyệt đối, RRF kết hợp thứ hạng của các tài liệu trong từng danh sách, từ đó ưu tiên các tài liệu có thứ hạng cao ổn định trên cả hai phương pháp. Cách tiếp cận này giúp tăng độ robust của hệ thống và giảm phụ thuộc vào một cơ chế truy xuất đơn lẻ.

3.5 Kiến trúc xếp hạng lại và Tạo sinh ngôn ngữ

Sau bước truy xuất ban đầu, hệ thống áp dụng một mô hình xếp hạng lại dựa trên kiến trúc *Cross-Encoder*, cụ thể là `bge-reranker-v2-m3`. Khác với các mô hình embedding hai nhánh, cross-encoder xử lý trực tiếp cặp (truy vấn, tài liệu) thông qua cơ chế *cross-attention*, cho phép mô hình học được các mối quan hệ ngữ nghĩa chi tiết hơn. Nhờ đó, thứ hạng của các tài liệu được tinh chỉnh với độ chính xác cao hơn.



Ở giai đoạn cuối, các đoạn văn bản có điểm số cao nhất được tổng hợp và đưa vào một prompt có cấu trúc, sau đó nạp vào mô hình ngôn ngữ **gemini-2.5-flash-lite**. Mô hình thực hiện suy luận dựa trên ngữ cảnh được cung cấp để sinh ra câu trả lời tự nhiên.

Thông qua kỹ thuật thiết kế prompt, hệ thống yêu cầu mô hình gắn kết nội dung trả lời với các tham chiếu thời gian cụ thể. Kết quả đầu ra không chỉ bao gồm phần giải thích mà còn kèm theo các liên kết trở trực tiếp đến vị trí tương ứng trong video. Điều này giúp người dùng dễ dàng kiểm chứng thông tin và truy cập lại nguồn tri thức gốc, hoàn thiện vòng lặp truy xuất và diễn giải tri thức.

4 Phương pháp

4.1 Tổng quan khung thuật toán

Kiến trúc cốt lõi của hệ thống được mô hình hóa vượt ra khỏi các luồng xử lý tuần tự truyền thống để chuyển sang dạng một đồ thị trạng thái có hướng (*directed state graph*) thông qua bộ khung phần mềm **LangGraph**. Thay vì thực thi một chuỗi lệnh tuyến tính, toàn bộ pipeline được chia thành các nút (*nodes*) tính toán độc lập, trong đó mỗi nút đảm nhiệm một chức năng chuyên biệt như kiểm duyệt truy vấn, biến đổi ngữ nghĩa, truy xuất thông tin hay sinh câu trả lời. Trạng thái trung gian của hệ thống được truyền tải và biến đổi liên tục dọc theo các cạnh (*edges*), tạo thành một cơ chế điều phối linh hoạt và có khả năng thích nghi theo nội dung đầu vào.

Thiết kế này không chỉ tối ưu hóa khả năng khai thác mô hình bất đồng bộ của **FastAPI**, giảm thiểu độ trễ gây ra bởi các thao tác I/O, mà còn cho phép cài đặt các cơ chế rẽ nhánh logic dựa trên kết quả của từng bước xử lý. Nhờ đó, hệ thống có thể lựa chọn động các chiến lược truy xuất và suy luận phù hợp với từng loại truy vấn, thay vì áp dụng một pipeline cố định.

Xét trên toàn cục, luồng xử lý của hệ thống có thể được tóm lược thành một chuỗi biến đổi tuần tự:

$q \rightarrow \text{Guardrail} \rightarrow \text{Query Transformation} \rightarrow \text{Hybrid Retrieval} \rightarrow \text{Fusion} \rightarrow \text{Reranking} \rightarrow \text{Generation}$

Trong đó mỗi phép biến đổi đóng vai trò thu hẹp không gian tìm kiếm và gia tăng mật độ thông tin hữu ích, hướng tới mục tiêu cực đại hóa xác suất sinh ra một câu trả lời chính xác và có khả năng truy vết nguồn gốc.

4.2 Định tuyến và Biến đổi Truy vấn (Routing & Query Transformation)

Sự tương tác của người dùng với hệ thống bắt đầu tại biên của đồ thị thông qua cơ chế kiểm duyệt nội dung *Guardrail*. Về mặt hình thức, cơ chế này hoạt động như một hàm phân loại nhị phân đánh giá khoảng cách ngữ nghĩa giữa truy vấn đầu vào q và không gian tri thức của môn học. Các chuỗi ký tự vi phạm hoặc nằm ngoài phân phối dữ liệu bài giảng sẽ bị hệ thống từ chối ngay lập tức, qua đó ngăn chặn sự lãng phí tài nguyên tính toán ở các cụm nhân GPU phía sau và bảo vệ tính an toàn của hệ thống.

Đối với các truy vấn hợp lệ, sự thưa thớt về mặt từ vựng thường dẫn đến hiện tượng chênh lệch không gian biểu diễn giữa ngôn ngữ nói của sinh viên và ngôn ngữ hàn lâm của giảng viên. Hệ thống giải quyết sự suy biến này bằng kỹ thuật sinh tài liệu giả định *Hypothetical Document Embeddings* (HyDE). Thay vì trực tiếp nhúng một câu hỏi ngắn gọn, hệ thống kích hoạt một mô hình ngôn ngữ để sinh ra một đoạn văn bản phản hồi dự đoán $\hat{d}$ dựa trên phân phối tri thức toàn cục của mô hình. Văn bản sinh ra này chứa một mật độ từ vựng chuyên ngành cao, giúp lấp đầy khoảng trống ngữ nghĩa và dịch chuyển vector truy vấn về gần hơn với các cụm vector mục tiêu trong cơ sở dữ liệu, từ đó cải thiện đáng kể khả năng tìm kiếm chính xác các phân đoạn video liên quan.

4.3 Công cụ truy xuất lai (Hybrid Retrieval)

Do tính chất đặc thù của các thuật ngữ khoa học máy tính và các công thức toán học trong bài giảng, việc chỉ sử dụng một phương pháp đo lường khoảng cách vector duy nhất thường dẫn đến hiện tượng



bỏ sót thông tin cục bộ. Để tối ưu hóa độ bao phủ không gian, hệ thống triển khai một khung truy xuất lai (*Hybrid Retrieval*) thực thi song song hai phép chiếu không gian độc lập.

4.3.1 Phép truy xuất từ vịnh (Sparse Retrieval)

Luồng truy xuất thứ nhất giải quyết bài toán đối sánh chính xác các thuật ngữ kỹ thuật, tên thuật toán hoặc các từ khóa đặc thù thông qua khung xác suất *BM25*. Khác với các phương pháp nhúng mạng nơ-ron, *BM25* tính toán sự phân bố tần suất từ khóa trong một không gian rời rạc. Điểm số tương đồng giữa truy vấn Q và tài liệu D được định lượng bằng hàm bão hòa phi tuyến tính:

$$\text{Score}_{\text{BM25}}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

Khung tính toán này đảm bảo rằng các thuật ngữ hiếm mang hàm lượng thông tin cao sẽ được khuếch đại trọng số, đồng thời hình phạt chiều dài văn bản thông qua tham số b giúp ngăn chặn sự thiên lệch đối với các phân đoạn bài giảng có thời lượng quá dài nhưng không tập trung vào chủ đề truy vấn.

4.3.2 Phép truy xuất đặc tuyến (Dense Retrieval)

Luồng truy xuất thứ hai nắm bắt cấu trúc ngữ pháp và ý nghĩa tiềm ẩn thông qua các mô hình nhúng sâu như *Multilingual-E5* hoặc *BGE-M3*. Các mô hình này chiếu cả truy vấn và văn bản thành các ma trận vector liên tục trong không gian $\mathbb{R}^d$. Độ tương đồng ngữ nghĩa giữa truy vấn q và tài liệu d được định lượng bằng hàm Cosine của góc tạo bởi hai vector:

$$\text{sim}(q, d) = \frac{v_q \cdot v_d}{\|v_q\| \|v_d\|}$$

Không gian liên tục này xuất sắc trong việc nắm bắt cấu trúc ngữ pháp ẩn, cho phép hệ thống nhận diện thành công các cấu trúc đồng nghĩa hoặc cách diễn đạt thay thế mà không phụ thuộc vào sự trùng khớp ký tự bề mặt. Toàn bộ các vector nhúng này được lưu trữ và lập chỉ mục trong hệ quản trị cơ sở dữ liệu **Chroma**, cho phép thực hiện tìm kiếm láng giềng gần nhất với độ trễ cực thấp.

4.3.3 Thuật toán hợp nhất (Reciprocal Rank Fusion)

Sự dị biệt về bản chất phân phối điểm số giữa không gian rời rạc của *BM25* và không gian liên tục của phép nhúng cosine khiến các phép cộng tuyến tính thông thường mất đi ý nghĩa toán học. Hệ thống giải quyết sự không đồng nhất này thông qua thuật toán *Reciprocal Rank Fusion* (RRF). Phương pháp này bỏ qua các giá trị điểm số thô để tập trung vào hàm nghịch đảo của thứ hạng xếp hạng $r(d)$, được định nghĩa như sau:

$$\text{RRF}(d) = \sum_{m \in \{\text{Dense}, \text{Sparse}\}} \frac{1}{k + r_m(d)}$$

Hằng số làm mịn $k = 60$ đóng vai trò kiểm soát tốc độ hội tụ của hàm phân thức, đảm bảo hệ thống ưu tiên một cách tuyệt đối những phân đoạn văn bản duy trì sự hiện diện ổn định ở các vị trí top đầu trên cả hai hệ quy chiếu tìm kiếm độc lập.



4.4 Xếp hạng lại bằng mã hóa chéo (Cross-Encoder Reranking)

Tập hợp ứng viên thu được từ quá trình hợp nhất RRF vẫn có thể chứa nhiều do giới hạn của kiến trúc bộ mã hóa kép (*Bi-encoder*). Trong kiến trúc truy xuất song song, sự tương tác giữa truy vấn và tài liệu chỉ xảy ra ở lớp tính toán cuối cùng, dẫn đến sự thiếu hụt khả năng mô hình hóa các mối quan hệ ngữ nghĩa sâu sắc.

Để thanh lọc tập thông tin trước khi nạp vào bộ nhớ động của mô hình ngôn ngữ, toàn bộ không gian ứng viên được đẩy qua một bộ Cross-Encoder, cụ thể là mô hình **BAAI/bge-reranker-v2-m3**. Khác biệt hoàn toàn với phép so sánh vector tĩnh, Cross-Encoder ghép nối trực tiếp chuỗi truy vấn và từng đoạn tài liệu thành một ma trận đầu vào thống nhất. Kiến trúc này kích hoạt cơ chế tự chú ý (*self-attention*) lan truyền qua toàn bộ các lớp của mạng nơ-ron học sâu, cho phép sự tương tác tín hiệu giữa từng cặp từ vựng xảy ra ngay từ những khâu tính toán đầu tiên. Mặc dù cấu trúc này gây ra áp lực tính toán với độ phức tạp $\mathcal{O}(N^2)$ lên hệ thống, nó cung cấp một hàm điểm số mang độ chuẩn xác cao, bóc tách thành công các mối quan hệ logic tinh vi để giữ lại những phân đoạn cốt lõi nhất.

4.5 Tạo sinh ngôn ngữ tăng cường truy xuất

Pha xử lý cuối cùng của đồ thị thuật toán là quá trình tổng hợp kết quả thông qua mô hình ngôn ngữ lớn **gemini-2.5-flash-lite**. Tập hợp các phân đoạn được truy xuất sau khâu Rerank được đóng gói vào một lời nhắc (*prompt*) có cấu trúc chặt chẽ. Lời nhắc này bao gồm các chỉ dẫn hệ thống yêu cầu mô hình phải tuyệt đối tuân thủ ngữ cảnh được cung cấp để tránh hiện tượng ảo giác thông tin.

Mô hình thực hiện dựa vào ngữ cảnh được cung cấp để kết xuất một chuỗi ngôn ngữ tự nhiên tối ưu. Đặc biệt, bằng kỹ thuật kỹ nghệ lời nhắc (*Prompt Engineering*), mô hình bị ép buộc phải gắn kết câu trả lời với các tham chiếu thời gian (s_{ij}, e_{ij}) và định danh video nguồn. Kết quả trả về cho giao diện người dùng không chỉ là một lời giải thích mạch lạc mà còn kèm theo các siêu liên kết (*hyperlinks*) trỏ trực tiếp đến tọa độ thời gian gốc của luồng video, tạo nên một chu trình phản hồi hoàn chỉnh cho bài toán tìm kiếm thông tin trong bài giảng.

5 Thực nghiệm

5.1 Phương pháp đánh giá và Các chỉ số đo lường

Để đánh giá hiệu năng của một hệ thống hỏi đáp tăng cường truy xuất, ta cần xem xét song song hai khía cạnh riêng biệt: mức độ chính xác khi tìm kiếm trong không gian vector, và chất lượng của phần tổng hợp câu trả lời bằng ngôn ngữ tự nhiên.

Trong giai đoạn truy xuất, việc đánh giá tập trung vào tập hợp các đoạn tài liệu được trả về. Hai chỉ số cơ bản thường dùng là Precision@K và Recall@K, đo lường mức độ trùng khớp giữa tập tài liệu truy xuất được R và tập nhãn chuẩn G trong K kết quả gần nhất — một chỉ số phản ánh độ chính xác, chỉ số kia phản ánh độ bao phủ:

$$P@K = \frac{|R \cap G|}{K}; \quad R@K = \frac{|R \cap G|}{|G|}$$

Nhằm lượng hóa chất lượng định hạng trên toàn bộ phổ truy vấn, hệ thống áp dụng chỉ số độ chính xác trung bình (*Mean Average Precision - MAP*). Đây là hàm mục tiêu đo lường diện tích dưới đường cong Precision-Recall, được tính toán thông qua việc lấy trung bình các giá trị Precision tại vị trí của từng tài liệu liên quan k trong tập m_q tài liệu chuẩn:

$$MAP = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \left(\frac{1}{m_q} \sum_{k=1}^n P@k \times rel(k) \right)$$

Trong đó $rel(k)$ là hàm chỉ thị nhận giá trị 1 nếu tài liệu tại vị trí k có liên quan, và 0 nếu ngược lại. Bên cạnh đó, hệ thống còn sử dụng chỉ số MRR (*Mean Reciprocal Rank - MRR*) để đo vị trí xuất hiện của tài liệu đúng đầu tiên, bằng cách lấy nghịch đảo thứ hạng trung bình trên tập truy vấn Q :

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{rank_i}$$

Độ chính xác của thuật toán còn được kiểm tra thêm qua chỉ số nDCG (*Normalized Discounted Cumulative Gain - nDCG*). Chỉ số này phạt nặng những tài liệu không liên quan nhưng lại được xếp hạng cao, từ đó đảm bảo dữ liệu đầu vào cho bộ mã hóa chéo có chất lượng tốt nhất có thể:

$$DCG_K = \sum_{i=1}^K \frac{rel_i}{\log_2(i+1)} \Rightarrow nDCG_K = \frac{DCG_K}{IDCG_K}$$

Ở phần sinh ngôn ngữ, hệ thống sử dụng bộ khung RAGAS với cơ chế tự động chấm điểm bằng LLM (LLM-as-a-Judge). Độ trung thực (*Faithfulness*) được đo bằng tỷ lệ giữa số mệnh đề rút ra từ câu trả lời S so với tập bằng chứng trích xuất từ ngữ cảnh V , giúp kiểm soát hiện tượng ảo giác của mô hình:

$$Faithfulness = \frac{|S \cap V|}{|S|}$$

Cuối cùng, độ liên quan của câu trả lời (*Answer Relevancy*) đánh giá mức độ tương đồng ngữ nghĩa bằng cách tính trung bình độ tương đồng *cosine* giữa vector nhúng của câu hỏi gốc $\mathbf{v}_q$ và ma trận các



vector $\mathbf{v}_{q_i}$ của n câu hỏi được sinh ngược lại từ câu trả lời:

$$\text{Answer Relevancy} = \frac{1}{n} \sum_{i=1}^n \frac{\mathbf{v}_q \cdot \mathbf{v}_{q_i}}{\|\mathbf{v}_q\| \|\mathbf{v}_{q_i}\|}$$

Sự kết hợp của hệ chỉ số này tạo thành khung đánh giá toàn diện, đảm bảo hệ thống phản hồi đúng trọng tâm tri thức học thuật của môn học CS431.

5.2 Thiết lập thực nghiệm

Thực nghiệm được tiến hành trên bộ dữ liệu đánh giá gồm 90 truy vấn độc lập, phân bố đều trên 10 chương của khóa học CS431. Mỗi mẫu dữ liệu là một tuple được xây dựng thủ công, bao gồm câu hỏi của sinh viên, đáp án tham chiếu và thông tin thời gian chính xác trở trực tiếp đến đoạn video tương ứng.

Để đánh giá mức độ ảnh hưởng của mô hình nhúng đến chất lượng truy xuất, thực nghiệm lần lượt thay thế mô-đun dense embedding bằng bốn mô hình khác nhau: `intfloat/multilingual-e5-large`, `BAAI/bge-m3`, `AITeamVN/Vietnamese_Embedding` và API thương mại `gemini-embedding-2-preview`. Vector sinh ra từ mỗi mô hình được kết hợp với thuật toán tìm kiếm từ vựng BM25 thông qua cơ chế hợp nhất thứ hạng tương hỗ (RRF), sau đó được xếp hạng lại bởi mô hình cross-attention `BAAI/bge-reranker-v2-m3`.

Ở bước tổng hợp câu trả lời, mô hình `gemini-2.5-flash-lite` được giữ cố định hoàn toàn trong suốt quá trình thực nghiệm, nhằm cách ly ảnh hưởng của mô-đun truy xuất, tránh bị phân sinh ngôn ngữ làm nhiễu kết quả.

5.3 Kết quả và Thảo luận

Bảng kết quả đo lường trên 90 mẫu thử nghiệm cho thấy sự khác biệt rõ rệt giữa các mô hình nhúng. Khả năng xử lý đa ngôn ngữ và mức độ bảo toàn ngữ nghĩa của từng mô hình ảnh hưởng trực tiếp đến chất lượng của cả hai giai đoạn truy xuất và sinh câu trả lời.

Bảng 5.1: Đánh giá hiệu năng truy xuất và tạo sinh trên các hệ tọa độ nhúng khác nhau

Mô hình nhúng	Faithfulness	Ans. Relevancy	P@10	R@10	MAP	MRR	nDCG
<code>multilingual-e5-large</code>	0.9596	0.8882	0.1655	0.6067	0.4640	0.5920	0.6258
<code>gemini-embedding-2</code>	0.9496	0.8832	0.1888	0.6885	0.4864	0.5722	0.6116
<code>bge-m3</code>	0.9583	0.8371	0.1544	0.5854	0.4427	0.5691	0.6006
<code>Vietnamese_Embedding</code>	0.9625	0.7644	0.1544	0.5740	0.4288	0.5377	0.5703

Phân tích kết quả truy xuất cho thấy mô hình `gemini-embedding-2-preview` đạt độ bao phủ tốt nhất, với `Recall@10` đạt 0.6885 và `MAP` đạt 0.4864. Điều này đảm bảo mô hình sinh ngôn ngữ có đủ ngữ cảnh khi xử lý các câu hỏi phức tạp. Tuy nhiên, khi xét về chất lượng xếp hạng, `multilingual-e5-large` lại chiếm ưu thế rõ rệt với `MRR` đạt 0.5920 và `nDCG` đạt 0.6258. Khả năng đẩy các đoạn văn bản quan trọng lên thứ hạng cao giúp lọc bớt nhiễu trước khi đưa vào mô hình sinh, từ đó đạt chỉ số `Answer Relevancy` cao nhất ở mức 0.8882.

Đáng chú ý là kết quả của mô hình `AITeamVN/Vietnamese_Embedding` lại cho thấy một điểm bất ngờ. Mô hình này đạt `Faithfulness` cao nhất tập thử nghiệm với 0.9625, phản ánh hiệu quả của chiến lược prompt engineering kết hợp với `gemini-2.5-flash-lite`, nơi mô hình được hướng dẫn ưu tiên trả lời thận trọng thay vì bịa đặt thông tin ngoài ngữ cảnh. Tuy nhiên, nghịch lý nằm ở chỗ đây cũng là mô hình có năng lực truy xuất yếu nhất, với `Recall@10` và `nDCG` đều ở mức thấp nhất. Nguyên



nhân cốt lõi là mô hình thuần tiếng Việt gặp khó khăn với các thuật ngữ tiếng Anh phổ biến trong Khoa học Máy tính như *Vanishing Gradient* hay *Feedforward*. Khi không định vị được các từ khóa chuyên ngành này, ngữ cảnh truy xuất trở nên thiếu hụt, buộc mô hình ngôn ngữ phải suy luận từ thông tin không đầy đủ, kéo Answer Relevancy xuống chỉ còn 0.7644.

6 Kết luận

6.1 Tổng kết quá trình nghiên cứu và kết quả đạt được

Đồ án đã giải quyết bài toán chuyển đổi tri thức từ các tệp đa phương tiện thành không gian vector phục vụ tìm kiếm ngữ nghĩa. Thông qua bộ khung **LangGraph**, hệ thống tự động hóa toàn bộ quy trình xử lý, từ việc trích xuất văn bản qua OCR và ASR kèm thông tin thời gian, cho đến bước suy luận và sinh câu trả lời. Sự kết hợp giữa tìm kiếm từ vựng BM25 và tìm kiếm theo vector đặc trưng giúp khắc phục điểm yếu của từng phương pháp đơn lẻ, cho phép hệ thống xử lý tốt hơn các trường hợp mà một mình BM25 hay vector search riêng rẽ thường bỏ sót.

Ở tầng tinh lọc, việc kết hợp Reciprocal Rank Fusion và mạng Cross-Encoder giúp chọn lọc ra tập ngữ cảnh chất lượng cao trước khi đưa vào mô hình **gemini-2.5-flash-lite**. Nhờ đó, mô hình có thể sinh câu trả lời sát với nội dung gốc và trả về đúng mốc thời gian trong video. Kết quả thực nghiệm cho thấy mô hình nhúng **multilingual-e5-large** cho hiệu quả tốt nhất trên các chỉ số MRR và nDCG, xác nhận tính hợp lý của kiến trúc lai được đề xuất.

6.2 Hạn chế của hệ thống

Một hạn chế đáng chú ý là chi phí tính toán của mô hình Cross-Encoder ở tầng tinh lọc. Do mô hình cần so sánh trực tiếp truy vấn với từng tài liệu một, độ phức tạp thời gian đạt $\mathcal{O}(N^2)$, dẫn đến tình trạng nghẽn cổ chai khi số lượng truy vấn đồng thời tăng cao.

Bên cạnh đó, chất lượng của các mô hình nhúng tiếng Việt hiện tại vẫn còn khoảng cách so với các mô hình đa ngôn ngữ, đặc biệt trong lĩnh vực Khoa học Máy tính vốn chứa nhiều thuật ngữ tiếng Anh. Kết quả của **Vietnamese_Embedding** trong thực nghiệm là minh chứng rõ ràng: mô hình đạt độ trung thực cao nhưng khả năng truy xuất lại hạn chế do không gian vector chưa biểu diễn tốt các thuật ngữ chuyên ngành vay mượn từ tiếng Anh.

Tài liệu tham khảo

- [1] Jean-Baptiste Alayrac **and others**. “Flamingo: a Visual Language Model for Few-Shot Learning”. *in arXiv preprint arXiv:2204.14198*: (2022). Accessed: 2026-04-22. URL: <https://arxiv.org/abs/2204.14198>.
- [2] Loubna Ben Allal **and others**. “Precise Zero-Shot Dense Retrieval without Relevance Labels”. *in arXiv preprint arXiv:2305.11746*: (2023). Accessed: 2026-04-22. URL: <https://aclanthology.org/2023.acl-long.99/>.
- [3] Gordon V. Cormack, Charles L. A. Clarke **and** Stefan Buettcher. “Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods”. *in Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*: Accessed: 2026-04-22. 2009. URL: <https://cormack.uwaterloo.ca/cormacksigir09-rrf>.
- [4] Yunfan Gao **and others**. “Retrieval-Augmented Generation for Large Language Models: A Survey”. *in arXiv preprint arXiv:2312.10997*: (2023). Accessed: 2026-04-22. URL: <https://arxiv.org/abs/2312.10997>.
- [5] Vladimir Karpukhin **and others**. “Dense Passage Retrieval for Open-Domain Question Answering”. *in arXiv preprint arXiv:2004.04906*: (2020). Accessed: 2026-04-22. URL: <https://arxiv.org/abs/2004.04906>.
- [6] Omar Khattab **and** Matei Zaharia. “Cross-Encoders for Passage Re-ranking”. *in arXiv preprint arXiv:2004.12832*: (2020). Accessed: 2026-04-22. URL: <https://arxiv.org/abs/2004.12832>.
- [7] Patrick Lewis **and others**. “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”. *in arXiv preprint arXiv:2005.11401*: (2020). Accessed: 2026-04-22. URL: <https://arxiv.org/abs/2005.11401>.
- [8] Alec Radford **and others**. “Robust Speech Recognition via Large-Scale Weak Supervision”. *in arXiv preprint arXiv:2212.04356*: (2022). Accessed: 2026-04-22. URL: <https://proceedings.mlr.press/v202/radford23a.html>.
- [9] Stephen E. Robertson **and others**. *Okapi BM25: A Non-Binary Model for Information Retrieval*. <https://nlp.stanford.edu/IR-book/html/htmledition/okapi-bm25-a-non-binary-model-1.html>. Accessed: 2026-04-22. 1994.