

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH TRƯỜNG ĐẠI HỌC CÔNG
NGHỆ THÔNG TIN ĐHQG-HCM**

KHOA KHOA HỌC MÁY TÍNH



BÁO CÁO ĐỒ ÁN

MÔN HỌC CS221 - XỬ LÝ NGÔN NGỮ TỰ NHIÊN

**Đề tài: SENTIMENT AND TOPIC ANALYSIS OF VIETNAMESE
UNIVERSITY STUDENTS' COURSE EVALUATIONS**

Giảng viên hướng dẫn: TS. Nguyễn Trọng Chính

Sinh viên thực hiện 1: Nguyễn Việt Thắng

Mã số sinh viên: 22521339

Sinh viên thực hiện 2: Nguyễn Bá Long

Mã số sinh viên: 23520880

Sinh viên thực hiện 3: Tô Đặng Minh Tuấn

Mã số sinh viên: 24521942

This image shows a full page of white paper with horizontal dotted lines. The lines are evenly spaced and run across the width of the page, providing a guide for handwriting practice. There are no margins, text, or other markings on the page.

LỜI CẢM ƠN

Để hoàn thành đồ án môn học với đề tài "*SENTIMENT AND TOPIC ANALYSIS OF VIETNAMESE UNIVERSITY STUDENTS' COURSE EVALUATIONS*", chúng em đã nhận được rất nhiều sự quan tâm, động viên và giúp đỡ từ Quý Thầy/Cô và bạn bè.

Đặc biệt, chúng em xin bày tỏ lòng biết ơn sâu sắc đến **TS. Nguyễn Trọng Chính** – giảng viên hướng dẫn, người đã tận tình định hướng và hỗ trợ nhóm trong suốt quá trình thực hiện. Những góp ý chuyên môn của Thầy, từ việc củng cố lý thuyết Xử lý ngôn ngữ tự nhiên, lựa chọn mô hình phù hợp (PhoBERT/mBERT) đến cách giải quyết các bài toán kỹ thuật như mất cân bằng dữ liệu và tối ưu hóa đa nhiệm, chính là kim chỉ nam giúp nhóm hoàn thành nghiên cứu này.

Dù đã nỗ lực hết mình để hoàn thiện đề tài, nhưng do thời gian và kiến thức còn hạn chế, nhóm khó tránh khỏi những thiếu sót nhất định. Chúng em rất mong nhận được sự góp ý quý báu từ quý Thầy/Cô để có thể cải thiện và phát triển hơn trong các nghiên cứu tiếp theo.

Xin chân thành cảm ơn!

Nhóm acm

MỤC LỤC

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN.....	2
LỜI CẢM ƠN	3
MỤC LỤC	4
DANH MỤC BẢNG	9
DANH MỤC HÌNH ẢNH	10
BẢNG ĐÁNH GIÁ ĐÓNG GÓP.....	11
CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI.....	1
1.1 Giới thiệu chung về đề tài.....	1
1.2 Mục tiêu nghiên cứu	1
1.3 Phạm vi nghiên cứu và giả định	2
1.3.1 Phạm vi nghiên cứu.....	2
1.3.2 Giả định nghiên cứu.	2
1.4 Đóng góp của đề tài	2
1.4.1 Về mặt học thuật:	2
1.4.2 Về mặt thực tiễn:	3
CHƯƠNG 2. NGUỒN DỮ LIỆU ĐÁNH GIÁ MÔN HỌC.....	4
2.1 Thu thập dữ liệu.....	4
2.1.1 Nguồn dữ liệu đánh giá môn học	4
2.1.2 Tiêu chí lựa chọn và sàng lọc dữ liệu.....	5
2.2 Định nghĩa nhãn dữ liệu	7
2.2.1 Nhãn cảm xúc (Sentiment Labels)	7
2.2.2 Nhãn chủ đề (Topic Labels)	8
2.2.3 Quy tắc gán nhãn và xử lý trường hợp phức tạp	10

2.3 Phân tích thống kê dữ liệu	12
2.3.1 Quy mô và phân bố nhãn (cảm xúc, chủ đề)	12
2.3.2 Độ dài văn bản và đặc điểm ngôn ngữ	13
2.3.3 Ma trận tương quan giữa các lớp	16
2.3.4 Tần suất xuất hiện của các từ	17
2.4 Ví dụ về dữ liệu	18
2.5 Đánh giá chất lượng dữ liệu	19
2.5.1 Phân tích nhiễu, tính thiên lệch và độ đa dạng	19
2.5.2 Phân tích độ nhập nhằng và nhất quán của nhãn (Label Consistency)	20
2.6 TỰ TẠO VÀ TĂNG CƯỜNG DỮ LIỆU (DATA AUGMENTATION)	23
2.7 Chia tập dữ liệu và thiết lập thí nghiệm	23
2.7.1 Chia tập Train, Validation và Test	23
2.7.2 Quy trình huấn luyện (Training Setup)	23
CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU	25
3.1 Tổng quan phương pháp nghiên cứu	25
3.2 Bài toán và mô hình	27
3.2.1 Bài toán phân loại cảm xúc (Single-label Classification)	27
3.2.2 Bài toán phân loại chủ đề (Multi-label Classification)	28
3.3 Các chỉ số đánh giá mô hình	28
3.3.1 Các chỉ số Accuracy, Precision, Recall, F1 score	28
3.3.2 Ma trận nhầm lẫn (Confusion Matrix)	30
3.3.3 Các chỉ số đánh giá cho bài toán đa nhãn	30
3.3.4 Đường cong ROC và chỉ số AUC (tùy chọn)	30
3.4 Các kỹ thuật tiền xử lý dữ liệu	31
3.5 Các mô hình Transformer và BERT cho tiếng Việt	32

3.5.1 Kiến trúc tổng quan của Transformer.....	32
3.5.2 Các mô hình BERT và Cơ sở lựa chọn	34
3.5.3 Biểu diễn vector và chiến lược Pooling.....	35
3.6 Các mô hình Baseline	35
CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT QUẢ.....	37
4.1 Thiết lập môi trường thực nghiệm.....	37
4.2 Cài đặt các phương pháp tiền xử lý dữ liệu.....	38
4.2.1 Tải và làm sạch dữ liệu.....	39
4.2.2 Phương pháp tiền xử lý văn bản (Preprocessing Pipeline).....	39
4.3 Cài đặt mô hình Baseline (Cơ sở).....	41
4.3.1 Cài đặt TF-IDF và tham số huấn luyện	42
4.3.2 Cài đặt mô hình phân loại (Classifier).....	42
4.4. Cài đặt mô hình BERT/PhoBERT (Multi-task Learning).....	43
4.4.1 Cài đặt Tokenizer	43
4.4.2 Kiến trúc mạng Multi-task và Hàm lỗi.....	43
4.4.3 Lựa chọn siêu tham số (Hyperparameters).....	45
4.4.4 Hậu xử lý kết quả và Hiệu chỉnh ngưỡng (Threshold Tuning)	45
4.4.5 Minh họa luồng xử lý (One-sample Walkthrough)	46
4.5 THỰC NGHIỆM FINE-TUNING	49
4.5.1 Chuẩn bị dữ liệu và kiểm định chất lượng đầu vào.....	49
4.5.2 Fine-tuning PhoBERT cho phân loại cảm xúc (Sentiment Head)	50
4.5.3 Fine-tuning đa nhãn chủ đề (Topic Head).....	50
4.5.4 Chiến lược Huấn luyện và Tối ưu hóa (Full Fine-tuning).....	51
4.5.5 So sánh chi phí và hiệu năng (Phân tích Nhật ký huấn luyện).....	52
4.5.6 Hạn chế và Hướng phát triển.....	53

4.7 Phân tích kết quả thực nghiệm	54
4.7.1 Kết quả của các mô hình Baseline.....	54
4.7.2 Kết quả từ mô hình BERT/PhoBERT Fine-tuning	55
4.7.3 So sánh hiệu năng và phân tích định lượng.....	58
4.8 Phân tích lỗi và Đánh giá chuyên sâu (Error Analysis)	59
4.8.1 Định nghĩa các nhóm lỗi ngôn ngữ đặc trưng (Error Taxonomy).....	59
4.8.2 Phân tích ảnh hưởng của tiền xử lý (Tách từ vs Không tách từ).....	60
4.8.3 Phân tích chuyên sâu theo nhóm chủ đề qua Confusion Matrix	60
4.8.4. Phân tích định tính và Truy vết hành vi mô hình (Qualitative Analysis & Model Behavior Tracing)	66
4.8.5. Tổng kết quy luật sai số và Kiến nghị (Synthesis & Recommendations)	74
CHƯƠNG 5. ĐẠO ĐỨC, QUYỀN RIÊNG TƯ VÀ RỦI RO	75
5.1 Ẩn danh hóa dữ liệu và bảo vệ thông tin cá nhân	75
5.2 Phân tích tính thiên lệch và công bằng.....	76
5.3 Công bố kết quả và tuân thủ quy định.....	78
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN.....	80
6.1 Kết luận.....	80
6.2 Đóng góp của đề tài	80
6.3 Hạn chế và Hướng phát triển.....	80
PHỤ LỤC. DANH SÁCH VÀ PHÂN TÍCH CHI TIẾT NGỮ LIỆU TIÊU BIỂU	82
I. Nhóm 1: Phân tích về Chương trình đào tạo & Nội dung (Training Program)	83
II. Nhóm 2: Phân tích về Cơ sở vật chất & Môi trường (Facility)	87
III. Nhóm 3: Nhóm các phản hồi Khác & Trung tính (Others / Neutral).....	90
IV. Nhóm 4: Các phản hồi về Giảng viên (Complex Lecturer)	93
CHƯƠNG 7. TÀI LIỆU THAM KHẢO	102

DANH MỤC BẢNG

Bảng 2.1.2.4. Bảng phân phối nhãn cảm xúc.	6
Bảng 2.1.2.5. Bảng phân phối nhãn chủ đề.	7
Bảng 2.2.1. Bảng định nghĩa và tiêu chí nhận diện nhãn cảm xúc.....	7
Bảng 2.2.2. Bảng định nghĩa và tiêu chí nhận diện nhãn cảm xúc.....	9
Bảng 2.3.1.1 mô tả sự phân bố của các nhãn cảm xúc.	13
Bảng 2.3.1.2 mô tả sự phân bố của các nhãn chủ đề.	13
Bảng 2.3.2.1 Thống kê độ dài văn bản qua độ độ dài ký tự và độ dài từ.....	14
Bảng 2.4 Các mẫu dữ liệu tiêu biểu và phân tích nhãn.	19
Bảng 2.5.2. Phân tích các trường hợp dữ liệu nhập nhầm và thách thức trong gán nhãn.	21
Bảng 3.4. Bảng so sánh dữ liệu trước và sau khi tiền xử lý.	31
Bảng 4.7.2 So sánh hiệu năng các mô hình trên hai tác vụ: Phân loại cảm xúc và phân loại chủ đề.....	56
Bảng 4.7.3. Tổng hợp hiệu năng của các mô hình trên tập Test.	58
PhoBERT có lợi thế cốt lõi là được tiền huấn luyện (pre-training) trên dữ liệu tiếng Việt quy mô lớn, trong đó văn bản đã được tách từ (word segmentation) trước khi áp dụng cơ chế mã hóa subword dựa trên Byte-Pair Encoding (BPE). Cách tiếp cận này giúp các token đầu vào tương ứng tốt hơn với đơn vị ngữ nghĩa thực của tiếng Việt, từ đó cải thiện chất lượng vector biểu diễn [CLS].	67
Bảng 4.8.4.1. Truy vết các mẫu PhoBERT dự đoán chính xác (Correct Cases).....	67
Bảng 4.8.4.2. Phân tích các trường hợp PhoBERT dự đoán sai (Error Analysis)	69
Bảng 4.8.4.3. Truy vết các mẫu mBERT dự đoán chính xác (Correct Cases).....	71
Bảng 4.8.4.4. Phân tích các trường hợp mBERT dự đoán sai (Error Analysis)	72

DANH MỤC HÌNH ẢNH

Hình 2.1.1 Minh họa bộ dữ liệu gốc ở bộ train	4
Hình 2.1.2 Minh họa bộ dữ liệu gốc ở bộ validation	5
Hình 2.1.3 Minh họa bộ dữ liệu gốc ở bộ test	5
Hình 2.3.2.2. Mô tả sự phân phối của độ dài ký tự và độ dài từ trong bộ dữ liệu trước xử lý	14
Hình 2.3.2.3. Mô tả sự phân phối của độ dài ký tự và độ dài từ trong bộ dữ liệu sau xử lý	15
Hình 2.3.2.4 Mô tả sự phân phối của độ dài ký tự trong các bộ dữ liệu	15
Hình 2.3.3 Ma trận tương quan giữa cảm xúc và chủ đề.	17
Hình 2.3.4. Word Cloud of Student Feedback	18
Hình 3.1. Sơ đồ tổng quan quy trình thực nghiệm của đề tài.	25
Hình 3.5.1. Kiến trúc Transformer.	34
Hình 4.7.2. Biểu đồ Loss huấn luyện và kiểm thử: PhoBERT vs mBERT.....	55
Hình 4.7.2. Biểu đồ F1-score theo các ngưỡng	57
Hình 4.8.3.1. Confusion Matrix cho bài toán Sentiment – mBERT Multitask.....	61
Hình 4.8.3.2.1 Confusion Matrix – Topic Lecturer.....	63
Hình 4.8.3.2.2 Confusion Matrix – Topic Facility	64
Hình 4.8.3.2.3 Confusion Matrix – Topic Training_program.....	65
Hình 4.8.3.2.4 Confusion Matrix – Topic Others	66

BẢNG ĐÁNH GIÁ ĐÓNG GÓP

STT	Họ và tên	Mã số sinh viên	Đánh giá % đóng góp (tổng 100%)
1	Nguyễn Việt Thắng	22521339	25%
2	Nguyễn Bá Long	23520880	50%
3	Tô Đặng Minh Tuấn	24521942	25%

CHƯƠNG 1. TỔNG QUAN ĐỀ TÀI

1.1 Giới thiệu chung về đề tài

Đề tài "Sentiment and Topic Analysis of Vietnamese University Students' Course Evaluations" (Phân tích cảm xúc và chủ đề trong đánh giá khóa học của sinh viên Việt Nam) tập trung nghiên cứu và thực nghiệm bài toán phân loại văn bản đa nhiệm (Multitask Text Classification). Dựa trên các phản hồi ngắn của sinh viên, đề án ứng dụng các kỹ thuật Xử lý ngôn ngữ tự nhiên (NLP) tiên tiến để đồng thời xác định trạng thái cảm xúc và bóc tách các khía cạnh (aspects) nổi bật. Kết quả của nghiên cứu cung cấp một cái nhìn khách quan về chất lượng giảng dạy, giúp các cơ sở giáo dục chuyển hóa dữ liệu phi cấu trúc thành thông tin có giá trị để cải tiến quy trình đào tạo.

1.2 Mục tiêu nghiên cứu

Đề án hướng tới việc xây dựng và thực nghiệm một hệ thống phân tích phản hồi đa nhiệm (Multitask Analysis) với những mục tiêu trọng tâm rõ rệt. Về khía cạnh kỹ thuật, nghiên cứu tập trung vào việc triển khai và tinh chỉnh (Fine-tuning) các mô hình ngôn ngữ dựa trên kiến trúc Transformer tiên tiến, cụ thể là PhoBERT cho đơn ngữ tiếng Việt và mBERT cho đa ngôn ngữ. Hệ thống được thiết kế tối ưu để thực hiện song song hai tác vụ cốt lõi: phân loại cảm xúc đa lớp theo các thang bậc Tiêu cực, Trung lập, Tích cực; đồng thời phân loại chủ đề đa nhãn tập trung vào các khía cạnh Giảng viên, Chương trình đào tạo, Cơ sở vật chất và các yếu tố khác.

Song song với việc phát triển các mô hình hiện đại, đề án còn chú trọng vào công tác đánh giá so sánh bằng cách thiết lập mô hình máy học truyền thống sử dụng Logistic Regression kết hợp TF-IDF làm Baseline. Bước đi này nhằm minh chứng một cách định lượng sự vượt trội của kiến trúc Deep Learning trong việc nắm bắt ngữ cảnh và độ chính xác so với các phương pháp thống kê cổ điển.

Về mặt thực tiễn, mô hình được đưa vào kiểm chứng trực tiếp trên tập dữ liệu phản hồi của sinh viên – vốn là loại dữ liệu phi cấu trúc mang tính đặc thù cao với sự xuất hiện dày đặc của từ viết tắt, cấu trúc ngôn ngữ tự do và các sắc thái biểu cảm phức tạp. Thông qua quá trình thực nghiệm khắt khe, nghiên cứu kỳ vọng sẽ xác định được mô hình tối ưu nhất, đạt được sự cân bằng giữa hiệu năng xử lý, khả năng tổng quát hóa và chi phí tính toán, làm nền tảng vững chắc cho việc nâng cao hiệu quả đánh giá môn học và hỗ trợ nhà trường trong việc cải tiến chất lượng giảng dạy.

1.3 Phạm vi nghiên cứu và giả định

1.3.1 Phạm vi nghiên cứu.

- **Ngôn ngữ:** Chỉ tập trung vào tiếng Việt, xử lý các đặc thù về từ ghép, teencode và ngữ pháp tiếng Việt.
- **Đối tượng dữ liệu:** Phản hồi của sinh viên về Giảng viên, Chương trình đào tạo và Cơ sở vật chất.
- **Kỹ thuật xử lý:** Áp dụng pipeline NLP hiện đại bao gồm tiền xử lý văn bản, tách từ (Word Segmentation) bằng Underthesea, và huấn luyện đa nhiệm với hàm mất mát kết hợp (Combined Loss).
- **Hệ thống thực tế:** Xây dựng Dashboard tương tác trên nền tảng Streamlit để trình diễn khả năng phân tích thời gian thực.

1.3.2 Giả định nghiên cứu.

- Dữ liệu phản ánh trung thực trải nghiệm của sinh viên.
- Bộ dữ liệu UIT-VSFC và dữ liệu tổng hợp (Synthetic Data) đủ độ bao phủ để huấn luyện mô hình.
- Các công cụ hỗ trợ như PhoBERT và Tokenizer hoạt động ổn định trên tập dữ liệu giáo dục chuyên biệt.

1.4 Đóng góp của đề tài

1.4.1 Về mặt học thuật:

Thực nghiệm thành công kiến trúc Multitask Learning cho tiếng Việt, giúp mô hình học được mối tương quan giữa cảm xúc và chủ đề, từ đó tăng cường độ chính xác cho từng tác vụ riêng lẻ.

Đánh giá định lượng về hiệu quả giữa mô hình đơn ngữ (PhoBERT) và đa ngôn ngữ (mBERT) trong ngữ cảnh ngôn ngữ tiếng Việt.

Đóng góp quy trình xử lý dữ liệu tổng hợp (Synthetic Data) để giải quyết vấn đề mất cân bằng nhãn trong dữ liệu giáo dục.

1.4.2 Về mặt thực tiễn:

Cung cấp công cụ tự động giúp nhà trường phân tích hàng nghìn phản hồi trong thời gian ngắn, thay thế quy trình rà soát thủ công.

Dashboard trực quan hóa giúp giảng viên và quản lý giáo dục nhận diện nhanh các "điểm nóng" tiêu cực về cơ sở vật chất hoặc chương trình học để kịp thời khắc phục.

Tiết kiệm tài nguyên và nâng cao tính khách quan trong công tác kiểm định chất lượng đào tạo.

CHƯƠNG 2. NGUỒN DỮ LIỆU ĐÁNH GIÁ MÔN HỌC

2.1 Thu thập dữ liệu

2.1.1 Nguồn dữ liệu đánh giá môn học

Nguồn dữ liệu sử dụng trong đề án là bộ dữ liệu gốc uitnlp/vietnamese_students_feedback được cung cấp trên nền tảng HuggingFace. Đây là bộ dữ liệu chuẩn cho các bài toán NLP tại Việt Nam, bao gồm các phản hồi của sinh viên được gán nhãn đa chiều:

- **Cảm xúc (Sentiment):** Positive (Tích cực), Neutral (Trung lập), Negative (Tiêu cực).
- **Chủ đề (Topic):** Training Program (Chương trình đào tạo), Lecturer (Giảng viên), Facility (Cơ sở vật chất), Others (Khác).

Link dataset: [uitnlp/vietnamese_students_feedback](https://huggingface.co/datasets/uitnlp/vietnamese_students_feedback)

Bộ dữ liệu gốc bao gồm 3 cột và 16175 mẫu dữ liệu, được chia thành 3 mẫu dữ liệu bao gồm train (11426), test (3166), và validation (1583). Các cột bao gồm cột sentence, sentiment, và topic.

Ví dụ một số mẫu từ dataset:

	comment	sentiment	topic	split
0	slide giáo trình đầy đủ .	2	1	train
1	nhật tình giảng dạy , gần gũi với sinh viên .	2	0	train
2	đi học đầy đủ full điểm chuyên cần .	0	1	train
3	chưa áp dụng công nghệ thông tin và các thiết bị hỗ trợ cho việc giảng dạy .	0	0	train
4	thầy giảng bài hay , có nhiều bài tập ví dụ ngay trên lớp .	2	0	train
...	...	...	...	...
11421	chỉ vì môn game mà em học hai lần mà không qua quả thật em rất không hài lòng vì những lý do vô cùng thiếu chuyên nghiệp như thế này .	0	1	train
11422	em cảm ơn cô nhiều .	2	0	train
11423	giao bài tập quá nhiều .	0	0	train
11424	giáo viên dạy dễ hiểu , nhiệt tình .	2	0	train
11425	gối gọn doubledot hay , tận tình , phù hợp với mọi trình độ cũng như nhu cầu môn học .	2	0	train

11426 rows × 4 columns

Hình 2.1.1 Minh họa bộ dữ liệu gốc ở bộ train

	comment	sentiment	topic	split
0	giáo trình chưa cụ thể .	0	1	val
1	giảng buồn ngủ .	0	0	val
2	giáo viên vui tính , tận tâm .	2	0	val
3	giảng viên nên giao bài tập nhiều hơn , chia nhóm để làm bài tập , giảng kỹ những vấn đề trọng tâm của môn học , đưa ra phương pháp để học hiệu quả hơn .	0	0	val
4	giảng viên cần giảng bài chi tiết hơn , đi sâu hơn code và chạy thử chương trình có trong bài giảng nếu được .	0	0	val
...	...	...	...	...
1578	hướng dẫn lab mơ hồ .	0	0	val
1579	thầy cho chúng em những bài tập mang tính thực hành , thực tiễn cao và em thực sự rất hài lòng .	2	0	val
1580	thầy không dạy nhiều chủ yếu cho sinh viên tự tìm hiểu .	0	0	val
1581	em muốn đổi tên môn học vì tên môn là lập trình c fraction cplusplus nhưng lại học thiên về csharp .	0	1	val
1582	thầy vừa dạy vừa chat hoặc gọi điện thoại thường xuyên .	0	0	val

1583 rows × 4 columns

Hình 2.1.2 Minh họa bộ dữ liệu gốc ở bộ validation

	comment	sentiment	topic	split
0	nói tiếng anh lưu loát .	2	0	test
1	giáo viên rất vui tính .	2	0	test
2	cô max có tâm .	2	0	test
3	giảng bài thu hút , dí dỏm .	2	0	test
4	giáo viên không giảng dạy kiến thức , hướng dẫn thực hành trong quá trình học .	0	0	test
...	...	...	...	...
3161	các slide khó hiểu , ngôn ngữ trong slide phức tạp , lòng vòng vì vậy giảng viên cần chỉnh sửa lại slide giảng dạy .	0	0	test
3162	giáo viên giảng dạy có tâm huyết .	2	0	test
3163	chia sẻ cho em nhiều điều hay .	2	0	test
3164	em tiếp thu chậm .	0	0	test
3165	em có học ở một trung tâm tiếng anh ở ngoài trường , thời lượng hợp lý , không nhiều không ít khoảng 2 - 3 tiết một buổi !	1	1	test

3166 rows × 4 columns

Hình 2.1.3 Minh họa bộ dữ liệu gốc ở bộ test

2.1.2 Tiêu chí lựa chọn và sàng lọc dữ liệu

Để đảm bảo chất lượng và tính chính xác dữ liệu đầu vào cho mô hình huấn luyện, nhóm áp dụng các tiêu chí sàng lọc và tiền xử lý sau:

2.1.2.1 Loại bỏ mẫu dữ liệu không hợp lệ:

- **Dữ liệu thiếu:** Loại bỏ các dòng có nội dung bình luận là None hoặc rỗng.
- **Dữ liệu trùng lặp:** Loại bỏ các bình luận trùng lặp hoàn toàn (duplicate) trong tập huấn luyện để tránh hiện tượng mô hình học vẹt (overfitting).
- **Dữ liệu nhiễu:** Loại bỏ các bình luận quá ngắn hoặc các bình luận chỉ chứa các ký tự vô nghĩa, không mang thông tin đánh giá.

2.1.2.2 Ánh xạ nhãn (Label Mapping)

- **Nhãn cảm xúc (Sentiment):** Chuyển đổi về dạng số nguyên: 0 (Negative), 1 (Neutral), 2 (Positive).
- **Nhãn chủ đề (Topic):** Chuyển đổi về dạng số nguyên: 0 (Lecturer), 1 (Training Program), 2 (Facility), 3 (Others).

2.1.2.3 Tiền xử lý văn bản(Text Preprocessing)

Đây là bước quan trọng để chuẩn hóa dữ liệu đầu vào cho mô hình PhoBERT/mBERT:

- **Chuẩn hóa:** Chuyển về chữ thường, xử lý lỗi Unicode và khoảng trắng thừa.
- **Tách từ (Word Segmentation):** Sử dụng thư viện Underthesea để gán nhãn từ ghép (Ví dụ: "sinh viên" → "sinh_viên"). Bước này vô cùng quan trọng để giúp mô hình PhoBERT nhận diện đúng thực thể trong từ điển tiếng Việt.
- **Bảo toàn Stopwords và dấu câu:** Khác với mô hình thống kê (TF-IDF), nhóm quyết định giữ lại các từ dừng và dấu câu. Điều này giúp cơ chế Attention của mô hình Transformer hiểu được cấu trúc câu và các sắc thái cảm xúc tinh tế (như các hư từ "nhưng", "tuy", "nhỉ", "nhé").

2.1.2.4 Phân bố nhãn sau xử lý

Bảng 2.1.2.4. Bảng phân phối nhãn cảm xúc.

Phân bố nhãn	Sentiment
2 (Positive)	8038
0 (Negative)	7437
1 (Neutral)	695

Bảng 2.1.2.5. Bảng phân phối nhãn chủ đề.

Nhãn Chủ Đề	Topic
Chương trình đào tạo (Training Program)	3040
Giảng viên (Lecturer)	11605
Cơ sở vật chất (Facility)	712
Khác (Others)	813

2.2 Định nghĩa nhãn dữ liệu

2.2.1 Nhãn cảm xúc (Sentiment Labels)

Trong bài toán phân tích cảm xúc đối với các bình luận đánh giá khóa học của sinh viên, nhóm nghiên cứu sử dụng 3 nhãn cảm xúc chính, được phân loại dựa trên mức độ hài lòng hoặc sự không hài lòng trong phản hồi của sinh viên. Các nhãn này bao gồm:

Bảng 2.2.1. Bảng định nghĩa và tiêu chí nhận diện nhãn cảm xúc.

Nhãn (Label)	Định nghĩa & Tiêu chí nhận diện	Ví dụ minh họa
Tích cực (Positive)	Định nghĩa: Gán cho các đánh giá thể hiện sự hài lòng, khen ngợi và đánh giá cao về chất lượng môn học, giảng viên hoặc cơ sở vật chất. Đặc điểm: Thường chứa các tính từ tích cực, thể hiện sự yêu thích hoặc được truyền cảm hứng trong học tập.	"Môn học rất thú vị, giảng viên giảng bài dễ hiểu và luôn tạo động lực cho sinh viên."

Tiêu cực (Negative)	Định nghĩa: Gán cho các đánh giá thể hiện thái độ không hài lòng, chỉ trích, chê bai hoặc thất vọng. Đặc điểm: Phản ánh các vấn đề tồn tại (bất công, khó hiểu, cơ sở vật chất kém) hoặc bức xúc cá nhân của sinh viên.	"Giảng viên quá khắt khe, đề thi rất khó và không công bằng."
Trung lập (Neutral)	Định nghĩa: Gán cho các bình luận mang tính khách quan, mô tả sự việc mà không bộc lộ cảm xúc rõ ràng. Đặc điểm: Chỉ đơn thuần cung cấp thông tin về môn học (tín chỉ, hình thức thi, lịch học) mà không khen hay chê.	"Môn học có 3 tín chỉ và hình thức thi là trắc nghiệm."

2.2.2 Nhãn chủ đề (Topic Labels)

Trong bài toán phân tích chủ đề từ các đánh giá môn học của sinh viên, các nhãn chủ đề được sử dụng để phân loại nội dung các bình luận theo các khía cạnh chính liên quan đến quá trình học tập và giảng dạy. Các nhãn chủ đề này phản ánh những vấn đề mà sinh viên quan tâm hoặc gặp phải trong quá trình học, bao gồm các yếu tố liên quan đến chương trình đào tạo, giảng viên, cơ sở vật chất, và những yếu tố khác. Dưới đây là các nhãn chủ đề chính:

Bảng 2.2.2. Bảng định nghĩa và tiêu chí nhận diện nhãn cảm xúc.

Nhãn (Label)	Phạm vi & Tiêu chí nhận diện	Ví dụ minh họa
Chương trình đào tạo (<i>Training Program</i>)	Phạm vi: Bao gồm nội dung môn học, cấu trúc bài giảng, tài liệu tham khảo, bài tập lớn, hình thức thi cử và quy chế đào tạo. Tiêu chí: Các bình luận nhận xét về độ khó/dễ, tính thực tế của kiến thức, hoặc sự phù hợp của đề thi so với nội dung đã học.	<i>"Nội dung môn học quá nặng về lý thuyết, bài tập lớn không sát với thực tế đi làm."</i>
Giảng viên (<i>Lecturer</i>)	Phạm vi: Tập trung vào con người – cụ thể là người dạy (thầy/cô/trợ giảng). Tiêu chí: Đánh giá về phương pháp sư phạm, thái độ giảng dạy (nhiệt tình/khắc khe), tác phong (đi trễ/về sớm) và khả năng hỗ trợ giải đáp thắc mắc cho sinh viên.	<i>"Thầy dạy rất có tâm, giảng bài lôi cuốn và thường xuyên trả lời email của sinh viên."</i>
Cơ sở vật chất (<i>Facility</i>)	Phạm vi: Liên quan đến môi trường vật lý và trang thiết bị phục vụ việc học.	<i>"Phòng B.102 máy chiếu bị mờ không nhìn thấy gì, wifi quá yếu không tải được tài liệu."</i>

	Tiêu chí: Các phản hồi về phòng học (máy lạnh, máy chiếu, bàn ghế), phòng thí nghiệm, wifi, hệ thống âm thanh hoặc khuôn viên trường.	
Khác (Others)	Phạm vi: Các khía cạnh không thuộc 3 nhóm trên hoặc các ý kiến chung chung. Tiêu chí: Các vấn đề về học phí, quy trình đăng ký môn học, bãi giữ xe, hoặc các bình luận spam, không rõ ngữ nghĩa cụ thể.	<i>"Hệ thống đăng ký môn học bị lỗi liên tục, học phí kỳ này tăng cao quá."</i>

2.2.3 Quy tắc gán nhãn và xử lý trường hợp phức tạp

2.2.3.1 Cơ chế gán nhãn trong mô hình (Label Assignment Mechanism)

Tác vụ 1: Phân loại cảm xúc (Sentiment - Single-label)

- **Cơ chế:** Mỗi bình luận chỉ được gán duy nhất một nhãn cảm xúc (Negative, Neutral, hoặc Positive).
- **Kỹ thuật:** Mô hình sử dụng hàm kích hoạt Softmax ở lớp đầu ra để tính xác suất, nhãn có xác suất cao nhất sẽ được chọn.
- **Quy tắc:** Ưu tiên cảm xúc chủ đạo. Nếu bình luận vừa khen vừa chê, nhãn sẽ được gán theo thái độ nào mạnh mẽ hơn hoặc ảnh hưởng trực tiếp đến đánh giá chung.

Tác vụ 2: Phân loại chủ đề (Topic - Multi-label)

- **Cơ chế:** Một bình luận có thể được gán một hoặc nhiều nhãn chủ đề đồng thời (Ví dụ: vừa nói về *Giảng viên*, vừa nói về *Cơ sở vật chất*).
- **Kỹ thuật:** Mô hình sử dụng hàm kích hoạt Sigmoid cho từng lớp chủ đề độc lập. Nhóm áp dụng kỹ thuật Threshold Tuning (tinh chỉnh ngưỡng) trên tập Validation để quyết định gán nhãn (ví dụ: nếu xác suất > ngưỡng tối ưu thì gán nhãn 1, ngược lại là 0).

2.2.3.2 Xử lý trường hợp phức tạp

Trong thực tế, nhiều bình luận có thể không dễ dàng gán nhãn vào chỉ một nhãn duy nhất. Dưới đây là một số trường hợp phức tạp và cách xử lý:

Bình luận đa cảm xúc (Mixed Sentiments):

- *Mô tả:* Sinh viên khen giảng viên nhưng chê cơ sở vật chất trong cùng một câu (VD: "Thầy dạy hay nhưng phòng nóng").
- *Xử lý:* Do bài toán Sentiment là đơn nhãn, nhãn sẽ được gán cho mệnh đề chính hoặc cảm xúc mang tính quyết định hơn. Đây là một nguyên nhân gây nhiễu (noise) mà mô hình cần học để tổng quát hóa.

Bình luận ẩn ý hoặc mỉa mai (Sarcasm/Ambiguity):

- *Mô tả:* Các câu như "Môn học 'tuyệt vời' đến mức tôi phải học lại" mang hàm ý tiêu cực dù dùng từ tích cực.
- *Xử lý:* Thay vì xử lý thủ công, nhóm dựa vào khả năng **Contextual Embedding (Nhúng ngữ cảnh)** của mô hình **PhoBERT**. Nhờ cơ chế Attention, mô hình có thể nhận diện sự mâu thuẫn giữa các từ trong ngữ cảnh toàn câu để dự đoán đúng nhãn Tiêu cực.

Ngôn ngữ không chuẩn (Teencode/Slang):

- *Mô tả:* Sinh viên thường dùng từ viết tắt, từ lóng (VD: "ko", "dc", "phê", "vãi", "gắt").

- *Xử lý*: Nhóm **không thực hiện thay thế thủ công** từng từ vì số lượng biến thể quá lớn. Thay vào đó, nhóm sử dụng mô hình **PhoBERT** (được huấn luyện trên dữ liệu tiếng Việt quy mô lớn bao gồm cả mạng xã hội) kết hợp với bước tách từ (underthesea) để mô hình tự học ngữ nghĩa của các từ lóng này trong không gian vector.

Bình luận đa chủ đề (Multi-topic Overlap):


- *Mô tả*: Một câu bình luận ngắn nhưng đề cập nhiều khía cạnh.
- *Xử lý*: Đây là lý do nhóm chọn phương pháp **Multi-label Classification** cho bài toán Topic thay vì Multi-class, cho phép mô hình bắt được tất cả các khía cạnh được nhắc đến mà không bị mất thông tin.

2.3 Phân tích thống kê dữ liệu

2.3.1 Quy mô và phân bố nhãn (cảm xúc, chủ đề)

Bộ dữ liệu đánh giá môn học từ sinh viên Việt Nam chứa tổng cộng 16170 bình luận sau khi đã lọc và xử lý. Các bình luận này được phân loại thành 3 nhãn cảm xúc và 4 nhãn chủ đề chính. Bộ dữ liệu được chia thành 3 tập: Train, Validation, và Test, mỗi tập được sử dụng trong các bước huấn luyện, kiểm tra và đánh giá mô hình.


Phân bố nhãn cảm xúc (Sentiment Labels)



Nhãn Cảm Xúc	Số Lượng	Tỷ Lệ (%)
Tích cực	8038	49.7%
Tiêu cực	7437	46%
Trung lập	695	4.3%

Bảng 2.3.1.1 mô tả sự phân bố của các nhãn cảm xúc.

Phân bố nhãn chủ đề (Topic Labels)



Nhãn Chủ Đề	Số Lượng	Tỷ Lệ (%)
Chương trình đào tạo	3040	19%
Giảng viên	11605	72%
Cơ sở vật chất	712	4%
Khác	813	5%

Bảng 2.3.1.2 mô tả sự phân bố của các nhãn chủ đề.


2.3.2 Độ dài văn bản và đặc điểm ngôn ngữ

Thống kê độ dài văn bản:


Sau khi tiền xử lý và chuẩn hóa văn bản, nhóm đã tính toán độ dài ký tự (len_char) và độ dài từ (len_tok) cho mỗi bình luận trong bộ dữ liệu. Dưới đây là thống kê chi tiết về độ dài văn bản:

Thống kê	len_char	len_tok
count	16170.0	16170.0
mean	58.779839	14.231602
std	43.261043	10.103110
min	5.0	2.0
25%	31.0	8.0
50%	46.0	11.0
75%	73.0	17.0
max	718.0	161.0

Bảng 2.3.2.1 Thống kê độ dài văn bản qua độ dài ký tự và độ dài từ




Hình 2.3.2.2. Mô tả sự phân phối của độ dài ký tự và độ dài từ trong bộ dữ liệu trước xử lý



Hình 2.3.2.3. Mô tả sự phân phối của độ dài ký tự và độ dài từ trong bộ dữ liệu sau xử lý

Phân bố độ dài văn bản trong các tập Train, Validation, Test




Hình 2.3.2.4 Mô tả sự phân phối của độ dài ký tự trong các bộ dữ liệu

Phân tích đặc điểm ngôn ngữ:

- **Độ dài văn bản:**
 - **Trung bình:** Mỗi bình luận có độ dài trung bình khoảng 58.8 ký tự và 14.2 từ.

- **Phân bố:** Độ dài bình luận có sự biến thiên lớn, dao động từ ngắn nhất 4 ký tự (2 từ) đến dài nhất 718 ký tự (161 từ). Tuy nhiên, phần lớn các bình luận có độ dài ngắn và súc tích, với 50% số lượng bình luận có độ dài dưới 46 ký tự và 11 từ.
- **Đặc điểm hình thái và từ vựng:**
 - **Cấu trúc đa dạng:** Sự chênh lệch lớn về độ dài (từ 2 đến 161 từ) cho thấy sự đa dạng trong cách diễn đạt của sinh viên: từ những câu nhận xét ngắn gọn, trực diện đến những đoạn văn mô tả chi tiết vấn đề.
 - **Ngữ pháp và phong cách:** Bộ dữ liệu là văn bản tự nhiên (free-text) nên chứa hỗn hợp giữa câu đơn và câu phức. Đặc biệt, xuất hiện nhiều ngôn ngữ không chuẩn mực như từ viết tắt, từ lóng (teencode) đặc trưng của sinh viên.
 - **Emoji và ký tự đặc biệt:** Các biểu tượng cảm xúc (Emoji) xuất hiện với tần suất cao. Đây là yếu tố mang nhiều thông tin cảm xúc, cần được xử lý khéo léo (chuẩn hóa hoặc giải mã) trong bước tiền xử lý để mô hình tận dụng tối đa ngữ nghĩa thay vì loại bỏ hoàn toàn như nhiều.
- **Phân tích ngữ nghĩa:**
 - **Sắc thái cảm xúc:** Bên cạnh các cảm xúc rõ ràng, dữ liệu chứa nhiều trường hợp sarcasm (mỉa mai) hoặc hài hước (ví dụ: dùng từ tích cực để chê bai), đặt ra thách thức lớn yêu cầu mô hình phải hiểu sâu ngữ cảnh (Contextual Understanding) để phân loại chính xác.

2.3.3 Ma trận tương quan giữa các lớp



Hình 2.3.3 Ma trận tương quan giữa cảm xúc và chủ đề.

- **Chủ đề gây bức xúc nhất (Pain Points):** Các khía cạnh về vật chất và chương trình học nhận phản hồi tiêu cực áp đảo. Cụ thể, chủ đề Facility (Cơ sở vật chất) có tỷ lệ Negative cao nhất lên tới 95.6%, theo sau là Training Program với 76.6%.
- **Điểm sáng (Bright Spot):** Chủ đề Lecturer (Giảng viên) là khía cạnh duy nhất nhận được sự hài lòng lớn từ sinh viên, với tỷ lệ Positive chiếm đa số (62.1%).
- **Sự phân tán:** Nhóm chủ đề Others có sự phân hóa cảm xúc đồng đều nhất và cũng chứa tỷ lệ Neutral cao nhất (28.3%), cho thấy các ý kiến này thường mang tính mô tả chung chung.

2.3.4 Tần suất xuất hiện của các từ



Hình 2.3.4. Word Cloud of Student Feedback

- **Tần suất xuất hiện:** Các từ khóa như "sinh_vien", "dạy", "giảng_vien" chiếm vị trí đầu bảng, phản ánh đúng ngữ cảnh của bộ dữ liệu là các văn bản đánh giá trong môi trường giáo dục.
- **Xu hướng đánh giá:** Các tính từ chỉ thái độ và chất lượng như "nhiệt_tình" (Top 3), "hiểu", "tốt", "tận_tâm" xuất hiện với tần suất rất cao. Điều này cho thấy sinh viên có xu hướng quan tâm nhiều đến thái độ sư phạm và khả năng truyền đạt của giảng viên khi viết phản hồi.
- **Về nội dung học tập:** Các từ khóa liên quan đến chuyên môn như "thực_hành", "bài_tập", "kiến_thức" cũng nằm trong nhóm phổ biến, thể hiện sự quan tâm đến tính thực tế của môn học.

2.4 Ví dụ về dữ liệu

Để minh họa rõ hơn về cách thức gán nhãn đa chiều (cảm xúc và chủ đề) trong bộ dữ liệu UIT-VSFC, bảng dưới đây trình bày một số mẫu dữ liệu điển hình đại diện cho các trường hợp khác nhau (Tham khảo thêm tại Phụ Lục):

Bảng 2.4 Các mẫu dữ liệu tiêu biểu và phân tích nhãn.

STT	Nội dung bình luận (Sentence)	Cảm xúc (Sentiment)	Chủ đề (Topic)	Phân tích & Giải thích
1	"Thầy dạy rất nhiệt tình, dễ hiểu, lấy ví dụ thực tế."	Positive	Lecturer	Khen ngợi trực tiếp: Tập trung vào kỹ năng sư phạm và thái độ của giảng viên.
2	"Phòng học nóng quá, điều hòa hỏng suốt không thấy sửa."	Negative	Facility	Phàn nàn về điều kiện vật chất: Chứa các từ mang sắc thái tiêu cực rõ rệt liên quan đến thiết bị phòng học.
3	"Môn này bài tập lớn hơi nặng nhưng kiến thức rất bổ ích."	Positive	Training Program	Sắc thái tương phản: Dù có vế chê (nặng), nhưng thông điệp cốt lõi là giá trị kiến thức (bổ ích), thuộc nội dung môn học.
4	"Nội dung môn học bình thường, không có gì đặc sắc."	Neutral	Training Program	Đánh giá trung tính: Phản hồi mang tính mô tả mức độ hài lòng ở mức trung bình, không thể hiện thái độ tích cực hay tiêu cực rõ ràng.
5	"Thầy dạy hay nhưng phòng máy chán quá, lag liên tục."	Positive (Dominant)	Lecturer & Facility	Đa chủ đề & Hỗn hợp cảm xúc: Đây là thách thức cho mô hình. Trong khi Topic được gán đa nhãn, Sentiment buộc phải chọn nhãn chủ đạo hoặc gán nhãn theo quy tắc của bộ dữ liệu gốc.

2.5 Đánh giá chất lượng dữ liệu

2.5.1 Phân tích nhiễu, tính thiên lệch và độ đa dạng

Dựa trên quá trình Khám phá dữ liệu (EDA) trong file thực nghiệm, nhóm nghiên cứu nhận thấy các đặc điểm sau:

- **Nhiều dữ liệu (Noise):** Dữ liệu thực tế từ sinh viên chứa nhiều "rác" đặc thù như:
 - **Teencode & Viết tắt:** Sử dụng dày đặc các từ như *ko*, *dc*, *j*, *wa*, *thik*... gây khó khăn cho việc tokenization chuẩn.
 - **Spam & Ký tự lạ:** Các bình luận vô nghĩa (ví dụ: "...", "ahhihi", các chuỗi ký tự ngẫu nhiên) đã được nhóm xử lý bằng bộ lọc ngôn ngữ (langdetect) và biểu thức chính quy (Regex).
- **Tính thiên lệch (Class Imbalance):** Đây là vấn đề nghiêm trọng nhất của bộ dữ liệu.
 - Lớp Tích cực (Positive) và Tiêu cực (Negative) chiếm đa số (khoảng 85-90%).
 - Lớp Trung lập (Neutral) là lớp thiểu số (Minority class), chỉ chiếm khoảng 10-15%.
 - *Hệ quả:* Mô hình máy học thường có xu hướng "học vẹt" theo lớp đa số, dẫn đến việc dự đoán các câu trung lập thành tích cực hoặc tiêu cực (Overfitting on majority classes).
- **Độ đa dạng (Diversity):** Dữ liệu bao phủ đa dạng các khía cạnh từ giảng viên, giáo trình đến cơ sở vật chất, phản ánh đầy đủ bức tranh chất lượng đào tạo.

2.5.2 Phân tích độ nhập nhằng và nhất quán của nhãn (Label Consistency)

Ngôn ngữ tự nhiên của sinh viên thường mang tính chủ quan cao, dẫn đến các trường hợp nhập nhằng (Ambiguity) hoặc gán nhãn chưa đồng nhất. Nhóm đã thực hiện trích xuất ngẫu nhiên và phân tích định tính một số mẫu dữ liệu điển hình để làm rõ vấn đề này (xem Bảng 2.5.2).

Bảng 2.5.2. Phân tích các trường hợp dữ liệu nhập nhằng và thách thức trong gán nhãn.

STT	Nội dung bình luận (Raw Data)	Nhãn gốc (Dataset)	Phân tích & Đánh giá của nhóm
1	"Thầy lên lớp đúng giờ"	Pos / Lecturer	Thách thức: <i>Sắc thái hàm ẩn (Implied Sentiment).</i> Về lý thuyết, đây là mô tả sự thật khách quan (Neutral). Tuy nhiên, trong ngữ cảnh giáo dục Việt Nam, việc tuân thủ tác phong được xem là điểm cộng lớn. Mô hình dễ nhầm sang Neutral nếu không học được ngữ cảnh đánh giá.
2	"Môn học này cũng bình thường thôi"	Neu / Program	Thách thức: <i>Sự ảnh hưởng của hư từ (Sentiment Nuance).</i> Từ "bình thường" là trung tính, nhưng hư từ "thôi" tạo sắc thái thất vọng nhẹ. Nhãn gốc gán Neutral có thể gây tranh cãi vì nó đã tiệm cận ranh giới Negative.

3	<i>"Slide bài giảng tiếng anh ko ah, khó hiểu mún chít"</i>	Neg / Program	Thách thức: <i>Nhiều Teencode và Tính chủ quan.</i> Nhiều nặng ("ko", "hiu"). Nội dung này vừa chê tài liệu, vừa thể hiện sự khó khăn cá nhân của SV. Đây là mẫu kiểm tra khả năng bền bỉ (robustness) của bộ Tokenizer.
4	<i>"Thầy dạy rất nhiệt tình nhưng phòng nóng quá không học nổi"</i>	Pos / [Lecturer, Facility]	Thách thức: <i>Xung đột cảm xúc (Mixed Sentiment).</i> Đây là mẫu điển hình cho bài toán Multitask. Nếu chỉ gán 1 nhãn Sentiment (Positive), thông tin tiêu cực về Cơ sở vật chất sẽ bị triệt tiêu hoàn toàn.
5	<i>"..." hoặc "asdasd"</i>	Neu / Others	Thách thức: <i>Dữ liệu rác (Noise).</i> Các mẫu này không mang giá trị ngữ nghĩa nhưng vẫn tồn tại trong tập huấn luyện. Nhóm quyết định xử lý bằng cách lọc bỏ hoặc đưa vào nhãn Others để tránh làm lệch phân phối trọng số của mô hình.

2.6 TỰ TẠO VÀ TĂNG CƯỜNG DỮ LIỆU (DATA AUGMENTATION)

Như đã phân tích ở Mục 2.3, bộ dữ liệu gốc tồn tại sự mất cân bằng giữa các lớp (Lớp Neutral rất ít). Thay vì can thiệp sinh dữ liệu nhân tạo (có rủi ro làm nhiễu ngữ nghĩa), nhóm quyết định sử dụng chiến lược giữ nguyên phân bố thực tế để huấn luyện.

Lý do lựa chọn:

- **Phản ánh thực tế:** Dữ liệu thực tế thu thập từ sinh viên vốn dĩ đã mất cân bằng (sinh viên thường chỉ đánh giá khi rất thích hoặc rất ghét). Mô hình cần học cách thích nghi với phân bố này.
- **Tối ưu hóa Metric:** Nhóm sẽ tập trung đánh giá mô hình dựa trên F1-Score (Macro) thay vì Accuracy, để đảm bảo hiệu năng trên các lớp thiểu số (Neutral, Facility) vẫn được ghi nhận chính xác.

2.7 Chia tập dữ liệu và thiết lập thí nghiệm

2.7.1 Chia tập Train, Validation và Test

Để đảm bảo tính khách quan, dữ liệu sạch (16,170 mẫu) được chia ngẫu nhiên thành 3 tập độc lập theo tỷ lệ xấp xỉ 70% - 10% - 20%.

- **Tập Huấn luyện (Training Set):** 11,426 mẫu. Dùng để huấn luyện trọng số cho mô hình PhoBERT/mBERT.
- **Tập Kiểm định (Validation Set):** 1,583 mẫu. Dùng để tinh chỉnh tham số (Threshold Tuning cho Topic) và đánh giá sớm (Early Stopping).
- **Tập Kiểm thử (Test Set):** 3,166 mẫu. Dữ liệu hoàn toàn mới, được giữ kín cho đến bước đánh giá cuối cùng để đo lường độ chính xác thực tế.

2.7.2 Quy trình huấn luyện (Training Setup)


- **Random Seed:** Cố định seed=42 để đảm bảo kết quả có thể tái lập (reproducible).
- **Batch Size:** Thiết lập phù hợp với bộ nhớ GPU (ví dụ: 16 hoặc 32).

- **Chiến lược:** Mô hình được huấn luyện theo cơ chế Multi-task Learning, tối ưu hóa đồng thời hàm mất mát của cả 2 nhánh (Sentiment và Topic) trên cùng một backbone (PhoBERT/mBERT)

CHƯƠNG 3. PHƯƠNG PHÁP NGHIÊN CỨU

3.1 Tổng quan phương pháp nghiên cứu

Để giải quyết bài toán phân tích ý kiến sinh viên (Student Feedback Analysis) một cách toàn diện, nhóm nghiên cứu thiết kế quy trình thực nghiệm gồm 4 giai đoạn, tập trung vào việc so sánh hiệu quả giữa các mô hình học máy truyền thống và các mô hình ngôn ngữ lớn hiện đại (Transformer-based).



Hình 3.1. Sơ đồ tổng quan quy trình thực nghiệm của đề tài.

Cụ thể, quy trình được triển khai chi tiết như sau:

Giai đoạn 1: Tiền xử lý và Làm sạch dữ liệu

Nhận thấy dữ liệu phản hồi thực tế chứa nhiều nhiễu, nhóm áp dụng pipeline xử lý tối ưu cho tiếng Việt:

- **Lọc nhiễu:** Loại bỏ các mẫu dữ liệu rỗng (NaN), các dòng trùng lặp và các ký tự vô nghĩa.
- **Chuẩn hóa:** Đưa văn bản về dạng chữ thường (lowercase), chuẩn hóa Unicode và xử lý Emoji (giữ lại hoặc chuyển đổi để hỗ trợ phân tích cảm xúc).

- **Tách từ (Word Segmentation):** Sử dụng thư viện Underthesea để gộp các từ đơn thành từ ghép có nghĩa (ví dụ: "sinh_viên", "giảng_viên"). Bước này đặc biệt quan trọng để chuẩn bị dữ liệu cho mô hình PhoBERT.

Giai đoạn 2: Chiến lược biểu diễn dữ liệu (Feature Engineering Strategy)

Nhóm thực hiện 2 hướng tiếp cận song song để phục vụ các nhóm mô hình khác nhau:

- **Biểu diễn thưa (Sparse Representation):** Sử dụng TF-IDF để trích xuất đặc trưng cho mô hình thống kê cơ sở (Baseline).
- **Biểu diễn ngữ cảnh (Contextual Representation):** Sử dụng AutoTokenizer (của mBERT và PhoBERT) để mã hóa văn bản thành chuỗi ID số học (input_ids) và mặt nạ sự chú ý (attention_mask), giúp mô hình hiểu được ngữ cảnh và thứ tự từ.

Giai đoạn 3: Kiến trúc và Thực nghiệm Mô hình (Model Experimentation)

Nhóm thiết kế kịch bản thực nghiệm phân tầng độ phức tạp để đánh giá sự cải thiện hiệu năng:

- **Nhóm Baseline (Cơ sở):** Sử dụng Logistic Regression kết hợp với chiến lược One-Vs-Rest. Đây là mô hình học máy đơn giản, tốc độ cao, được dùng làm mốc chuẩn (Benchmark) để so sánh.
- **Nhóm Đa ngữ (Multilingual):** Sử dụng mBERT (Multilingual BERT). Đây là mô hình được huấn luyện trên 104 ngôn ngữ. Nhóm đưa vào để đánh giá xem liệu một mô hình học từ dữ liệu toàn cầu có hiệu quả với tiếng Việt hay không.
- **Nhóm Chuyên biệt (State-of-the-Art):** Sử dụng PhoBERT. Đây là mô hình chủ đạo, được huấn luyện chuyên biệt cho tiếng Việt với kỹ thuật tách từ và dữ liệu quy mô lớn, kỳ vọng mang lại kết quả tốt nhất.

Giai đoạn 4: Đánh giá và Phân tích lỗi (Evaluation & Error Analysis)

- Sử dụng bộ chỉ số đa chiều: Accuracy, Precision, Recall, và đặc biệt là F1-Score (Macro) để đánh giá khách quan trên tập dữ liệu mất cân bằng.

- Thực hiện phân tích các trường hợp dự đoán sai (Error Analysis) và tinh chỉnh ngưỡng (Threshold Tuning) cho bài toán phân loại chủ đề đa nhãn.

3.2 Bài toán và mô hình

Phát biểu bài toán (Problem Statement)

Đề tài giải quyết bài toán phân loại văn bản có giám sát (Supervised Text Classification).

Giả sử tập dữ liệu huấn luyện là:

$$D = \{(x_i, y_i, z_i)\}_{i=1}^N$$

Trong đó:

- x_i : - Văn bản phản hồi thứ i của sinh viên.
 - y_i : - Nhãn cảm xúc (Sentiment) tương ứng, $y_i \in \{Negative, Neutral, Positive\}$.
 - z_i : - Tập nhãn chủ đề (Topic) tương ứng, $z_i \subseteq \{Lecturer, Program, Facility, Others\}$.

Mục tiêu: Xây dựng một hàm ánh xạ $f(x)$ để dự đoán đồng thời nhãn cảm xúc $\hat{y}$ và tập nhãn chủ đề $\hat{z}$ cho một văn bản đầu vào mới x , đồng thời tối thiểu hóa hàm mất mát tổng hợp trên hai tác vụ.

3.2.1 Bài toán phân loại cảm xúc (Single-label Classification)

Bài toán phân loại cảm xúc trong đề tài này được định nghĩa là bài toán phân loại đơn nhãn đa lớp (Multi-class Single-label Classification). Với mỗi bình luận đầu vào x , mô hình cần dự đoán một nhãn duy nhất y thuộc tập nhãn $C = \{0: Negative, 1: Neutral, 2: Positive\}$

Mô hình sẽ học một hàm ánh xạ $f: x \rightarrow R^{|C|}$ để tính toán phân phối xác suất $P(y|x)$. Nhãn dự đoán $\hat{y}$ được chọn là nhãn có xác suất cao nhất:

$$\hat{y} = \underset{y \in C}{\operatorname{argmax}} P(y|x)$$

Hàm kích hoạt: Sử dụng Softmax ở lớp cuối cùng để chuẩn hóa đầu ra thành xác suất.

Hàm mất mát: Sử dụng Cross-Entropy Loss, giúp tối thiểu hóa sự khác biệt giữa phân phối dự đoán và nhãn thực tế.

3.2.2 Bài toán phân loại chủ đề (Multi-label Classification)

Khác với phân loại cảm xúc, phân loại chủ đề là bài toán đa nhãn (Multi-label Classification). Một bình luận có thể thuộc nhiều chủ đề cùng lúc (ví dụ: vừa nói về "Giảng viên", vừa nói về "Cơ sở vật chất"). Tập nhãn $T = \{Lecturer, Training Program, Facility, Others\}$.

- **Đầu ra:** Mỗi nhãn $t \in T$ có một xác suất độc lập thuộc khoảng $[0, 1]$.
- **Hàm kích hoạt:** Sử dụng hàm **Sigmoid** cho từng node đầu ra, cho phép mô hình dự đoán xác suất độc lập theo phân phối Bernoulli:

$$P(t | x) = \sigma(z_t) = \frac{1}{1 + e^{-z_t}}, \forall t \in T$$

- **Hàm mất mát:** Sử dụng **BCEWithLogitsLoss** (Binary Cross Entropy kết hợp Logits).

$$\mathcal{L}(x, y) = - \sum_{t \in T} [y_t \cdot \log \sigma(z_t) + (1 - y_t) \cdot \log (1 - \sigma(z_t))]$$

- **Cơ chế quyết định:** Mặc định ngưỡng phân loại là 0.5. Tuy nhiên, để tối ưu hóa chỉ số F1-Score cho từng chủ đề, nhóm thực hiện kỹ thuật Tinh chỉnh ngưỡng (Threshold Tuning) trên tập Validation thay vì sử dụng ngưỡng cứng nhắc.

$$\hat{y}_t = \begin{cases} 1 & \text{nếu } P(t | x) \geq 0.5 \\ 0 & \text{nếu } P(t | x) < 0.5 \end{cases}$$

3.3 Các chỉ số đánh giá mô hình

3.3.1 Các chỉ số Accuracy, Precision, Recall, F1 score

Để đánh giá hiệu năng, nhóm sử dụng bộ chỉ số tiêu chuẩn. Đặc biệt, do dữ liệu có sự mất cân bằng (lớp Neutral và Facility chiếm thiểu số), chỉ số Accuracy không phản ánh đúng thực tế. Nhóm tập trung vào F1-Score – trung bình điều hòa giữa Precision và Recall.

- **Precision:**

$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Recall:**

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **F1-Score:**

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Trong bài toán đa lớp, F1-Score được tính theo hai phương pháp

- **Macro Average:** Tính F1 cho từng lớp rồi lấy trung bình cộng, coi trọng tầm quan trọng của các lớp thiểu số (đây là chỉ số quan trọng nhất trong bài toán này).

$$F1_{\text{macro}} = \frac{1}{|C|} \sum_{i=1}^{|C|} F1_i$$

- **Weighted Average:** Tính trung bình F1 có trọng số dựa trên số lượng mẫu của từng lớp, phản ánh hiệu năng tổng thể trên toàn bộ tập dữ liệu.

$$F1_{\text{weighted}} = \frac{1}{N} \sum_{i=1}^{|C|} n_i \cdot F1_i$$

với n_i là số lượng mẫu của lớp i , N là tổng số mẫu.

3.3.2 Ma trận nhầm lẫn (Confusion Matrix)

Ma trận nhầm lẫn được sử dụng để trực quan hóa kết quả dự đoán, giúp nhóm phân tích xem mô hình đang bị nhầm lẫn ("confused") giữa các cặp lớp nào. Ví dụ: Liệu mô hình có thường xuyên dự đoán nhầm từ *Negative* sang *Neutral* hay không.

3.3.3 Các chỉ số đánh giá cho bài toán đa nhãn

Đối với bài toán phân loại chủ đề (Multi-label), nhóm sử dụng các chỉ số chuyên biệt:

- **Hamming Loss:** Đo lường tỷ lệ các nhãn bị dự đoán sai trên tổng số nhãn. Giá trị càng thấp càng tốt. Ưu điểm của chỉ số này là tính toán trực tiếp trên từng label.

$$\text{Hamming Loss} = \frac{1}{N \cdot |T|} \sum_{i=1}^N \sum_{t \in T} \mathbf{1}[\hat{y}_{i,t} \neq y_{i,t}]$$

với N là số mẫu, $|T|$ là số nhãn, $\mathbf{1}[\cdot]$ là hàm chỉ thị.

- **Jaccard Score:** Đo độ tương đồng giữa tập nhãn dự đoán và tập nhãn thực tế dựa trên giao và hợp của chúng.

$$\text{Jaccard}(y, \hat{y}) = \frac{|y \cap \hat{y}|}{|y \cup \hat{y}|}$$

Chỉ số càng cao càng thể hiện mô hình dự đoán chính xác hơn.

3.3.4 Đường cong ROC và chỉ số AUC (tùy chọn)

- **ROC Curve (Receiver Operating Characteristic Curve):** Biểu diễn mối quan hệ giữa **True Positive Rate (TPR)** và **False Positive Rate (FPR)** tại các ngưỡng (threshold) khác nhau.

$$\text{TPR} = \frac{TP}{TP + FN}, \text{FPR} = \frac{FP}{FP + TN}$$

- **AUC (Area Under the Curve):** Đo diện tích dưới đường cong ROC. Giá trị AUC càng gần 1 càng cho thấy mô hình có khả năng phân tách tốt giữa các lớp.

3.4 Các kỹ thuật tiền xử lý dữ liệu

Dữ liệu phản hồi của sinh viên thường mang tính tự do, chứa nhiều nhiễu đặc thù của ngôn ngữ mạng xã hội và môi trường giáo dục. Để tối ưu hóa hiệu suất cho mô hình Transformer, nhóm áp dụng quy trình tiền xử lý nghiêm ngặt qua các bước:

- **Lọc nhiễu kỹ thuật:** Sử dụng biểu thức chính quy (Regex) để loại bỏ các thành phần không mang giá trị ngữ nghĩa như URL, Email, thẻ HTML và các chuỗi ký tự rác (spam).
- **Chuẩn hóa văn bản:** Chuyển đổi toàn bộ văn bản về bảng mã **Unicode dạng sẵn (NFC)** để tránh lỗi font, chuyển về chữ thường (lowercase) và chuẩn hóa khoảng trắng.
- **Xử lý ngôn ngữ đặc thù (Teencode & Slang):** Nhóm xây dựng bộ quy tắc chuẩn hóa các từ lóng và từ viết tắt phổ biến (ví dụ: "*ko*" $\rightarrow$ "*không*", "*gv*" $\rightarrow$ "*giảng viên*") giúp mô hình nắm bắt từ vựng chính xác hơn.
- **Tách từ (Word Segmentation):** Nhóm sử dụng thư viện **Underthesea**.
 - **Lý do:** Tiếng Việt là ngôn ngữ đơn âm tiết nhưng từ vựng lại đa âm tiết. Việc tách từ chính xác (ví dụ: "*sinh_viên*", "*học_phần*") giúp mô hình PhoBERT hiểu đúng thực thể thay vì xử lý các âm tiết đơn lẻ, vốn có thể làm sai lệch ngữ nghĩa.

Bảng 3.4. Bảng so sánh dữ liệu trước và sau khi tiền xử lý.

STT	Trước tiền xử lý (Raw Input)	Sau tiền xử lý (Preprocessed Output)	Phân tích biến đổi (Analysis)
1	"Thầy giảng bài	thầy giảng_bài	Word Segmentation: Gộp các âm tiết

	rất nhiệt tình và dễ hiểu <3. Tuy nhiên, tài liệu bị lỗi font."	nhiệt_tình dễ_hiểu tuy_nhiên tài_liệu bị lỗi font	thành từ ghép có nghĩa (<i>giảng_bài, nhiệt_tình</i>); Emoji : Xử lý biểu tượng cảm xúc; Stopwords : Giữ lại các từ nối (<i>tuy_nhiên, và</i>) để bảo toàn cấu trúc ngữ cảnh cho cơ chế Attention.
2	"gv ko support sinh viên gì cả. chấm điểm gắt."	giảng_viên không hỗ_trợ sinh_viên chấm điểm gắt	Normalization : Chuyển đổi từ viết tắt (<i>gv</i> → <i>giảng_viên</i>), teencode (<i>ko</i> → <i>không</i>) và thuật ngữ tiếng Anh (<i>support</i> → <i>hỗ_trợ</i>) về tiếng Việt chuẩn để khớp với từ điển của PhoBERT.
3	"Phòng thực hành B.12 máy lạnh hư rồi!!! Nóng kinh khủng."	phòng thực_hành máy_lạnh hư nóng kinh_khủng	Cleaning : Loại bỏ các dấu câu thừa (!!!) và định danh phòng học cụ thể (<i>B.12</i>) để giảm nhiễu, nhưng vẫn giữ lại các từ mang sắc thái tiêu cực cốt lõi (<i>hư, nóng</i>) phục vụ việc phân loại cảm xúc.

3.5 Các mô hình Transformer và BERT cho tiếng Việt

3.5.1 Kiến trúc tổng quan của Transformer


Kiến trúc Transformer được giới thiệu nhằm khắc phục những hạn chế cố hữu của các mô hình dòng RNN/LSTM, đặc biệt là vấn đề **triệt tiêu đạo hàm (gradient vanishing)** và khả năng xử lý song song kém khi đối mặt với các phụ thuộc xa (long-range dependencies) trong văn bản.

Transformer vận hành dựa trên cơ chế Self-Attention, bao gồm hai khối chính:

- **Khối Encoder:** Nhiệm vụ chính là trích xuất đặc trưng và tạo ra vector đại diện (representation) cho từng token trong sự tương quan với toàn bộ các từ còn lại trong câu.
- **Khối Decoder:** Sử dụng thông tin từ Encoder để sinh dữ liệu đầu ra theo trình tự.

Các thành phần quan trọng trong kiến trúc Transformer:

- **Multi-Head Attention:** Thay vì có một attention duy nhất, mô hình xử lý song song, mỗi head học cách chú ý khác nhau, sau đó kết hợp lại với nhau.
- **Masked Multi-Head Attention:** Trong khối decoder, sử dụng phương pháp masking để không cho các mô hình nhìn thấy từ phía sau, việc này giúp mô hình sinh từ tuần tự theo đúng hướng
- **Positional Encoding:** Transformer không có cơ chế tuần tự như RNN nên cần khối này để mã hóa vị trí, dùng hàm $\sin/\cos$ để thêm thông tin vị trí vào vector đầu vào. Tuy có hai khối là encoder và decoder, một các mô hình nổi tiếng hiện nay chỉ sử dụng một trong hai khối tùy vào cách ứng dụng của mô hình
- **BERT:** Chỉ sử dụng khối encoder để áp dụng vào bài toán phân loại văn bản, trích xuất thông tin hay trả lời câu hỏi.
- **GPT:** Chỉ sử dụng khối Decoder, áp dụng vào bài toán tạo sinh.



Hình 3.5.1. Kiến trúc Transformer.

3.5.2 Các mô hình BERT và Cơ sở lựa chọn

BERT (Bidirectional Encoder Representations from Transformers) là framework học máy mã nguồn mở được giới thiệu bởi Google AI năm 2018. Khác với các mô hình đọc hiểu văn bản truyền thống (trái qua phải hoặc phải qua trái), BERT sử dụng cơ chế Attention để đọc toàn bộ câu cùng một lúc (hai chiều), giúp nắm bắt ngữ cảnh sâu sắc hơn.

Để giải quyết bài toán phân tích phản hồi sinh viên (UIT-VSFC) với đặc thù tiếng Việt, nhóm nghiên cứu đã khảo sát và quyết định lựa chọn các mô hình tiền huấn luyện sau làm nòng cốt thực nghiệm:

- **PhoBERT-base (Mô hình chủ đạo):**

- **Thông số:** Sử dụng kiến trúc RoBERTa với 12 lớp Transformer, 768 hidden units và 12 attention heads. Mô hình được huấn luyện trên 20GB dữ liệu văn bản tiếng Việt không gán nhãn (Wikipedia, báo chí).
- **Lý do lựa chọn:** Đây là mô hình SOTA (State-of-the-art) cho tiếng Việt. Lý do quan trọng nhất nhóm chọn PhoBERT là vì mô hình này áp dụng kỹ thuật

tách từ (Word Segmentation) trước khi đưa vào huấn luyện (khác với BERT gốc dùng WordPiece). Điều này cực kỳ phù hợp với bài toán đánh giá môn học, nơi xuất hiện nhiều từ ghép chuyên ngành giáo dục (ví dụ: "*tín_chi*", "*học_phần*", "*giảng_viên*") mà nếu tách rời sẽ mất đi ngữ nghĩa chính xác.

- **mBERT (Mô hình đối chứng đa ngữ):**

- **Thông số:** bert-base-multilingual-cased, được huấn luyện bởi Google trên Wikipedia của 104 ngôn ngữ (bao gồm tiếng Việt).
- **Lý do xem xét:** Nhóm muốn so sánh hiệu năng giữa một mô hình "đa năng" (học từ dữ liệu toàn cầu) và một mô hình "chuyên sâu" (PhoBERT - chỉ học tiếng Việt). Việc sử dụng mBERT giúp kiểm chứng xem liệu kiến thức ngôn ngữ học đặc thù của PhoBERT có thực sự mang lại ưu thế vượt trội so với mô hình đa ngữ phổ biến hay không.

3.5.3 Biểu diễn vector và chiến lược Pooling

Nhóm sử dụng vector đặc trưng của token đặc biệt đầu câu (<s> hoặc [CLS]) tại lớp ẩn cuối cùng làm vector đại diện ngữ nghĩa cho toàn bộ câu. Điểm đặc biệt là việc triển khai kiến trúc Đa nhiệm (Multitask Learning):

Vector đặc trưng này được đưa vào hai lớp Tuyến tính song song (Parallel Linear Layers):

- **Sentiment Head:** Dự đoán 3 nhãn cảm xúc qua hàm Softmax.
- **Topic Head:** Dự đoán đồng thời 4 nhãn chủ đề qua hàm Sigmoid và cơ chế ngưỡng (Thresholding).

Việc học đa nhiệm giúp mô hình chia sẻ thông tin giữa cảm xúc và chủ đề, giúp cải thiện độ chính xác tổng thể và tối ưu hóa thời gian tính toán.

3.6 Các mô hình Baseline

Để thiết lập mức chuẩn cơ sở (Baseline), nhóm sử dụng phương pháp thống kê truyền thống kết hợp với thuật toán hồi quy:

- **TF-IDF:** Trích xuất đặc trưng văn bản dựa trên tần suất từ, giúp làm nổi bật các từ khóa quan trọng.
- **Logistic Regression (Hồi quy Logistic):**
 - **Lý do chọn:** Đây là thuật toán phân loại tuyến tính mạnh mẽ, dễ diễn giải và thường hoạt động rất tốt với các đặc trưng thưa (sparse features) từ TF-IDF. Nhóm sử dụng chiến lược **One-Vs-Rest** để xử lý bài toán đa nhãn (cho phần Chủ đề). Kết quả của Logistic Regression là mốc so sánh (benchmark) để đánh giá mức độ cải thiện của các mô hình Deep Learning.

CHƯƠNG 4. THỰC NGHIỆM VÀ KẾT QUẢ

4.1 Thiết lập môi trường thực nghiệm

Thực nghiệm được triển khai trên nền tảng Google Colab, tận dụng tài nguyên tính toán đám mây để hỗ trợ huấn luyện mô hình học sâu với GPU. Môi trường này cho phép xử lý dữ liệu lớn và tối ưu hóa thời gian huấn luyện mà không yêu cầu hạ tầng cục bộ mạnh mẽ.

- **Phần cứng:** Sử dụng GPU T4 (16GB VRAM) với hỗ trợ CUDA để tăng tốc các phép tính tensor trong PyTorch và Transformers.
- **Ngôn ngữ lập trình: Python 3.10**, đảm bảo tính tương thích với các thư viện cốt lõi.
- **Các thư viện nòng cốt:**
 - **Xử lý ngôn ngữ tự nhiên:** underthesea (tách từ tiếng Việt), emoji, re.
 - **Học sâu:** torch (PyTorch), transformers (Hugging Face) để tải và fine-tune PhoBERT/mBERT.
 - **Học máy cơ bản:** scikit-learn cho TF-IDF, Logistic Regression và các metrics đánh giá.
 - **Xử lý dữ liệu:** pandas, numpy.
- **Cấu hình:** Môi trường được cấu hình với seed ngẫu nhiên (random_state=42) để đảm bảo tính tái lập kết quả thực nghiệm.

Mã nguồn thiết lập và cấu hình đường dẫn:

Đoạn mã này định nghĩa các đường dẫn thư mục quan trọng, giúp tổ chức dự án một cách khoa học, tách biệt giữa dữ liệu thô, dữ liệu đã xử lý và các mô hình đầu ra.

```
import os
import random, numpy as np, torch
```



```

# Thiết lập hạt giống ngẫu nhiên (Seed) để đảm bảo tính tái lập (Reproducibility)
# Việc này cực kỳ quan trọng trong nghiên cứu khoa học để người khác có thể tạo ra kết
quả y hệt.
def set_seed(seed=42):
    random.seed(seed)
    np.random.seed(seed)
    torch.manual_seed(seed)
    torch.cuda.manual_seed_all(seed)
set_seed(42)

# Thiết lập đường dẫn dự án
PROJECT_ROOT = os.path.abspath("..")
PATHS = {
    "train_csv": os.path.join(PROJECT_ROOT, "datasets", "processed", "train.csv"),
    "val_csv": os.path.join(PROJECT_ROOT, "datasets", "processed", "validation.csv"),
    "test_csv": os.path.join(PROJECT_ROOT, "datasets", "processed", "test.csv"),
    "metrics": os.path.join(PROJECT_ROOT, "outputs", "metrics"),
    "figures": os.path.join(PROJECT_ROOT, "outputs", "figures"),
    "preds": os.path.join(PROJECT_ROOT, "outputs", "output_data"),
}

# Kiểm tra thiết bị tính toán
DEVICE = "cuda" if torch.cuda.is_available() else "cpu"

```

4.2 Cài đặt các phương pháp tiền xử lý dữ liệu

Dữ liệu đầu vào từ các bình luận của sinh viên thường chứa nhiều nhiễu như lỗi chính tả, viết tắt (teencode), emoji, và các ký tự đặc biệt. Do đó, một pipeline tiền xử lý mạnh mẽ là yếu tố then chốt để mô hình hiểu đúng ngữ nghĩa.

4.2.1 Tải và làm sạch dữ liệu

Thay vì sinh dữ liệu nhân tạo, nhóm sử dụng bộ dữ liệu chuẩn UIT-VSFC được tải trực tiếp từ các nguồn lưu trữ đảm bảo. Dữ liệu được chia thành 3 tập: Train (Huấn luyện), Validation (Tinh chỉnh) và Test (Kiểm thử).

Mã nguồn tải dữ liệu:

Đoạn mã này sử dụng thư viện requests để tải dữ liệu từ Google Drive, đảm bảo dữ liệu luôn sẵn sàng và nhất quán mỗi lần chạy thực nghiệm.

```
SPLIT_URLS: Dict[str, Dict[str, str]] = {
    "train": { ... }, "validation": { ... }, "test": { ... }
}
def download_text(url: str, destination: Path) -> Path:
    if destination.exists(): return destination
    response = requests.get(url, timeout=60)
    response.raise_for_status()
    destination.write_bytes(response.content)
    return destination
```

4.2.2 Phương pháp tiền xử lý văn bản (Preprocessing Pipeline)

Pipeline xử lý văn bản được thiết kế tỉ mỉ để giải quyết các vấn đề đặc thù của tiếng Việt và ngôn ngữ mạng xã hội.

4.2.2.2. Chuẩn hóa văn bản cơ bản

Hàm preprocess_vì thực hiện một chuỗi các thao tác làm sạch:

- **Loại bỏ nhiễu:** Xóa các thẻ HTML, đường dẫn URL và Emoji bằng biểu thức chính quy (Regex). Emoji tuy mang cảm xúc nhưng thường gây nhiễu cho các mô hình BERT nếu không được xử lý kỹ.

- **Chuẩn hóa từ viết tắt (Teencode):** Đây là bước quan trọng nhất. Từ điển ABBR được xây dựng để map các từ như "ko", "k", "kh" về "không"; "th" về "thầy". Nếu không có bước này, mô hình sẽ coi "ko" là một từ lạ (unknown token) và mất đi ngữ nghĩa phủ định quan trọng.

Mã nguồn chuẩn hóa:

```
ABBR = {
    "ko": "không", "k": "không", "kh": "không", "hok": "không", "k0": "không",
    "bt": "bình thường", "ok": "ồ", "dc": "được", "đc": "được", "vs": "với",
    "th": "thầy", "gv": "giảng viên", "sv": "sinh viên"
}

def expand_abbr(text: str) -> str:
    tokens = str(text).split()
    tokens = [ABBR.get(t.lower(), t) for t in tokens]
    return " ".join(tokens)

def preprocess_vi(text: str, do_segment: bool = False) -> str:
    text = str(text)
    text = remove_html(text) # Xóa HTML
    text = remove_url(text) # Xóa URL
    text = remove_emoji(text) # Xóa Emoji
    text = expand_abbr(text) # Bung từ viết tắt
    text = normalize_spaces(text) # Chuẩn hóa khoảng trắng
    if do_segment and USE_WORD_SEGMENT:
        text = word_tokenize(text, format="text")
    return text
```

4.2.2.3 Tách từ tiếng Việt (Word Segmentation)

Tiếng Việt là ngôn ngữ đơn lập, ý nghĩa thường nằm ở cụm từ ghép (ví dụ: "sinh viên", "giảng viên"). Nếu không tách từ, mô hình sẽ hiểu lầm "sinh viên" là hai từ rời rạc "sinh" và "viên". Nhóm sử dụng thư viện `underthesea` để nối các từ ghép bằng dấu gạch dưới (vd: "sinh_viên"), giúp PhoBERT tận dụng tối đa kiến thức đã học từ dữ liệu tiền huấn luyện.

4.2.2.4 Mã hóa nhãn (Label Encoding)

Để phục vụ bài toán đa nhiệm (Multi-task), nhãn dữ liệu cần được chuyển đổi sang định dạng số học:

- **Sentiment:** Ánh xạ sang số nguyên: 0 (Negative), 1 (Neutral), 2 (Positive).
- **Topic:** Sử dụng **One-Hot Encoding** để tạo ra vector nhị phân độ dài 4 (tương ứng 4 chủ đề). Một mẫu có thể có vector [1, 0, 1, 0] nghĩa là thuộc cả chủ đề 0 và 2.

Mã nguồn mã hóa nhãn Topic:

```
def to_onehot_topic(topic_id, num_topics=NUM_TOPICS):  
    vec = np.zeros(num_topics, dtype=np.float32)  
    vec[int(topic_id)] = 1.0  
    return vec  
  
# Áp dụng cho toàn bộ DataFrame  
train_df["topic_vec"] = train_df["topic_id"].apply(to_onehot_topic)
```

4.3 Cài đặt mô hình Baseline (Cơ sở)

Để thiết lập một mức chuẩn (benchmark) nhằm đánh giá hiệu quả thực sự của các mô hình Deep Learning phức tạp, nhóm xây dựng mô hình Baseline sử dụng phương pháp học máy truyền thống nhưng hiệu quả: TF-IDF kết hợp với Logistic Regression.

4.3.1 Cài đặt TF-IDF và tham số huấn luyện

Việc chuyển đổi văn bản sang vector đặc trưng sử dụng TF-IDF. Nhóm cấu hình `ngram_range=(1, 2)` để mô hình bắt được cả các cụm 2 từ (bigram) quan trọng như "không tốt", "rất hay". Giới hạn `max_features` giúp loại bỏ các từ quá hiếm, giảm nhiễu và tăng tốc độ tính toán.

Mã nguồn Vectorizer:

```
from sklearn.feature_extraction.text import TfidfVectorizer

tfidf = TfidfVectorizer(
    ngram_range=(1,2), # Bắt cả từ đơn và cụm 2 từ
    min_df=2, # Loại bỏ từ xuất hiện dưới 2 lần
    max_features=50000 # Giới hạn số lượng đặc trưng
)
Xtr = tfidf.fit_transform(X_train)
Xte = tfidf.transform(X_test)
```

4.3.2 Cài đặt mô hình phân loại (Classifier)

Đối với bài toán đa nhãn Topic, nhóm sử dụng chiến lược One-Vs-Rest (OvR). Chiến lược này huấn luyện 4 bộ phân loại nhị phân độc lập cho 4 chủ đề. Ví dụ, bộ phân loại cho chủ đề "Lecturer" sẽ học cách phân biệt "Có nói về giảng viên" hay "Không nói về giảng viên".

Mã nguồn Classifier:

```
from sklearn.linear_model import LogisticRegression
from sklearn.multiclass import OneVsRestClassifier
# Huấn luyện mô hình OneVsRest với Logistic Regression
```

```
clf = OneVsRestClassifier(LogisticRegression(max_iter=2000))
clf.fit(Xtr, y_train_oh)
# Dự đoán xác suất và áp dụng ngưỡng cắt cứng 0.5
prob_lr = clf.predict_proba(Xte)
pred_lr = (prob_lr >= 0.5).astype(int)
```

Phân tích: Mặc dù đơn giản, Baseline này cho kết quả khá tốt với Topic ($F1 \sim 0.78$) nhưng lại kém ở Sentiment do không nắm bắt được ngữ cảnh phức tạp và các từ đa nghĩa.

4.4. Cài đặt mô hình BERT/PhoBERT (Multi-task Learning)

Đây là trái tim của đề án. Nhóm sử dụng mô hình ngôn ngữ tiền huấn luyện PhoBERT làm "xương sống" (backbone) để trích xuất đặc trưng ngữ cảnh, sau đó chia làm hai nhánh (heads) để giải quyết đồng thời hai bài toán Sentiment và Topic.

4.4.1 Cài đặt Tokenizer

Sử dụng AutoTokenizer từ thư viện transformers. Hàm encode_plus thực hiện đồng thời việc tokenize, thêm token đặc biệt <s>, </s>, padding về độ dài cố định và tạo attention_mask để mô hình bỏ qua các token đệm.

4.4.2 Kiến trúc mạng Multi-task và Hàm lỗi

Nhóm tự định nghĩa lớp MultiTaskModel kế thừa từ nn.Module.

- **Shared Encoder:** Sử dụng PhoBERT để tạo ra vector đại diện cho câu (vector tại vị trí [CLS]).
- **Task-specific Heads:**
 - **Sentiment Head:** Lớp Linear + Softmax (ẩn trong hàm loss CrossEntropy) cho bài toán đơn nhãn.
 - **Topic Head:** Lớp Linear + Sigmoid (ẩn trong hàm loss BCEWithLogits) cho bài toán đa nhãn.

- **Loss Function:** Trong mô hình kết hợp hai nhánh (phân loại cảm xúc và phân loại chủ đề), hàm mất mát tổng hợp được định nghĩa:

$$Loss = Loss_{sent} + \alpha \cdot Loss_{topic}$$

Trong đó:

- $Loss_{sent}$: Hàm mất mát cho nhánh phân loại cảm xúc.
- $Loss_{topic}$: Hàm mất mát cho nhánh phân loại chủ đề.
- α : Hệ số điều chỉnh (hyperparameter) để cân bằng mức độ ảnh hưởng giữa hai nhánh

Mã nguồn mô hình Multi-task:

```
class MultiTaskModel(nn.Module):
    def __init__(self, encoder_name, n_sent, n_topic, dropout=0.1, alpha=1.0):
        super().__init__()
        self.encoder = AutoModel.from_pretrained(encoder_name)
        self.drop = nn.Dropout(dropout)

        # Hai nhánh đầu ra riêng biệt
        self.sent_head = nn.Linear(self.encoder.config.hidden_size, n_sent)
        self.topic_head = nn.Linear(self.encoder.config.hidden_size, n_topic)

        self.ce = nn.CrossEntropyLoss() # Cho Sentiment
        self.bce = nn.BCEWithLogitsLoss() # Cho Topic (Đa nhãn)
        self.alpha = alpha # Trọng số cân bằng

    def forward(self, input_ids=None, attention_mask=None, sentiment_id=None,
                topic_vec=None, **kwargs):
        outputs = self.encoder(input_ids=input_ids, attention_mask=attention_mask)
        cls = self.drop(outputs.last_hidden_state[:, 0]) # Lấy vector CLS
```

```
sent_logits = self.sent_head(cls)
topic_logits = self.topic_head(cls)

loss = None
if sentiment_id is not None and topic_vec is not None:
    # Tính toán và tổng hợp Loss
    loss_sent = self.ce(sent_logits, sentiment_id)
    loss_topic = self.bce(topic_logits, topic_vec)
    loss = loss_sent + self.alpha * loss_topic
    return {"loss": loss, "sent_logits": sent_logits, "topic_logits": topic_logits}
```

4.4.3 Lựa chọn siêu tham số (Hyperparameters)

Các tham số được tinh chỉnh dựa trên tài nguyên phần cứng (GPU T4 16GB):

- Batch Size = 32: Tận dụng tối đa VRAM.
- Learning Rate = 1e-5: Tốc độ học nhỏ để tránh phá vỡ trọng số đã tiền huấn luyện (Catastrophic Forgetting).
- Optimizer = AdamW: Tối ưu hóa với trọng số suy giảm (weight decay) giúp chống quá khớp.

4.4.4 Hậu xử lý kết quả và Hiệu chỉnh ngưỡng (Threshold Tuning)

Đối với bài toán đa nhãn, việc chọn ngưỡng (threshold) 0.5 mặc định thường không tối ưu.

Nhóm đã thực hiện kỹ thuật Threshold Sweep (quét ngưỡng) trên tập Validation để tìm ra ngưỡng BEST_TH giúp tối đa hóa điểm F1-Micro.

Mã nguồn quét ngưỡng:

```
def apply_threshold(prob, th):
```



```

pred = (prob >= th).astype(int)
# Fallback: Nếu không nhãn nào vượt ngưỡng, chọn nhãn có xác suất cao nhất
for i in range(len(pred)):
    if pred[i].sum() == 0:
        pred[i, int(prob[i].argmax())] = 1
return pred

# Quét các giá trị từ 0.1 đến 0.9 để tìm ngưỡng tối ưu
ths = np.round(np.arange(0.10, 0.91, 0.05), 2)
# ... (vòng lặp tính F1 tại mỗi ngưỡng và lưu lại kết quả tốt nhất)

```

4.4.5 Minh họa luồng xử lý (One-sample Walkthrough)

Để làm rõ cơ chế hoạt động, nhóm xây dựng hàm `walkthrough_one_sample` in ra chi tiết từng bước xử lý của một mẫu dữ liệu thực tế.

Mã nguồn minh họa:

```

def walkthrough_one_sample(text, tokenizer, model, threshold=0.35):
    # 1. Tiền xử lý & Tokenize
    text2 = preprocess_vi(text, do_segment=DO_SEGMENTATION)
    enc = tokenizer(text2, return_tensors="pt", ...)

    # 2. Forward qua Model
    with torch.no_grad():
        out = model(**enc)

    # 3. Giải mã kết quả Sentiment (Softmax)
    sent_prob = np.exp(out["sent_logits"]) / np.exp(out["sent_logits"]).sum()

```

4. Giải mã kết quả Topic (Sigmoid + Threshold)

```
topic_prob = 1 / (1 + np.exp(-out["topic_logits"]))  
y_pred = (topic_prob >= threshold).astype(int)  
  
return sent_prob, topic_prob, y_pred
```

Để kiểm chứng khả năng hiểu ngữ cảnh và cơ chế hoạt động của mô hình, nhóm thực hiện truy vết (trace) chi tiết quá trình xử lý trên một mẫu dữ liệu thực tế có tính chất đa nhân và cảm xúc tiêu cực.

Mẫu thử nghiệm: *"Phòng học nóng quá, máy lạnh hư mà thầy giảng hơi nhanh."*

Quá trình xử lý qua các tầng của mô hình diễn ra như sau:

- **Bước 1: Tiền xử lý và Tokenize** Văn bản được làm sạch và tách thành các token (đơn vị từ). Lưu ý các token đặc biệt <s> (bắt đầu) và <pad> (đệm) được thêm vào để đảm bảo độ dài đầu vào cố định.

=== 1) Raw text ===

Phòng học nóng quá, máy lạnh hư mà thầy giảng hơi nhanh.

=== 2) Preprocessed text ===

Phòng học nóng quá, máy lạnh hư mà thầy giảng hơi nhanh.

=== 3) Tokenize ===

Decoded tokens[:24] = ['<s>', 'Phòng', 'học', 'nóng', 'quá@@', ',', 'máy', 'lạnh', 'hư', 'mà', 'thầy', 'giảng', 'hơi', 'nha@@', 'nh.', '</s>', '<pad>', ...]

Input IDs[:32] = [0, 1119, 222, 898, 20027, 4, 558, 1310, 6007, 64, 1249, 5415, 1329, 37361, 18109, 2, 1, ...]

- **Bước 2: Trích xuất đặc trưng (Encoding)** Chuỗi ID được đưa qua 12 lớp Transformer của PhoBERT. Vector tại vị trí đầu tiên (CLS token) được trích xuất làm đại diện ngữ nghĩa cho toàn bộ câu.

=== 4) Encoder output & CLS embedding ===

CLS shape = (1, 768)

CLS first 10 dims = [-0.256 0.321 0.073 0.072 -0.282 0.226 0.813 -0.653 0.343 -0.241]

- **Bước 3: Dự đoán Cảm xúc (Sentiment Head)** Vector CLS đi qua lớp Linear và hàm Softmax. Mô hình xác định cảm xúc **Negative** với độ tin cậy tuyệt đối (~99.57%), phản ánh đúng sự phàn nàn về cơ sở vật chất và tốc độ giảng.

=== 5) Sentiment head (softmax) ===

Probabilities: [Negative: 0.9957, Neutral: 0.0023, Positive: 0.0021]

=> Kết quả: Negative

- **Bước 4: Dự đoán Chủ đề (Topic Head)** Vector CLS đi qua lớp Linear và hàm Sigmoid độc lập cho 4 nhãn. Với ngưỡng cắt (threshold) được tinh chỉnh là **0.35**, mô hình kích hoạt thành công 2 nhãn:

1. **Lecturer (0.5383):** Từ khóa "thầy giảng".
2. **Facility (0.4584):** Từ khóa "phòng học", "máy lạnh".

=== 6) Topic head (sigmoid + threshold) ===

Probabilities: [Lecturer: 0.5383, Program: 0.0387, Facility: 0.4584, Others: 0.0405]

Thresholds : [0.35, 0.35, 0.35, 0.35]

=> Kết quả: ['lecturer', 'facility']

Nhận xét: Kết quả thực nghiệm cho thấy mô hình Multi-task PhoBERT hoạt động chính xác ngay cả với các câu ghép phức tạp, nhận diện đúng đa chủ đề (Multi-topic) và cảm xúc chủ đạo mà không bị nhiễu bởi các từ nối.

4.5 THỰC NGHIỆM FINE-TUNING

Quy trình huấn luyện (Fine-tuning) được thực hiện trên môi trường GPU T4 với sự giám sát chặt chẽ các chỉ số hiệu năng. Nhóm áp dụng chiến lược Early Stopping để tối ưu hóa thời gian và ngăn chặn hiện tượng quá khớp (Overfitting).

4.5.1 Chuẩn bị dữ liệu và kiểm định chất lượng đầu vào

Dữ liệu sau khi tiền xử lý được chuyển đổi sang định dạng Dataset của thư viện Hugging Face. Nhóm thực hiện kiểm tra kích thước các tập dữ liệu trước khi đưa vào DataLoader để đảm bảo tính toàn vẹn.

Mã nguồn chuẩn bị dữ liệu:

```
from datasets import Dataset
from transformers import DataCollatorWithPadding

# Chuyển đổi DataFrame sang Dataset
train_ds = Dataset.from_pandas(train_df[["text", "sentiment_id", "topic_vec"]])
val_ds = Dataset.from_pandas(val_df[["text", "sentiment_id", "topic_vec"]])

# Tokenize dữ liệu với độ dài cố định
def tok(batch):
    return tokenizer(batch["text"], truncation=True, max_length=256)

train_ds_tok = train_ds.map(tok, batched=True)
val_ds_tok = val_ds.map(tok, batched=True)
```

```
# Sử dụng DataCollator để tự động padding theo batch
```

```
collator = DataCollatorWithPadding(tokenizer=tokenizer)
```

Việc sử dụng `DataCollatorWithPadding` giúp tối ưu hóa bộ nhớ GPU bằng cách chỉ padding đến chiều dài của câu dài nhất trong batch hiện tại, thay vì padding toàn bộ theo `max_length` cố định.

4.5.2 Fine-tuning PhoBERT cho phân loại cảm xúc (Sentiment Head)

Trong kiến trúc Multi-task, nhánh phân loại cảm xúc sử dụng vector đặc trưng [CLS] đi qua một lớp tuyến tính (Linear) để ánh xạ về 3 lớp (Negative, Neutral, Positive).

Cơ chế huấn luyện:

- Hàm kích hoạt: Softmax (tích hợp trong hàm Loss).
- Hàm mất mát: CrossEntropyLoss.
- Trọng số lớp (class weights): Được áp dụng để xử lý mất cân bằng dữ liệu, tăng mức phạt đối với các lớp hiếm.

```
# Trích xuất từ class MultiTaskModel
```

```
self.sent_head = nn.Linear(hidden_size, 3)
```

```
self.ce = nn.CrossEntropyLoss()
```

```
# Forward pass
```

```
sent_logits = self.sent_head(cls_embedding)
```

```
loss_sent = self.ce(sent_logits, sentiment_labels)
```

4.5.3 Fine-tuning đa nhãn chủ đề (Topic Head)

Nhánh phân loại chủ đề hoạt động độc lập với nhánh cảm xúc nhưng chia sẻ chung tầng Encoder. Đây là bài toán đa nhãn (Multi-label), do đó hàm kích hoạt ở đầu ra là Sigmoid thay vì Softmax.

Cơ chế huấn luyện:

- Hàm mất mát: BCEWithLogitsLoss (Binary Cross Entropy kết hợp Sigmoid).
- Tổng hợp Loss: Tổng loss của mô hình là tổng có trọng số của hai nhánh nhiệm vụ.
- Tổng loss của mô hình là tổng có trọng số của hai nhánh nhiệm vụ:

$$Loss_{total} = Loss_{sentiment} + \alpha \cdot Loss_{topic}$$

Trong thực nghiệm, nhóm chọn: $\alpha = 1.0$ nhằm cân bằng sự đóng góp của hai tác vụ (phân loại cảm xúc và phân loại chủ đề).

```
# Trích xuất từ class MultiTaskModel
self.topic_head = nn.Linear(hidden_size, 4)
self.bce = nn.BCEWithLogitsLoss()

# Forward pass
topic_logits = self.topic_head(cls_embedding)
loss_topic = self.bce(topic_logits, topic_labels)

# Tổng hợp Loss
loss = loss_sent + self.alpha * loss_topic
```

4.5.4 Chiến lược Huấn luyện và Tối ưu hóa (Full Fine-tuning)

Lưu ý: Do đặc thù mô hình PhoBERT-base (135M tham số) phù hợp với tài nguyên T4, nhóm áp dụng kỹ thuật Full Fine-tuning thay vì LoRA để đạt độ chính xác cao nhất.

Nhóm sử dụng Trainer API với cơ chế Early Stopping. Mô hình sẽ tự động dừng huấn luyện nếu chỉ số eval_loss trên tập Validation không giảm sau 2 epochs liên tiếp (patience=2).

Cấu hình huấn luyện:

```

from transformers import TrainingArguments, EarlyStoppingCallback

args = TrainingArguments(
    learning_rate=1e-5, # Tốc độ học nhỏ
    per_device_train_batch_size=16, # Batch size phù hợp GPU 16GB
    num_train_epochs=5, # Số vòng lặp tối đa
    weight_decay=0.01, # Giảm thiểu Overfitting
    save_strategy="epoch", # Lưu checkpoint mỗi epoch
    evaluation_strategy="epoch", # Đánh giá mỗi epoch
    load_best_model_at_end=True, # Luôn lấy mô hình tốt nhất
    metric_for_best_model="eval_loss"
)

# Callback dừng sớm
callbacks = [EarlyStoppingCallback(early_stopping_patience=2)]

```

4.5.5 So sánh chi phí và hiệu năng (Phân tích Nhật ký huấn luyện)

Dựa trên nhật ký huấn luyện (Training Logs) thực tế thu được từ quá trình chạy thực nghiệm, nhóm thực hiện so sánh chi tiết giữa hai mô hình:

Tiêu chí	PhoBERT (Multitask)	mBERT (Multitask)
Tổng thời gian (5 epochs)	~3 giờ 48 phút (13,712s)	~3 giờ 05 phút (11,122s)
Tốc độ xử lý	4.17 samples/giây	5.14 samples/giây
Hội tụ Loss (Train)	0.77 → 0.27	0.65 → 0.21

Hội tụ Loss (Eval)	0.46 $\rightarrow$ 0.37	0.39 $\rightarrow$ 0.36
---------------------------	-------------------------	-------------------------

Phân tích chuyên sâu:

- **Về tốc độ:** Trong thực nghiệm này, mBERT huấn luyện nhanh hơn PhoBERT (~3.1h so với ~3.8h). Nguyên nhân có thể do cấu trúc tokenizer của mBERT (WordPiece) khi xử lý dữ liệu sinh viên (chứa nhiều từ không chuẩn) tạo ra các sub-words ngắn hơn, hoặc do cài đặt DO_SEGMENTATION=False cho mBERT giúp giảm bớt chi phí tiền xử lý trong DataLoader.
- **Về độ hội tụ:** Cả hai mô hình đều cho thấy sự hội tụ tốt.
 - mBERT đạt train_loss thấp hơn (0.21) so với PhoBERT (0.27) ở epoch cuối, cho thấy khả năng khớp dữ liệu huấn luyện rất mạnh.
 - Tuy nhiên, eval_loss của cả hai khá tương đồng (quanh mức 0.36 - 0.37), chứng tỏ PhoBERT dù khớp chậm hơn nhưng khả năng tổng quát hóa (generalization) trên tập Validation là ngang ngửa, thậm chí ổn định hơn (tránh overfitting quá mức vào tập train).
- **Kết luận:** Dù mBERT nhanh hơn trong pha huấn luyện này, nhưng xét về khả năng hiểu ngữ nghĩa tiếng Việt đặc thù (như đã phân tích ở mục 4.4.5), PhoBERT vẫn là lựa chọn ưu tiên cho chất lượng dự đoán cuối cùng (F1-score).

4.5.6 Hạn chế và Hướng phát triển

Mặc dù đạt kết quả khả quan, nhóm nghiên cứu nhận thấy một số điểm cần cải thiện và mở rộng trong tương lai:

(1) **Về dữ liệu:** Dữ liệu Synthetic từ ChatGPT có văn phong khá chuẩn mực, chưa phản ánh hết sự đa dạng và "nhiều" của ngôn ngữ sinh viên thực tế.

- *Giải pháp:* Cần thu thập và gán nhãn thêm dữ liệu thực tế từ các kênh phi chính thức hoặc Confession.

(2) Tối ưu hóa mô hình: PhoBERT khá nặng nề để triển khai trên các hệ thống thời gian thực với chi phí thấp.

- *Giải pháp:* Nghiên cứu áp dụng kỹ thuật Model Distillation (Chưng cất mô hình) hoặc Quantization (Lượng tử hóa) để giảm kích thước mô hình.

(3) Mở rộng ứng dụng: Tích hợp Chatbot phản hồi tự động (Expert-Assistant)
Hiện tại hệ thống chỉ dừng lại ở việc phân loại. Trong giai đoạn tiếp theo, nhóm đề xuất phát triển module **Chatbot Trợ lý ảo** dựa trên kiến trúc "Chuyên gia - Trợ lý" (Expert-Assistant Architecture):

- **Cơ chế:** Kết hợp mô hình phân loại PhoBERT (Expert) để nhận diện chính xác vấn đề, sau đó chuyển kết quả cho một Mô hình Ngôn ngữ Lớn (như Llama 3 hoặc VinALLAMA) đóng vai trò "Trợ lý" để sinh câu trả lời tự động.
- **Lợi ích:** Giúp Phòng Đào tạo không chỉ nắm bắt vấn đề mà còn phản hồi sinh viên một cách nhanh chóng, thân thiện và chuyên nghiệp dựa trên các mẫu câu được sinh tự động, giảm tải khối lượng công việc thủ công. Nhóm đã thử nghiệm sơ bộ các kỹ thuật Prompt Engineering và Quantization 4-bit để chuẩn bị cho hướng đi này.

4.7 Phân tích kết quả thực nghiệm

4.7.1 Kết quả của các mô hình Baseline

- **Mục tiêu:** Đánh giá hiệu năng của phương pháp truyền thống (TF-IDF + Logistic Regression) để làm cơ sở so sánh.
- **Kết quả định lượng:**


```
{  
  "f1_micro": 0.8621395935087443,  
  "f1_macro": 0.6928334711062508,  
  "f1_samples": 0.8626026531901453,  
  "hamming": 0.06909349336702464,
```

```
"jaccard_samples": 0.8618130132659507
}
```

- **Nhận xét:** Mô hình Baseline hoạt động tốt với các câu đơn giản, từ vựng rõ ràng nhưng gặp khó khăn với các câu phức, câu có cấu trúc đối lập ("tuy... nhưng...") hoặc chứa từ lóng mới lạ chưa có trong bộ từ điển TF-IDF.

4.7.2 Kết quả từ mô hình BERT/PhoBERT Fine-tuning

Biểu đồ Loss (Training vs Validation):



Hình 4.7.2. Biểu đồ Loss huấn luyện và kiểm thử: PhoBERT vs mBERT.

- **Mô tả:** Đường cong Loss giảm dần đều và ổn định qua các epochs.
- **Phân tích:** Chứng tỏ mô hình hội tụ tốt. Validation Loss bắt đầu tăng nhẹ trong khi Training Loss vẫn giảm, đó là dấu hiệu Overfitting (nhưng đã được kiểm soát bằng Early Stopping).

So sánh hiệu năng (PhoBERT , mBERT và Baseline):

Bảng 4.7.2 So sánh hiệu năng các mô hình trên hai tác vụ: Phân loại cảm xúc và phân loại chủ đề


STT	Model	Task	Metric	Value
1	PhoBERT multitask	Sentiment	F1_macro	0.791073
2	PhoBERT multitask	Topic	F1_micro	0.881734
3	PhoBERT multitask	Topic	Hamming	0.060328
4	PhoBERT multitask	Topic	Jaccard(samples)	0.881080
5	mBERT multitask	Sentiment	F1_macro	0.792687
6	mBERT multitask	Topic	F1_micro	0.885266
7	mBERT multitask	Topic	Hamming	0.058354
8	mBERT multitask	Topic	Jaccard(samples)	0.884081
9	TF-IDF + OVR LR	Sentiment	F1_macro	0.69283
10	TF-IDF + OVR LR	Topic	F1_micro	0.862140
11	TF-IDF + OVR LR	Topic	Hamming	0.069093
12	TF-IDF + OVR LR	Topic	Jaccard(samples)	0.861813

- **mBERT** đạt hiệu năng cao nhất trên cả hai tác vụ phân loại cảm xúc và phân loại chủ đề, với F1-score macro = 0.7927 cho sentiment và F1-score micro = 0.8853 cho topic.

Kết quả này cho thấy mô hình đa ngôn ngữ vẫn có khả năng biểu diễn ngữ nghĩa tiếng Việt rất hiệu quả trong bối cảnh dữ liệu phản hồi sinh viên.

- **PhoBERT** đạt kết quả rất sát với mBERT (F1-score topic = 0.8817), chỉ thấp hơn một lượng nhỏ. Điều này khẳng định ưu thế của mô hình được huấn luyện chuyên biệt cho tiếng Việt trong việc nắm bắt cấu trúc ngữ pháp và ngữ nghĩa bản địa.
- **TF-IDF + Logistic Regression** cho kết quả thấp hơn rõ rệt so với hai mô hình Transformer, đặc biệt ở tác vụ sentiment (F1 = 0.6928), cho thấy hạn chế của các phương pháp dựa trên đặc trưng thủ công trong việc xử lý ngôn ngữ tự nhiên phức tạp và giàu ngữ cảnh.

Tác động của Threshold Tuning:



Hình 4.7.2. Biểu đồ F1-score theo các ngưỡng

- Biểu đồ F1-score theo các ngưỡng (0.1 -> 0.9).
- *Kết quả:* Ngưỡng tối ưu khoảng 0.3–0.5, mô hình đạt hiệu năng cao nhất tại 0.45, nên nhóm chọn 0.45, giúp cân bằng tốt nhất giữa Precision và Recall cho các lớp hiếm (như Facility).

4.7.3 So sánh hiệu năng và phân tích định lượng

Dựa trên bảng tổng hợp kết quả chạy thực nghiệm trên tập Test, nhóm đưa ra các phân tích định lượng chi tiết:

Bảng 4.7.3. Tổng hợp hiệu năng của các mô hình trên tập Test.

Mô hình	Sentiment F1 (Macro)	Topic F1 (Micro)	Hamming Loss (Tốt)
TF-IDF + OVR LR (Baseline)	0.6928	0.8621	0.0691
PhoBERT (Multitask)	0.7911	0.8817	0.0603
mBERT (Multitask)	0.7927	0.8853	0.0584

Nhận xét và Đánh giá:

- **Hiệu năng nhỉnh hơn của mBERT:**
 - Mặc dù giả thuyết ban đầu cho rằng mô hình đơn ngữ (PhoBERT) sẽ đạt kết quả tốt hơn, thực nghiệm cho thấy mBERT đạt hiệu năng cao nhất ở cả hai tác vụ Sentiment ($F1 \approx 0.793$) và Topic ($F1 \approx 0.885$).
 - Một nguyên nhân khả dĩ là dữ liệu phản hồi của sinh viên chứa nhiều từ tiếng Anh chuyên ngành (ví dụ: *deadline*, *slide*, *project*, *bonus point*) và hiện tượng pha trộn ngôn ngữ (code-switching). Nhờ được huấn luyện trên nhiều ngôn ngữ, mBERT có khả năng xử lý các biểu thức lai ngữ này tốt hơn so với PhoBERT, vốn chủ yếu được huấn luyện trên văn bản tiếng Việt chuẩn.
 - Tuy nhiên, mức chênh lệch giữa hai mô hình là khá nhỏ, cho thấy PhoBERT và mBERT đều đạt hiệu năng cao và ổn định trên tập dữ liệu này.

- **Hiệu quả của mô hình Baseline:**

- Mô hình TF-IDF kết hợp Logistic Regression đạt F1-micro cho tác vụ Topic lên tới 0.8621, chỉ thấp hơn các mô hình Transformer khoảng 2%. Điều này cho thấy trong bài toán phân loại chủ đề dựa trên từ khóa, các phương pháp thống kê truyền thống vẫn có hiệu quả đáng kể và ưu thế về chi phí tính toán.

- **Hamming Loss:**

- mBERT có Hamming Loss thấp nhất (0.0584), tương ứng với tỷ lệ dự đoán sai nhãn thấp nhất trong ba mô hình. PhoBERT đạt giá trị gần tương đương (0.0603), tiếp tục khẳng định tính ổn định của hai mô hình Transformer trong bài toán phân loại đa nhãn.

4.8 Phân tích lỗi và Đánh giá chuyên sâu (Error Analysis)

Để hiểu rõ hơn về hành vi của mô hình và định hướng cải thiện trong tương lai, nhóm nghiên cứu thực hiện phân tích chi tiết các trường hợp dự đoán sai dựa trên kết quả thực nghiệm và các ma trận nhầm lẫn (Confusion Matrix).

4.8.1 Định nghĩa các nhóm lỗi ngôn ngữ đặc trưng (Error Taxonomy)

Trước khi đi sâu vào phân tích từng mẫu dữ liệu cụ thể, nhóm nghiên cứu phân loại các thách thức chính mà mô hình gặp phải thành hai nhóm lỗi mang tính hệ thống. Việc định danh này giúp định hướng cho quá trình truy vết hành vi mô hình ở phần sau.

4.8.1.1 Lỗi Cấu trúc Tương phản (Contrastive Structure Failure)

Đây là hiện tượng phổ biến trong các câu có cấu trúc "Khen trước chê sau" (ví dụ: *Tuy... nhưng...*). Về mặt lý thuyết, cơ chế Self-Attention của Transformer có xu hướng tập trung vào các từ khóa cảm xúc mạnh (Salient words) bất kể vị trí. Nếu vế đầu chứa từ tích cực mạnh, mô hình dễ bị "át chế" và bỏ qua sắc thái phủ định ở vế sau, dẫn đến sai lệch trong bài toán Sentiment.

4.8.1.2 Lỗi Nhập nhằng Ngữ nghĩa & Thiên kiến Thực thể (Semantic Ambiguity & Entity Bias)

Trong bài toán phân loại chủ đề (Topic), sự nhập nhằng xảy ra khi một thực thể (Entity) có thể thuộc về nhiều lớp khác nhau tùy ngữ cảnh. Đặc biệt, hiện tượng tương quan giả xảy ra khi mô hình học vẹt mối liên hệ giữa một từ khóa phổ biến (ví dụ: "*Phòng*") với nhãn đa số (ví dụ: *Facility*), dẫn đến việc phân loại sai các trường hợp ngoại lệ (như "*Phòng đào tạo*" thuộc nhãn *Others*).

4.8.2 Phân tích ảnh hưởng của tiền xử lý (Tách từ vs Không tách từ)

Một giả thuyết quan trọng trong xử lý tiếng Việt là việc tách từ (Word Segmentation, ví dụ: ghép "giảng viên" thành một token giảng_viên) sẽ giúp cải thiện hiệu năng.


- **Lý thuyết:** Tiếng Việt là ngôn ngữ đơn lập, ý nghĩa thường nằm ở cụm từ ghép. Việc tách từ giúp mô hình nắm bắt ngữ nghĩa chính xác hơn là để các từ đơn rời rạc.
- **Thực tế thực nghiệm:** Tuy nhiên, kết quả tại mục 4.7.4 cho thấy mBERT (không sử dụng tách từ chuyên biệt của underthesea) lại có hiệu năng nhỉnh hơn PhoBERT (có sử dụng tách từ).
- **Lý giải:** Điều này phản ánh đặc thù của dữ liệu sinh viên. Ngôn ngữ được sử dụng không chuẩn mực, chứa nhiều từ viết tắt (teencode), từ lóng và tiếng Anh xen kẽ (code-switching). Trong môi trường "lai tạp" này, việc tách từ cứng nhắc theo quy chuẩn tiếng Việt đôi khi lại gây lỗi. Ngược lại, cách tiếp cận token hóa dạng sub-word linh hoạt của mBERT lại tỏ ra hiệu quả hơn trong việc xử lý các từ vựng "lạ" này.

4.8.3 Phân tích chuyên sâu theo nhóm chủ đề qua Confusion Matrix

Dựa trên các biểu đồ Confusion Matrix thu được từ mô hình mBERT Multitask trên tập kiểm thử (Test set), nhóm tiến hành phân tích chi tiết hiệu quả dự đoán cho từng tác vụ, bao gồm phân loại cảm xúc (Sentiment) và phân loại chủ đề (Topic – One-vs-Rest). Các

kết quả này cho phép đánh giá không chỉ độ chính xác tổng thể mà còn khả năng mô hình xử lý các lớp khó và hiện tượng nhầm lẫn đặc trưng trong dữ liệu phản hồi sinh viên.

4.8.3.1 Phân tích kết quả bài toán Sentiment



Hình 4.8.3.1. Confusion Matrix cho bài toán Sentiment – mBERT Multitask

Ma trận nhầm lẫn cho bài toán phân loại cảm xúc gồm ba lớp Negative – Neutral – Positive cho thấy:

Lớp Negative

- Mô hình dự đoán đúng 1.354 mẫu Negative.
- Chỉ có 13 mẫu bị nhầm sang Neutral và 42 mẫu bị nhầm sang Positive.
- Điều này cho thấy mô hình nhận diện rất tốt các phản hồi mang tính phàn nàn rõ ràng, thường chứa từ vựng tiêu cực đặc trưng như “tệ”, “không hài lòng”, “nóng”, “chán”, “khó chịu”.

→ Negative là lớp có độ ổn định cao, đóng vai trò quan trọng trong các hệ thống cảnh báo chất lượng đào tạo.

Lớp Positive

- Có 1.502 mẫu được dự đoán đúng.
- Một số mẫu bị nhầm sang Negative (71 mẫu) hoặc Neutral (17 mẫu).
- Các lỗi này thường xuất hiện ở những câu mang tính đối lập ngữ nghĩa (contrast), ví dụ:

“Thầy giảng hay nhưng phòng học nóng” – chứa cả yếu tố tích cực và tiêu cực.

→ Điều này phản ánh hạn chế tự nhiên của bài toán sentiment, khi một câu chứa nhiều sắc thái cảm xúc khác nhau

Lớp Neutral – lớp khó nhất

- Chỉ có 65 mẫu Neutral được dự đoán đúng, thấp hơn rõ rệt so với hai lớp còn lại.
- Neutral thường bị nhầm sang:
 - Negative (49 mẫu)
 - Positive (53 mẫu)

Nguyên nhân chính:

- Các câu Neutral trong dữ liệu sinh viên thường không hoàn toàn trung tính, mà mang sắc thái nhẹ, mơ hồ hoặc thiếu từ khóa đặc trưng.
- Ví dụ: *“Môn học cũng được”*, *“Tạm ổn”*, *“Bình thường”* rất dễ bị kéo về Positive hoặc Negative.

➔ Kết luận cho Sentiment:


Mô hình mBERT thể hiện hiệu năng rất tốt với Negative và Positive, trong khi Neutral vẫn là lớp khó, đòi hỏi:

- Dữ liệu huấn luyện cân bằng hơn
- Hoặc các kỹ thuật xử lý ngữ nghĩa sâu hơn (contrast modeling, discourse-aware).

4.8.3.2 Phân tích kết quả bài toán Topic

Các biểu đồ Confusion Matrix cho từng chủ đề (One-vs-Rest) cho thấy hiệu quả của việc tinh chỉnh ngưỡng (Threshold = 0.45):

Chủ đề Lecturer (Giảng viên)



Hình 4.8.3.2.1 Confusion Matrix – Topic Lecturer

- True Positive = 2.183
- False Negative = 107
- False Positive = 168


→ Đây là chủ đề có hiệu quả cao nhất.

Nguyên nhân:

- Chủ đề Lecturer sở hữu tập từ khóa rất đặc trưng:
“thầy”, “cô”, “giảng”, “dạy”, “hướng dẫn”, “nhiệt tình”...
- Những từ này xuất hiện ổn định và ít đa nghĩa trong ngữ cảnh phản hồi sinh viên.

→ Điều này cho thấy mBERT học rất tốt các pattern ngữ nghĩa rõ ràng, đặc biệt khi dữ liệu có tính nhất quán cao.

Chủ đề Training Facility (Cơ sở vật chất)



Hình 4.8.3.2.2 Confusion Matrix – Topic Facility

- True Positive = 135
- False Negative = 10
- False Positive = 17


Đây là một kết quả rất quan trọng về mặt ứng dụng thực tế.

False Negative cực thấp (chỉ 10 mẫu) cho thấy:

- Hầu hết các phản hồi liên quan đến cơ sở vật chất (phòng học, wifi, máy chiếu, điều hòa...) đều được hệ thống phát hiện.
- Điều này giúp giảm thiểu nguy cơ bỏ sót phản nản của sinh viên, hỗ trợ nhà trường phản ứng kịp thời.

→ Việc tinh chỉnh threshold = 0.45 đã cải thiện đáng kể Recall cho lớp Facility so với threshold mặc định 0.5.

Chủ đề Training Program (Chương trình đào tạo)



Hình 4.8.3.2.3 Confusion Matrix – Topic Training_program

- True Positive = 469
- False Negative = 103
- False Positive = 189


➔ Đây là nhóm có mức độ nhầm lẫn trung bình.

Nguyên nhân:

- Từ vựng của chủ đề này thường chồng lấn với Lecturer hoặc Others (ví dụ: “môn học”, “nội dung”, “đề cương”, “học phần”).
- Một số phản hồi đề cập chương trình đào tạo nhưng không đủ rõ ràng để vượt qua ngưỡng xác suất.

→ Tuy nhiên, mô hình vẫn duy trì khả năng phát hiện tương đối tốt các phản hồi liên quan đến nội dung học tập.

Chủ đề Others (Khác)



Hình 4.8.3.2.4 Confusion Matrix – Topic Others

- True Positive = 64
- False Negative = 95
- False Positive = 50

➔ Đây là chủ đề khó nhất.

Nguyên nhân chính:

- Others là nhóm không đồng nhất, bao gồm nhiều nội dung như hành chính, lịch học, học phí, thông báo...
- Thiếu tập từ khóa đặc trưng, dễ bị nhầm sang các chủ đề khác.

→ Kết quả này phản ánh đúng bản chất của dữ liệu, và không phải lỗi mô hình đơn thuần.

4.8.4. Phân tích định tính và Truy vết hành vi mô hình (Qualitative Analysis & Model Behavior Tracing)

Để vượt qua các đánh giá định lượng thông thường (như F1-score), nhóm nghiên cứu tiến hành phân tích định tính chuyên sâu nhằm giải mã "hộp đen" (black-box) của các mô hình Transformer. Mục tiêu là làm rõ sự khác biệt trong tư duy ngữ nghĩa giữa kiến trúc

đơn ngữ chuyên biệt (**PhoBERT**) và kiến trúc đa ngữ (**mBERT**), đặc biệt khi đối mặt với các thách thức ngôn ngữ đặc thù của sinh viên Việt Nam.

4.8.4.1 Phân tích thực nghiệm trên mô hình PhoBERT Multitask

PhoBERT có lợi thế cốt lõi là được tiền huấn luyện (pre-training) trên dữ liệu tiếng Việt quy mô lớn, trong đó văn bản đã được tách từ (word segmentation) trước khi áp dụng cơ chế mã hóa subword dựa trên Byte-Pair Encoding (BPE). Cách tiếp cận này giúp các token đầu vào tương ứng tốt hơn với đơn vị ngữ nghĩa thực của tiếng Việt, từ đó cải thiện chất lượng vector biểu diễn [CLS].

Bảng 4.8.4.1. Truy vết các mẫu PhoBERT dự đoán chính xác (Correct Cases)

Nội dung phản hồi (Sentence)	Nhãn (S/T)	Phân tích chuyên sâu Cơ chế & Hành vi mô hình
"thầy dạy nhiệt tình , có kiến thức chuyên môn vững , lấy nhiều ví dụ thực tế trong bài giảng ."	Pos / Lecturer	Cơ chế Attention & Semantics: • Tách từ: underthesea gom cụm "kiến_thức_chuyên_môn" và "ví_dụ_thực_tế" thành các token đơn nhất, giúp giảm chiều dài chuỗi và tăng mật độ thông tin. • Self-Attention: Trọng số sự chú ý (Attention weights) hội tụ mạnh vào các tính từ cực tính dương ("nhiệt_tình", "vững"). • Kết luận: Đầu phân loại Sentiment nhận được tín hiệu Feature Vector rất rõ ràng, dẫn đến xác suất Softmax cho lớp Positive tiệm cận 1.0.

"môn học cung cấp nhiều kiến thức bổ ích."	Pos / Program	Cơ chế Phân loại Chủ đề: • Ngữ cảnh: PhoBERT phân biệt tốt giữa chủ thể con người (Thầy/Cô) và chủ thể trừu tượng (Môn học). • Quyết định: Mặc dù từ "cung_cấp" là động từ chung, nhưng sự kết hợp với tân ngữ "kiến_thức" đã kích hoạt neuron tương ứng với lớp <i>Training Program</i> trong tầng Linear cuối cùng, ức chế xác suất của lớp <i>Lecturer</i>.
"hệ thống đăng ký môn học thường xuyên bị lỗi , gây khó khăn cho sinh viên."	Neg / Others	Khả năng Tổng quát hóa (Generalization): • Nhận diện thực thể: Mô hình xác định "hệ_thốngĐăng_ký" không thuộc về cơ sở vật chất vật lý (như máy lạnh, bàn ghế). • Sentiment: Cụm "bị_lỗi" và "khó_khăn" đóng vai trò là <i>negative anchors</i> (neo tiêu cực), kéo vector ngữ nghĩa về phía không gian Negative.
"thầy giảng bài hơi nhanh , đôi khi em không theo kịp."	Neg / Lecturer	Xử lý Phụ thuộc xa (Long-range Dependency): • Cấu trúc: Câu không chứa từ chủ ngữ hay che bai trực diện. Tuy nhiên, Transformer encoder nắm bắt được mối quan hệ nhân quả: <i>Tốc độ nhanh → Hậu quả (không theo kịp)</i>. • Kết quả: Mô hình suy luận ra sắc thái Tiêu cực dựa trên ngữ cảnh phủ định năng lực tiếp thu ("không theo kịp").

Bảng 4.8.4.2. Phân tích các trường hợp PhoBERT dự đoán sai (Error Analysis)

Nội dung phản hồi	Nhãn Thực → Dự đoán	Phân tích Nguyên nhân Gốc rễ (Root Cause Analysis)
"môn học này cũng bình thường ."	Neutral → Positive	Lỗi Ranh giới Quyết định (Decision Boundary Shift): • Vấn đề: Từ "bình_thường" nằm ở vùng xám (gray area) của không gian vector cảm xúc. Trong tập huấn luyện, từ này đôi khi xuất hiện trong các câu mang ý chấp nhận được (positive bias). • Hệ quả: Mô hình chưa học được siêu phẳng (hyperplane) phân tách đủ tinh tế để cô lập lớp Neutral, dẫn đến việc gán nhãn Positive do xác suất vượt trội nhẹ.
"thầy dạy rất hay nhưng bài tập về nhà quá nhiều ."	Neutral → Negative	Lỗi Cơ chế Attention trong câu đối lập: • Cơ chế: Câu có cấu trúc <i>Contrastive</i> (Tuy... nhưng...). Theo lý thuyết, thông tin sau từ "nhưng" thường quan trọng hơn. • Sai số: PhoBERT đã dồn quá nhiều trọng số attention vào vế sau ("quá nhiều" - Negative) và triệt tiêu thông tin tích cực ở vế trước. Điều này làm mất đi tính cân bằng cần thiết cho nhãn Neutral.

"phòng đào tạo phản hồi email quá chậm ."	Others → Facility	Lỗi Thiên kiến Thực thể (Entity Bias/Heuristic): • Phân tích: Mô hình đã học vệt (overfit) quy tắc: thấy từ "Phòng" $\rightarrow$ gán nhãn <i>Facility</i> (Cơ sở vật chất). • Nguyên nhân: Do dữ liệu về các phòng ban hành chính (Others) quá ít so với dữ liệu về phòng học/phòng máy (Facility), khiến mô hình hình thành lối tắt tư duy (heuristic shortcut) sai lệch.
"lịch thi xếp quá dày đặc ."	Others → Program	Sự chồng lấn ngữ nghĩa (Semantic Overlap): • Vấn đề: Khái niệm "lịch thi" có giao thoa giữa quy chế đào tạo (Program) và công tác tổ chức (Others). • Kết quả: Mô hình ưu tiên nhãn <i>Program</i> do sự xuất hiện của từ khóa "thi", cho thấy sự khó khăn trong việc phân định các lớp có ranh giới mờ.

4.8.4.2. Phân tích thực nghiệm trên mô hình mBERT Multitask

Khác với PhoBERT, mBERT sử dụng Tokenizer dạng WordPiece (cắt từ thành các mảnh nhỏ, ví dụ: "deadline" $\rightarrow$ "dead" + "##line"). Cơ chế này cho thấy lợi thế rõ rệt khi xử lý ngôn ngữ không chuẩn mực của Gen Z.

Bảng 4.8.4.3. Truy vết các mẫu mBERT dự đoán chính xác (Correct Cases)

Nội dung phản hồi (Sentence)	Nhãn (S/T)	Phân tích chuyên sâu Cơ chế & Hành vi mô hình
"giảng viên dạy rất có tâm , nhiệt tình hỗ trợ sinh viên ."	Pos / Lecturer	Khả năng Cross-lingual Transfer: • Cơ chế: mBERT tận dụng các đặc trưng ngữ nghĩa đa ngôn ngữ đã học được từ Wikipedia. Các khái niệm như "có tâm" (dedicated) hay "hỗ trợ" (support) được ánh xạ vào không gian vector tương đồng với các ngôn ngữ khác, giúp việc nhận diện trở nên bền vững (robust).
"phòng máy tính thường xuyên bị hỏng máy , mong nhà trường sớm khắc phục ."	Neg / Facility	Nhận diện Co-occurrence (Đồng xuất hiện): • Phân tích: Mô hình bắt được cặp bài trùng: <i>Entity (máy tính) + State (hỏng)</i>. • Kết quả: Đầu Sigmoid cho nhãn Facility kích hoạt mạnh mẽ (xác suất > 0.8) do sự liên kết chặt chẽ giữa đối tượng và trạng thái hư hỏng.
"thầy giảng bài dễ hiểu , slide trình bày khoa học ."	Pos / Lecturer	Xử lý Từ vựng Lai (Code-switching Handling): • Ưu điểm: Trong khi các bộ tách từ tiếng Việt có thể gặp khó với từ tiếng Anh, Tokenizer của mBERT xử lý từ "slide" như một token gốc (nhờ dữ liệu huấn luyện tiếng Anh phong phú). • Hiệu quả: Giúp bảo toàn trọn vẹn ngữ nghĩa của câu chứa từ mượn mà không bị nhiễu.

<i>"thời gian học quá dài , sinh viên dễ bị mệt mỏi và mất tập trung ."</i>	Neg / Others	Phân tích Cảm xúc Ẩn (Implicit Sentiment): • Cơ chế: Mô hình không chỉ dựa vào từ khóa mà phân tích trạng thái tâm lý. Các cụm "mệt_mỏi", "mất_tập_trung" được vector hóa thành các đặc trưng tiêu cực mạnh, giúp định danh chính xác thái độ của sinh viên dù không có từ chê bai trực tiếp.
---	---------------------	---

Bảng 4.8.4.4. Phân tích các trường hợp mBERT dự đoán sai (Error Analysis)

Nội dung phản hồi	Nhãn Thực → Dự đoán	Phân tích Nguyên nhân Gốc rễ (Root Cause Analysis)
<i>"môn học này 'tuyệt vời' đến nỗi em phải học lại lần nữa ."</i>	Neg → Pos	Lỗi Ngữ dụng học (Pragmatics/Sarcasm Failure): • Bản chất: Đây là câu mỉa mai (Sarcasm). Về mặt từ vựng (Lexical), từ "tuyệt vời" mang trọng số dương rất lớn. • Hạn chế: Cơ chế Self-Attention hiện tại chỉ tập trung vào sự tương đồng từ vựng mà chưa đủ khả năng suy luận logic ngược (counter-intuitive reasoning) để hiểu rằng "học lại" sẽ đảo ngược cực tính của "tuyệt vời".

<i>"thầy dạy ỏn ."</i>	Pos → Neu	Vấn đề Độ dài chuỗi (Sequence Length): • Phân tích: Với câu quá ngắn (3 từ), ngữ cảnh cung cấp cho mô hình là quá ít (sparse context). • Kết quả: Từ "ỏn" mang tính trung dung. Không có thêm các từ hỗ trợ (như "rất", "lắm"), mô hình thiếu tự tin (low confidence) để đẩy xác suất lên mức Positive, do đó rơi vào trạng thái mặc định là Neutral.
<i>"bài tập cũng được ."</i>	Neu → Pos	Lỗi Over-fitting vào Lớp Đa số: • Nguyên nhân: Do dữ liệu huấn luyện mất cân bằng (lớp Positive chiếm tỷ trọng lớn). • Hệ quả: Mô hình có xu hướng "hào phóng" khi gán nhãn Tích cực cho các câu nằm ở vùng ranh giới mờ nhạt (ambiguous inputs) để tối ưu hóa hàm loss tổng thể.
<i>"đừng có một chỗ tiếng anh một chỗ tiếng việt ."</i>	Others → Program	Sai lệch Phân loại Khía cạnh: • Phân tích: Mô hình nhận diện các từ khóa ngôn ngữ ("tiếng anh", "tiếng việt") và liên kết chúng với tài liệu học tập (Program). Tuy nhiên, ý định thực sự của sinh viên là phàn nàn về sự thiếu nhất quán trong trình bày (Others/Format). Đây là lỗi do mô hình chưa hiểu sâu ý định (Intent Recognition).

4.8.5. Tổng kết quy luật sai số và Kiến nghị (Synthesis & Recommendations)

Từ việc mổ xẻ các trường hợp trên, nhóm nghiên cứu tổng hợp 3 tầng nguyên nhân chính gây ra sai số cho hệ thống:

1. Hạn chế về Kiến trúc (Architectural Limitation):

- Cả PhoBERT và mBERT đều dựa trên cơ chế Attention cục bộ. Khi gặp các câu Mỉa mai (Sarcasm) hoặc câu có cấu trúc Đảo ngữ, mô hình thường bị "đánh lừa" bởi các từ khóa cảm xúc mạnh xuất hiện trên bề mặt (surface forms) mà bỏ qua hàm ý sâu xa.

2. Thiên kiến Dữ liệu (Data Bias):

- Hiện tượng "Entity Bias" (thấy "Phòng" là đoán "Cơ sở vật chất") cho thấy mô hình đang học vẹt dựa trên đồng xuất hiện (co-occurrence) hơn là hiểu ngữ cảnh.
- Sự mất cân bằng dữ liệu khiến lớp Neutral trở thành điểm yếu nghiêm trọng của mô hình, với xu hướng bị dự đoán sai thành Positive/Negative rất cao.

3. Đặc thù Ngôn ngữ (Linguistic Specificity):

- Tiếng Việt của sinh viên có tính Đa nghĩa và Dụng học (Pragmatics) cao (ví dụ: "thầy dạy cũng được" có thể là khen hoặc chê tùy ngữ cảnh). Các mô hình hiện tại chưa được tích hợp tri thức ngoài (External Knowledge) để giải quyết các trường hợp này.

➔ **Hướng giải quyết đề xuất:** Trong tương lai, cần áp dụng chiến lược Contrastive Learning (Học tương phản) để giúp mô hình phân biệt rõ hơn các mẫu câu có cấu trúc giống nhau nhưng ý nghĩa đối lập, đồng thời tăng cường dữ liệu cho các lớp thiểu số (Others, Neutral) thông qua kỹ thuật sinh dữ liệu (Data Augmentation).

CHƯƠNG 5. ĐẠO ĐỨC, QUYỀN RIÊNG TƯ VÀ RỦI RO

5.1 Ẩn danh hóa dữ liệu và bảo vệ thông tin cá nhân

Trong đề tài phân tích cảm xúc và chủ đề từ phản hồi sinh viên, vấn đề bảo vệ quyền riêng tư (Privacy) là yêu cầu bắt buộc nhằm đảm bảo yếu tố đạo đức trong nghiên cứu. Vì dữ liệu đánh giá môn học có thể chứa thông tin nhạy cảm về cá nhân hoặc tổ chức, nhóm nghiên cứu đã thực hiện các biện pháp ẩn danh hóa (Anonymization) và phi định danh hóa (De-identification) toàn diện.

(1) Loại bỏ các thông tin nhận dạng cá nhân (Personally Identifiable Information – PII)

Trước khi đưa vào pipeline xử lý, tất cả bình luận được kiểm tra qua bộ lọc Regex và NER để loại bỏ các thông tin như:

- Tên sinh viên hoặc mã số sinh viên.
- Tên giảng viên (nếu xuất hiện dưới dạng gọi trực tiếp kèm các thông tin định danh khác).
- Lớp học, nhóm học hoặc bất cứ dữ liệu nào có thể quy ngược về một cá nhân cụ thể.
- Email, số điện thoại, đường link chứa thông tin đăng nhập.

Điều này đảm bảo dữ liệu đầu ra chỉ phản ánh nội dung đánh giá chất lượng dạy và học chứ không tiết lộ danh tính các bên liên quan.

(2) Chuẩn hóa và làm sạch nội dung để tránh rò rỉ danh tính gián tiếp

Một số bình luận có thể chứa thông tin nhạy cảm một cách gián tiếp (Contextual Identifiers). Ví dụ: “Thầy H** dạy rất khó hiểu”* hay “Bạn lớp trưởng nhóm 3 làm việc không tốt”. Nhóm áp dụng quy trình thay thế bằng các token trung tính (Masking) như:

- “Giảng viên A...”, “Sinh viên B...”, “Nhóm học X...”.

(3) Không thu thập hoặc lưu trữ dữ liệu gốc ngoài phạm vi đề tài

Dữ liệu chỉ được tải từ bộ UIT-VSFC công khai và không thu thập từ nguồn nội bộ khác. Mọi dữ liệu xử lý trung gian (cache, log) đều được xóa sau khi kết thúc thực nghiệm để đảm bảo tính an toàn.

(4) Tách biệt dữ liệu huấn luyện – kiểm thử

Đảm bảo mô hình không thể học thuộc lòng (memorization) bất kỳ thông tin cá nhân nào. Việc tách biệt tập Test giúp kiểm chứng rằng mô hình học các mẫu ngôn ngữ tổng quát chứ không ghi nhớ nội dung nhạy cảm cụ thể.

(5) Nguyên tắc bảo mật theo chuẩn FAIR & GDPR

Dù dataset không chứa PII, nhóm vẫn tuân thủ các nguyên tắc:

- **Minimization:** Chỉ sử dụng các trường dữ liệu cần thiết cho bài toán sentiment/topic.
- **Purpose Limitation:** Chỉ sử dụng dữ liệu cho mục đích nghiên cứu khoa học.
- **Security:** Không chia sẻ dữ liệu đã qua xử lý (như synthetic data) ra ngoài phạm vi nhóm nếu chưa qua kiểm duyệt.

5.2 Phân tích tính thiên lệch và công bằng

Một trong những rủi ro lớn nhất của các mô hình NLP là học theo thiên lệch (bias) của dữ liệu. Bộ dữ liệu đánh giá môn học của sinh viên Việt Nam cũng thể hiện nhiều dạng thiên lệch đặc thù, đòi hỏi cần xem xét và giảm thiểu.

(1) Thiên lệch do phân bố nhãn không đồng đều (Class Imbalance Bias)

Như đã phân tích trong Chương 2, dữ liệu gốc có sự mất cân bằng nghiêm trọng khi nhãn Neutral chỉ chiếm ~4%, trong khi Positive & Negative chiếm trên 90%.

- **Rủi ro:** Mô hình có xu hướng dự đoán Tích cực hoặc Tiêu cực ngay cả khi văn bản mang tính mô tả trung tính, dẫn đến sai lệch trong báo cáo tổng hợp.
- **Giải pháp đã triển khai:**

- Tăng cường dữ liệu (Synthetic Data Generation) bằng template để cân bằng phân bố.
- Sử dụng **F1-Macro** làm thước đo chính thay vì Accuracy.
- Áp dụng trọng số lớp (Class Weights) trong hàm mất mát khi huấn luyện BERT.

(2) Thiên lệch chủ đề (Topic Bias)

Nhân Lecturer và Training Program chiếm tỷ trọng vượt trội, trong khi Facility và Others rất ít.

- **Rủi ro:** Mô hình có xu hướng "bắt từ khóa" (ví dụ: thấy từ "thầy/cô" là gán Lecturer) mà bỏ qua ngữ cảnh, dẫn đến việc không học tốt các chủ đề hiếm.
- **Giải pháp:**
 - Sinh dữ liệu bổ sung >1500 mẫu cho Facility & Others.
 - Sử dụng kiến trúc Multi-label classification với hàm kích hoạt Sigmoid, giúp mô hình nhận diện độc lập từng chủ đề mà không bị lấn át bởi các chủ đề lớn.

(3) Thiên lệch ngôn ngữ (Linguistic Bias)

Dữ liệu sinh viên chứa nhiều đặc thù: Teencode ("ko", "hok", "vl"), câu thiếu chủ vị, hoặc pha trộn tiếng Anh (Code-switching).

- **Rủi ro:** Các câu dùng từ lóng mạnh dễ bị mô hình gán nhãn Negative dù ngữ cảnh có thể là khen (ví dụ: "*đỉnh vãi*"). Ngoài ra, các câu mỉa mai (sarcasm) rất khó phát hiện.
- **Biện pháp:** Chuẩn hóa văn bản (tách từ, chuẩn hóa slang dictionary), loại bỏ spam bằng Regex và thực hiện Error Analysis để tinh chỉnh quá trình tiền xử lý.

(4) Thiên lệch nhận thức (Human Annotation Bias)

Bản thân bộ dữ liệu gốc chứa nhiều do người gán nhãn không nhất quán (ví dụ: gán Positive cho câu vốn Trung lập như "Thầy lên lớp đúng giờ").

- **Giải pháp:** Nhóm đã đánh giá lại thủ công một phần dữ liệu (Re-annotation) và chuẩn hóa quy tắc gán nhãn. Đồng thời, việc sử dụng dữ liệu tổng hợp (synthetic data được kiểm chứng thủ công) giúp mô hình học được các mẫu chuẩn xác hơn.

(5) Đảm bảo công bằng (Fairness) trong áp dụng mô hình

Mục tiêu cuối cùng là hỗ trợ phân tích chất lượng giảng dạy một cách khách quan.

- **Yêu cầu:** Mô hình không được thiên lệch có lợi hoặc bất lợi cho bất kỳ nhóm giảng viên hay môn học nào. Không diễn giải sai cảm xúc dẫn đến các đánh giá bất công.
- **Kiểm chứng:** Nhóm đánh giá tính công bằng thông qua Ma trận nhầm lẫn (Confusion Matrix) chi tiết theo từng nhãn và phân tích các trường hợp sai lệch (False Positives/False Negatives) để đảm bảo sai số được phân bố đều, không tập trung vào một nhóm cụ thể.

5.3 Công bố kết quả và tuân thủ quy định

(1) Minh bạch trong quá trình công bố kết quả

Khi báo cáo kết quả mô hình, nhóm tuân thủ nguyên tắc minh bạch số liệu: Báo cáo đầy đủ các chỉ số (Accuracy, Precision, Recall, F1-Macro) và không che giấu hạn chế đối với các lớp Neutral hay chủ đề hiếm. Phân tích lỗi (Error Analysis) được trình bày chi tiết giúp người đọc hiểu rõ giới hạn của mô hình.

(2) Không công bố dữ liệu thô chứa thông tin nhạy cảm

Dữ liệu huấn luyện sau khi nhóm tăng cường (gồm nội dung gốc + synthetic) sẽ không được chia sẻ công khai nếu chưa qua rà soát kỹ lưỡng về tàn dư thông tin nhạy cảm. Tất cả ví dụ minh họa trong báo cáo đều đã được chỉnh sửa ẩn danh.

(3) Tuân thủ quy định và Chuẩn mực đạo đức

Đề tài cam kết không sử dụng dữ liệu cho mục đích đánh giá giảng viên ngoài ngữ cảnh nghiên cứu khoa học; không đưa ra các kết luận mang tính xếp hạng hay định kiến cá nhân.

(4) Khuyến nghị sử dụng

Nhóm khuyến nghị không sử dụng mô hình để đưa ra các quyết định quản trị nhân sự tự động mà không có sự kiểm chứng của con người (Human-in-the-loop), nhằm tránh các rủi ro máy móc hiểu sai ngữ cảnh phức tạp.

(5) Đảm bảo tính tái lập (Reproducibility)

Mã nguồn, siêu tham số và cấu hình môi trường thực nghiệm được tài liệu hóa đầy đủ theo chuẩn FAIR (Findable – Accessible – Interoperable – Reusable), đóng góp vào cộng đồng nghiên cứu học thuật.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1 Kết luận

Đồ án đã xây dựng thành công quy trình xử lý ngôn ngữ tự nhiên (NLP Pipeline) toàn diện cho bài toán phân tích phản hồi sinh viên tại các trường đại học. Kết quả thực nghiệm khẳng định PhoBERT (với kỹ thuật Fine-tuning đa nhiệm) là giải pháp tối ưu nhất hiện nay, đạt độ chính xác ~88%, vượt trội so với các phương pháp truyền thống và mô hình đa ngữ mBERT.

Việc áp dụng thành công kiến trúc Multi-task Learning cho phép mô hình nhìn nhận một câu phản hồi dưới góc độ đa chiều (vừa xác định sắc thái cảm xúc, vừa phân loại chủ đề liên quan), mang lại công cụ đắc lực cho công tác quản lý và nâng cao chất lượng giáo dục.

6.2 Đóng góp của đề tài

Về mặt kỹ thuật: Cung cấp bộ mã nguồn (Source code) chuẩn mực, cấu trúc rõ ràng, dễ dàng tái sử dụng và mở rộng cho các bài toán phân loại văn bản tiếng Việt khác.

Về mặt thực nghiệm: Đưa ra các đánh giá định lượng chi tiết, so sánh sòng phẳng giữa các kiến trúc mô hình (Baseline vs Deep Learning, Monolingual vs Multilingual), cung cấp cái nhìn sâu sắc cho cộng đồng nghiên cứu.

6.3 Hạn chế và Hướng phát triển

Mặc dù đạt kết quả khả quan, nhóm nghiên cứu nhận thấy một số điểm cần cải thiện để mô hình có thể triển khai thực tế hiệu quả hơn:

- **Về dữ liệu:** Dữ liệu Synthetic sinh bởi LLM có văn phong khá chuẩn mực, chưa phản ánh hết sự đa dạng và độ "nhiều" (teencode, viết tắt, tiếng lóng, sai chính tả) của ngôn ngữ sinh viên.
 - *Hướng phát triển:* Thu thập và gán nhãn thêm dữ liệu thực tế từ các kênh phi chính thức (như Confession) hoặc thực hiện Data Augmentation dựa trên các quy tắc thay thế từ đồng nghĩa/teencode.

- **Về tối ưu hóa mô hình:** PhoBERT-base có kích thước tương đối lớn, gây khó khăn khi triển khai trên các hệ thống có tài nguyên hạn chế hoặc yêu cầu thời gian thực.
 - *Hướng phát triển:* Nghiên cứu áp dụng kỹ thuật **Knowledge Distillation** (Chưng cất mô hình) hoặc **Quantization** (Lượng tử hóa) để giảm kích thước và tăng tốc độ suy luận mà vẫn giữ vững độ chính xác.
- **Về mở rộng bài toán:** Hiện tại mô hình chỉ xử lý các khía cạnh hiện (Explicit Aspects).
 - *Hướng phát triển:* Phát triển thêm chức năng phát hiện khía cạnh ẩn (Implicit Aspect Detection) để hiểu được những ý kiến sâu sắc không nhắc trực tiếp đến từ khóa chủ đề.

PHỤ LỤC. DANH SÁCH VÀ PHÂN TÍCH CHI TIẾT NGỮ LIỆU TIÊU BIỂU

Phụ lục này trình bày phân tích chi tiết về đặc điểm ngôn ngữ học và mức độ phức tạp ngữ nghĩa của bộ dữ liệu phản hồi sinh viên được sử dụng trong nghiên cứu.

Mục tiêu của phần này là:

- (1) làm rõ các hiện tượng ngôn ngữ phổ biến xuất hiện trong dữ liệu thực tế,
- (2) chỉ ra những thách thức đối với các mô hình phân loại cảm xúc và chủ đề, đặc biệt là các phương pháp dựa trên đặc trưng bề mặt,
- và (3) cung cấp cơ sở khoa học để lý giải cho việc lựa chọn các mô hình học sâu dựa trên biểu diễn ngữ cảnh (contextual embeddings) như PhoBERT và mBERT trong bài toán đa nhiệm.

Khác với các tập dữ liệu được xây dựng trong môi trường kiểm soát, phản hồi của sinh viên trong thực tế thường mang tính tự phát, không chuẩn hóa và chịu ảnh hưởng mạnh bởi ngữ cảnh giao tiếp, phong cách cá nhân, cũng như kiến thức chuyên ngành của người viết. Do đó, các câu trong dữ liệu không chỉ đơn thuần chứa thông tin cảm xúc rõ ràng, mà còn bao gồm nhiều hiện tượng phức tạp như cảm xúc ẩn (implicit sentiment), mỉa mai (irony), đảo cực cảm xúc (polarity reversal), đa chủ đề (multi-topic), và đa khía cạnh (multi-aspect).

Việc phân tích các trường hợp này giúp đánh giá mức độ phù hợp của các phương pháp mô hình hóa khác nhau, đồng thời làm rõ những giới hạn của các mô hình truyền thống như TF-IDF kết hợp với bộ phân loại tuyến tính, so với các mô hình Transformer có khả năng khai thác ngữ cảnh dài hạn và quan hệ phụ thuộc ngữ nghĩa trong câu.

I. Nhóm 1: Phân tích về Chương trình đào tạo & Nội dung (Training Program)

Đặc điểm: Phản hồi về tính thực tiễn, độ khó, giáo trình và sự phân bổ thời gian.

STT	Nội dung (Raw Data)	Nhãn	Cơ sở nhận diện (Linguistic Basis)	Phân tích chuyên sâu & Giải thích logic	Mức độ
1	<i>"theo em nghĩ , đã làm đồ án môn học thì không nên thi cuối kỳ , mà thi cuối kỳ thì nên bỏ đồ án môn học ."</i>	Neg / Program	Chứa thực thể định danh Topic ("đồ án", "thi") và cấu trúc phủ định đề xuất ("không nên", "bỏ").	Xung đột cấu trúc đánh giá: Sinh viên sử dụng câu ghép đẳng lập để chỉ ra sự bất hợp lý trong khối lượng công việc. Dù không dùng từ cảm xúc tiêu cực trực diện, nhưng ý định (intent) là phản nản về sự quá tải.	TB
2	<i>"nội dung các bài thực hành cần có hướng đi bao quát hơn ."</i>	Neg / Program	Cụm danh từ chủ đề ("nội dung", "thực hành") đi kèm động từ tình thái cầu khiến ("cần có").	Góp ý xây dựng (Constructive Feedback): Dạng câu này gây khó cho mô hình vì "bao quát hơn" là từ tích cực, nhưng ngữ cảnh "cần có" lại ám chỉ sự thiếu hụt hiện tại.	TB
3	<i>"có những cái học không biết để làm gì sau này"</i>	Neg / Program	Câu hỏi tu từ chứa cụm phủ định giá trị	P phủ định giá trị thực tiễn: Câu hỏi không nhằm mục đích tìm kiếm	Dễ

	<i>vậy tại sao không giảm tải nó đi ."</i>		mạnh ("không biết để làm gì").	thông tin mà để nhấn mạnh sự vô nghĩa của nội dung học. Tín hiệu tiêu cực rất rõ ràng qua cụm "giảm tải".	
4	<i>"môn học có phần không hợp lý , vì từ giữa kỳ qua chương 5 trình độ tăng rất nhanh , có nhiều sinh viên không nắm bắt được ."</i>	Neg / Program	Tính từ đánh giá trực tiếp ("không hợp lý") và cụm từ chỉ trạng thái năng lực ("không nắm bắt được").	Phân tích nhịp độ (Pacing Analysis): Phàn nàn về đường cong học tập (Learning Curve) quá dốc. Mô hình cần liên kết nguyên nhân (tăng nhanh) với kết quả tiêu cực (không hiểu) để xác định nhân.	Khó
5	<i>"nội dung học quá trừu tượng , thực hành chưa thực sự mang lại hiệu quả... thực hành xong không biết mình đang làm gì , không thấy được ý nghĩa thực tiễn ."</i>	Neg / Program	Chuỗi phủ định kép ("không biết", "không thấy") đi kèm tính từ trừu tượng tiêu cực.	Sự thất vọng toàn diện: Câu phức thể hiện sự gãy đổ trong cả lý thuyết (trừu tượng) và thực hành (không hiệu quả). Mật độ từ khóa tiêu cực dày đặc.	Dễ
6	<i>"môn học quá sâu và mới mẻ rất khó nắm bắt để làm bài tập ."</i>	Neg / Program	Nghịch lý từ vựng: Tính từ tích cực ("sâu", "mới") kết hợp	Ngữ cảnh đảo ngược: "Sâu" và "Mới" thường là khen, nhưng trong ngữ cảnh này lại là rào	TB

			với hệ quả tiêu cực ("khó nắm bắt").	cảm nhận thức. Đây là bấy ngữ nghĩa đối với các mô hình chỉ dựa trên từ khóa đơn lẻ.	
7	<i>"kiến thức của môn này có lẽ hiếm khi nào tụi em dùng tới."</i>	Neg / Program	Trạng từ chỉ tần suất thấp ("hiếm khi") bổ nghĩa cho động từ sử dụng ("dùng tới").	Dự báo giá trị tương lai: Sinh viên đánh giá thấp tính ứng dụng. "Hiếm khi" đóng vai trò là từ phủ định giảm nhẹ (soft negation), đòi hỏi mô hình hiểu ngữ cảnh rộng.	TB
8	<i>"đề án cuối kỳ trong vòng một tháng cuối, áp dụng được quy trình thực tế."</i>	Pos / Program	Cụm động từ khẳng định năng lực ("áp dụng được") và tính từ giá trị ("thực tế").	Đánh giá tính ứng dụng cao: Không cần tính từ khen ngợi cảm xúc (như "tuyệt vời"), bản thân việc "áp dụng thực tế" đã là tín hiệu Positive mạnh nhất trong chủ đề Program.	Dễ
9	<i>"môn mạng máy tính nên tăng cường thời gian thực hành thay vì dạy quá nhiều lý thuyết gây khó hiểu."</i>	Neg / Program	Cấu trúc so sánh hơn kém ("tăng cường A thay vì B") và tính từ kết quả tiêu cực ("khó hiểu").	So sánh bất cân xứng: Sinh viên dùng cấu trúc "thay vì" để hạ thấp giá trị của phần Lý thuyết. Từ "khó hiểu" là chốt chặn cuối cùng xác định nhãn Negative.	Dễ

10	<i>"nâng cao khả năng tự học đạt điểm cao trong các kỳ thi ."</i>	Pos / Program	Động từ chỉ sự phát triển ("nâng cao") và danh từ chỉ thành tích ("điểm cao").	Hiệu quả đầu ra (Outcome): Câu khẳng định ngắn gọn về lợi ích kỹ năng mềm (tự học) và lợi ích cứng (điểm số). Tín hiệu tích cực rõ ràng.	Dễ
11	<i>"các bài thực hành cần bám sát theo chương trình lý thuyết ."</i>	Neg / Program	Động từ cầu khiến ("cần") thể hiện sự thiếu hụt sự liên kết.	Yêu cầu tính thống nhất: Phàn nàn về sự rời rạc trong giáo trình. Tương tự câu 2, "cần" là dấu hiệu của việc hiện trạng chưa đạt yêu cầu.	TB
12	<i>"môn học giúp hiểu rõ về từng ngành ."</i>	Pos / Program	Động từ hỗ trợ ("giúp") và tính từ nhận thức ("hiểu rõ").	Giá trị định hướng: Câu ngắn gọn xác nhận môn học đã hoàn thành mục tiêu truyền tải kiến thức tổng quan. Không có yếu tố gây nhiễu.	Dễ
13	<i>"nhiều phần nâng cao thường bị giảng viên bỏ qua ."</i>	Neg / Program	Động từ thể bị động mang nghĩa tiêu cực ("bị bỏ qua").	Lỗi thiếu hụt nội dung: Sinh viên phàn nàn về việc cắt xén chương trình. Cụm "bị bỏ qua" là tín hiệu Negative đặc trưng.	Dễ
14	<i>"cần đổi mới tài liệu ."</i>	Neg / Program	Động từ chỉ sự thay đổi ("đổi mới") đi kèm	Tính cập nhật: Yêu cầu "đổi mới" ngụ ý tài liệu	Dễ

			từ cầu khiến ("cần").	hiện tại đã cũ kỹ, lạc hậu (Implicit Negative).	
15	"đề án thực hành khác xa so với lý thuyết học trên lớp."	Neg / Program	Tính từ so sánh sự khác biệt ("khác xa") trong ngữ cảnh sự tương đồng.	Mâu thuẫn nội dung: "Khác xa" là từ trung tính, nhưng trong giáo dục, sự thiếu đồng bộ giữa Lý thuyết và Thực hành là một lỗi hệ thống lớn.	Khó

II. Nhóm 2: Phân tích về Cơ sở vật chất & Môi trường (Facility)

Đặc điểm nhận diện: Chứa thực thể vật lý cụ thể (noun entities) và tính từ mô tả trạng thái hoạt động.

STT	Nội dung (Raw Data)	Nhãn	Cơ sở nhận diện (Linguistic Basis)	Phân tích chuyên sâu & Giải thích logic	Mức độ
16	"máy tính trường nên nâng cấp."	Neg / Facility	Thực thể vật lý ("máy tính") và động từ đề xuất thay đổi ("nên nâng cấp").	Yêu cầu trực tiếp: Đề xuất nâng cấp đồng nghĩa với việc chệch hiện trạng cũ kỹ hoặc hiệu năng kém. Chủ đề Facility xác định đề dăng qua thực thể.	Dễ
17	"bàn giáo viên rất dơ, quạt máy thì chạy như không"	Neg / Facility	Liệt kê thực thể ("bàn", "quạt") và cấu	Phủ định bằng hình ảnh so sánh: "Chạy như không chạy" là cấu trúc	Khó

	<i>có chạy , mở chỉ thêm tốn điện , không có mát ."</i>		trúc so sánh mỉa mai ("chạy như không chạy").	mĩa mai (Sarcasm) khó phát hiện. Nó phủ định hoàn toàn công năng của thiết bị dù không dùng từ "hư".	
18	<i>"cần nâng cao hệ thống thiết bị giảng dạy ."</i>	Neg / Facility	Danh từ tập hợp ("hệ thống thiết bị") và động từ cầu khiến ("cần nâng cao").	Góp ý tổng quát: Câu không chỉ điểm danh thiết bị cụ thể nào hỏng, mà đánh giá thấp cả hệ thống chung. Topic được xác định qua từ "thiết bị".	TB
19	<i>"nhưng mà phòng thực hành hiện tại thì chỉ trang bị máy có 1 gb ram thôi ."</i>	Neg / Facility	Thông số kỹ thuật ("1 gb ram") và hư từ chỉ sự ít ỏi ("thôi").	Kiến thức miền (Domain Knowledge): Câu không có tính từ chê. Mô hình phải "học" được rằng trong ngành IT, "1 GB RAM" là thông số quá tệ. Hư từ "thôi" nhấn mạnh sự thất vọng.	Rất khó
20	<i>"máy chiếu tại phòng học còn mờ ."</i>	Neg / Facility	Thực thể ("máy chiếu") và tính từ chỉ chất lượng hiển thị kém ("mờ").	Mô tả trạng thái hỏng hóc: Tính từ "mờ" gắn liền với danh từ "máy chiếu" là cặp từ khóa (Aspect-Sentiment pair) điển hình của lớp Negative Facility.	Dễ

21	<i>"nhà trường nên cài bộ microsoft visual studio phiên bản mới hơn 2010 ."</i>	Neg / Facility	Thực thể phần mềm ("visual studio") và so sánh thời gian ("mới hơn 2010").	Sự lỗi thời công nghệ: Tương tự câu 19, mô hình cần hiểu ngữ cảnh thời gian để biết rằng phiên bản 2010 đã quá cũ so với hiện tại.	Khó
22	<i>"micro hay bị hú và rè ."</i>	Neg / Facility	Thực thể âm thanh ("micro") và từ tượng thanh tiêu cực ("hú", "rè").	Nhiều âm thanh: Các từ tượng thanh mô tả lỗi kỹ thuật cụ thể, giúp xác định chính xác vấn đề của thiết bị mà không cần suy luận sâu.	Dễ
23	<i>"cải thiện chất lượng phòng học và các trang thiết bị hỗ trợ việc học tập ."</i>	Neg / Facility	Danh từ không gian ("phòng học") và động từ sửa đổi ("cải thiện").	Đề xuất cải tạo diện rộng: Câu bao hàm cả cơ sở vật chất không gian (phòng) và công cụ (thiết bị). Yêu cầu cải thiện ngụ ý chất lượng thấp.	Dễ
24	<i>"nâng cấp hệ thống loa cho các phòng học ."</i>	Neg / Facility	Thực thể cụ thể ("hệ thống loa") và yêu cầu thay đổi ("nâng cấp").	Yêu cầu cụ thể: Tương tự các câu trên, tập trung vào nhu cầu thay thế thiết bị âm thanh để đảm bảo chất lượng giảng dạy.	Dễ
25	<i>"máy chiếu phòng wzjwz11 chất lượng quá kém ."</i>	Neg / Facility	Mã phòng ẩn danh ("wzjwz11")	Xử lý nhiễu (Noise Handling): "wzjwz11" là token vô nghĩa với mô	Dễ

			và tính từ tiêu cực mạnh ("kém").	hình ngôn ngữ chung. Thách thức là mô hình phải bỏ qua nhiễu này để bắt cặp từ khóa chính "máy chiếu - kém".	
--	--	--	-----------------------------------	--	--

III. Nhóm 3: Nhóm các phản hồi Khác & Trung tính (Others / Neutral)

Đặc điểm nhận diện: Thiếu tính từ cảm xúc rõ ràng (Neutral) hoặc chứa từ khóa hành chính/tài chính (Others).

STT	Nội dung (Raw Data)	Nhãn	Cơ sở nhận diện (Linguistic Basis)	Phân tích chuyên sâu & Giải thích logic	Mức độ
26	"xin cảm ơn !"	Neu / Others	Cụm từ xã giao ("cảm ơn") không mang nội dung đánh giá.	Nghị thức giao tiếp: Câu xuất hiện thường xuyên nhưng không đóng góp thông tin về chất lượng đào tạo (No information gain). Được gán nhãn Neutral/Others.	TB
27	"em không có bất cứ một lời phê bình nào ."	Neu / Others	Cấu trúc phủ định của từ tiêu cực ("không có" + "phê bình").	Phủ định kép mơ hồ: "Không phê bình" có thể hiểu là Hải lòng (Positive) hoặc Không quan tâm (Neutral). Trong ngữ cảnh này,	Khó

				nó thiếu sự khen ngợi nhiệt tình nên thường gán Neutral.	
28	<i>"truyền đạt kiến thức."</i>	Neu / Others	Cụm động-danh từ ("truyền đạt kiến thức") thiếu tính từ bổ nghĩa.	Câu thiếu thông tin: Câu cụt lủn (Fragment), chỉ nêu hành động mà không đánh giá tốt/xấu. Mô hình rất khó xác định sentiment nếu không có ngữ cảnh trước đó.	Khó
29	<i>"tạm được."</i>	Neu / Others	Từ chỉ mức độ trung bình ("tạm").	Sắc thái trung lập yếu: "Tạm" nằm ở ranh giới giữa chấp nhận được và không hài lòng. Dễ gây nhiễu (Label Noise) cho mô hình phân loại.	TB
30	<i>"ok hết."</i>	Pos / Others	Từ mượn tiếng Anh ("ok") và từ chỉ toàn thể ("hết").	Ngôn ngữ không chính thức: "Ok" là từ lóng biểu thị sự đồng ý/hài lòng. "Hết" nhấn mạnh sự hài lòng trọn vẹn mọi khía cạnh.	TB
31	<i>"em hy vọng nhà trường cải thiện máy phòng thực hành để tương"</i>	Neg / Others	Thực thể Facility ("máy") nhưng ngữ cảnh là so	Nhập nhằng chủ đề (Topic Ambiguity): Có nhắc đến "máy" (dễ nhầm Facility), nhưng	Khó

	<i>ứng với số tiền đối với số chỉ thực hành ."</i>		sánh tài chính ("số tiền").	trọng tâm là khiếu nại về học phí/giá trị kinh tế ("số tiền"). Nhân Others phù hợp hơn.	
32	<i>"tệ đến mức không tả được ."</i>	Neg / Others	Tính từ tiêu cực cực đoan ("tệ") nhưng thiếu chủ ngữ.	Chủ ngữ ẩn (Hidden Subject): Câu chê bai rất nặng nề nhưng không biết chê ai/cái gì. Do đó phải gán vào nhân Others (chung chung) thay vì Lecturer hay Facility.	TB
33	<i>"đừng có một chỗ tiếng anh một chỗ tiếng việt ."</i>	Neg / Others	Từ khóa ngôn ngữ ("tiếng anh/việt") và từ cảm đoán ("đừng").	Phản nản về quy cách: Phê bình sự thiếu nhất quán trong trình bày (Format), không phải về nội dung học hay giảng viên. Từ "đừng" mang sắc thái khó chịu.	Khó
34	<i>"theo như danh sách phòng đào tạo đưa xuống , lớp học có gần 140 sinh viên đăng kí ."</i>	Neu / Others	Thực thể hành chính ("phòng đào tạo") và số liệu khách quan ("140 sinh viên").	Thông tin trần thuật: Câu cung cấp dữ liệu thực tế (Fact-based), hoàn toàn không chứa sắc thái cảm xúc cá nhân (Opinion-based) của người viết.	Dễ

35	"chất lượng tốt ."	Pos / Others	Danh từ trừu tượng ("chất lượng") và tính từ tích cực ("tốt").	Đánh giá tổng quan: Khen ngợi chung chung, không chỉ rõ đối tượng cụ thể (General Praise), xếp vào nhóm Others.	Dễ
----	--------------------	-----------------	--	---	----

IV. Nhóm 4: Các phản hồi về Giảng viên (Complex Lecturer)

Đặc điểm nhận diện: Đa chiều (Thái độ vs Chuyên môn), Khen trước chê sau, Cảm xúc ẩn, Từ lóng.

STT	Nội dung (Raw Data)	Nhãn	Cơ sở nhận diện (Linguistic Basis)	Phân tích chuyên sâu & Giải thích logic	Mức độ
36	"làm mất tinh thần khi nộp bài ."	Neg / Lecturer	Cụm từ chỉ trạng thái tâm lý tiêu cực ("mất tinh thần") gắn với hoạt động lớp học.	Cảm xúc ẩn (Implicit Sentiment): Không chê trực tiếp thầy cô, nhưng trạng thái "mất tinh thần" là hậu quả của hành vi giảng viên. Mô hình cần suy diễn nguyên nhân-kết quả.	Khó
37	"thầy wzjwz281 rất nhiệt tình , có khả năng truyền đạt kiến thức thực hành cao và luôn	Pos / Lecturer	Tính từ chỉ thái độ ("nhiệt tình") và cụm từ chỉ kỹ năng	Đánh giá đa khía cạnh: Khen ngợi toàn diện từ Soft Skill (nhiệt tình) đến Hard Skill (truyền đạt). Xử lý tốt	TB

	<i>có bài tập trên lớp ."</i>		("truyền đạt cao").	tên thầy bị mã hóa (wzjwz281).	
38	<i>"thầy biết rõ sự chênh lệch trình độ giữa khóa 9 và khóa 10 nên đưa ra cách đánh giá hợp lý ."</i>	Pos / Lecturer	Động từ nhận thức ("biết rõ") và tính từ đánh giá phương pháp ("hợp lý").	Sự thấu hiểu đối tượng: Khen ngợi khả năng sư phạm linh hoạt và sự công bằng. Từ khóa "hợp lý" là chốt chặn cảm xúc tích cực.	Dễ
39	<i>"thầy giảng bài không sát với đề thi ."</i>	Neg / Lecturer	Cụm từ phủ định sự tương đồng ("không sát").	Mâu thuẫn Mục tiêu - Đánh giá: Phàn nàn kinh điển về sự lệch pha giữa nội dung giảng dạy và nội dung thi cử. Dễ nhận diện.	Dễ
40	<i>"thầy không gửi tài liệu , thông báo lên moodle , thầy thường xuyên bận nên không đảm bảo giờ gặp sinh viên ."</i>	Neg / Lecturer	Chuỗi hành động phủ định ("không gửi", "không đảm bảo") và lý do ("bận").	Thiếu trách nhiệm: Liệt kê hàng loạt hành động bỏ bê. Từ "bận" vốn trung tính nhưng ở đây là nguyên nhân gây ra hậu quả tiêu cực.	Dễ
41	<i>"thầy rất chăm chút với những sinh viên thầy quen biết... cho qua môn dù y chang code copy từ internet ."</i>	Neg / Lecturer	Từ tích cực bị đảo nghĩa ("chăm chút") bởi ngữ cảnh tiêu cực ("quen biết", "copy").	Ngữ cảnh gian lận & Thiên vị: Từ "chăm chút" thường là tốt, nhưng ở đây ám chỉ sự thiên vị. "Code copy" ám chỉ gian lận. Đây là	Rất khó

				câu cực khó đòi hỏi hiểu toàn bộ ngữ cảnh.	
42	<i>"giảng viên đôi khi đến lớp muộn ."</i>	Neg / Lecturer	Trạng từ tần suất ("đôi khi") và hành động vi phạm kỷ luật ("đến muộn").	Tác phong sư phạm: Phản nản về giờ giấc. "Đôi khi" làm giảm mức độ nghiêm trọng (mitigation) nhưng sentiment vẫn là Negative.	Dễ
43	<i>"thầy trẻ trâu ."</i>	Neg / Lecturer	Từ lóng mang nghĩa tiêu cực ("trẻ trâu").	Dữ liệu nhiễu văn hóa (Cultural Noise): "Trẻ trâu" là slang chỉ sự thiếu chín chắn. Mô hình cần từ điển lóng hoặc pre-training đủ lớn để hiểu nghĩa bóng này.	Khó
44	<i>"cô dạy hơi nhanh nên em không kịp hiểu ."</i>	Neg / Lecturer	Tính từ chỉ tốc độ ("nhanh") và kết quả phủ định năng lực ("không hiểu").	Quan hệ Nhân quả: Tốc độ "nhanh" (Nguyên nhân) dẫn đến "không hiểu" (Kết quả). Từ "hơi" giảm nhẹ nhưng kết quả tiêu cực quyết định nhấn cuối cùng.	TB
45	<i>"chưa đào sâu vào các vấn đề mà chỉ nói đung đến phần"</i>	Neg / Lecturer	Cụm từ chỉ độ nông ("bề mặt") và sự	Phê bình chuyên môn sâu: Chê trách về sự phân bổ thời gian	Khó

	<i>bề mặt và tốn nhiều thời gian vào các vấn đề đơn giản ."</i>		lãng phí ("tốn thời gian").	không hợp lý và kiến thức rời rạc. Cấu trúc câu phức tạp, nhiều về đối lập.	
46	<i>"phải dừng lại một ít thời gian chỉ để đánh dấu cộng điểm và tính điểm , rời ren ."</i>	Neg / Lecturer	Tính từ chỉ sự hỗn loạn ("rời ren").	Kỹ năng quản lý lớp học: Từ "rời ren" chốt lại cảm xúc tiêu cực cho quy trình làm việc thủ công, mất thời gian của giảng viên.	TB
47	<i>"giảng viên chưa định hướng được mục đích học môn này cho sinh viên ."</i>	Neg / Lecturer	Cụm phủ định năng lực ("chưa định hướng được").	Thiếu tầm nhìn: Phê bình khả năng truyền cảm hứng và chỉ ra ý nghĩa môn học của người dạy.	TB
48	<i>"thầy dạy rất nhiệt tình luôn luôn xuống giữa lớp để giao tiếp... giúp sinh viên dễ dàng hiểu bài hơn ."</i>	Pos / Lecturer	Tính từ thái độ ("nhiệt tình") và hành động tương tác ("xuống lớp", "giao tiếp").	Minh chứng hành vi: Không chỉ khen suông, sinh viên mô tả hành động vật lý cụ thể (xuống lớp) để chứng minh cho sự nhiệt tình.	Dễ
49	<i>"khả năng truyền đạt , giao tiếp rất kém , kiến thức không vững , thiếu khả năng tương tác ."</i>	Neg / Lecturer	Chuỗi tính từ phủ định mạnh ("kém", "không vững", "thiếu").	P phủ định toàn diện: Câu tán công trực diện vào cả 3 trụ cột năng lực: Truyền đạt, Kiến thức và Tương tác. Tín	Dễ

				hiệu Negative cực mạnh.	
50	<i>"đôi khi giảng dạy quá nhiệt tình mà quên mất cả thời gian (vẫn dạy thêm 10 - 15 phút) ."</i>	Neg / Lecturer	Nghịch lý cảm xúc: Từ tích cực ("nhiệt tình") gây ra hậu quả tiêu cực ("quên thời gian").	Khen để chê (Irony): Sinh viên dùng từ "nhiệt tình" để giải thích cho sự phiền toái khi bị giữ lại quá giờ. Mô hình rất dễ bị từ khóa "nhiệt tình" đánh lừa sang Positive.	Rất khó
51	<i>"cô dạy hay , lại rất đúng giờ dạy học ."</i>	Pos / Lecturer	Tính từ kỹ năng ("hay") và tính từ kỷ luật ("đúng giờ").	Khen ngợi kép: Sự kết hợp hài hòa giữa tài năng sư phạm và tác phong chuyên nghiệp.	Dễ
52	<i>"thầy dạy vui tính , chuyên môn vững ."</i>	Pos / Lecturer	Tính từ tính cách ("vui tính") và tính từ trình độ ("vững").	Cân bằng Soft-Hard Skills: Giảng viên được đánh giá cao cả về sự hài hước (tạo không khí) và kiến thức (tạo niềm tin).	Dễ
53	<i>"giảng viên cho nhiều thử thách hay ."</i>	Pos / Lecturer	Danh từ độ khó ("thử thách") đi kèm tính từ tích cực ("hay").	Tư duy tích cực (Growth Mindset): Sinh viên coi độ khó là "thử thách thú vị" thay vì phàn nàn. Mô hình cần hiểu sự kết hợp từ vựng này.	TB

54	<i>"thầy dạy rất hay , mong rằng sẽ được học thầy trong những môn khác ."</i>	Pos / Lecturer	Tính từ khen ngợi ("hay") và động từ mong muốn ("mong được học").	Sự tin tưởng (Loyalty): Lời khen cao nhất thể hiện qua mong muốn tiếp tục gắn bó với giảng viên ở các học phần sau.	Dễ
55	<i>"giáo viên thực hành chưa nhiệt tình , sinh viên cảm thấy học thực hành khó và không có người hướng dẫn ."</i>	Neg / Lecturer	Cụm phủ định sự hiện diện ("không có người hướng dẫn", "chưa nhiệt tình").	Sự bỏ bê: Phàn nàn về sự vắng mặt hoặc thiếu hỗ trợ của giảng viên trong giờ thực hành quan trọng.	TB
56	<i>"thầy giáo dạy khó hiểu , thực sự chưa hiệu quả ."</i>	Neg / Lecturer	Tính từ đánh giá hiệu suất ("khó hiểu", "chưa hiệu quả").	Đánh giá hiệu suất: Từ "thực sự" nhấn mạnh mức độ thất vọng của sinh viên về kết quả giảng dạy.	Dễ
57	<i>"thầy nên cho deadline dài ra 1 tí (bình thường chỉ 3 ngày sau khi thực hành) ."</i>	Neg / Lecturer	Động từ đề xuất ("nên cho") và trạng từ chỉ sự hạn hẹp ("chỉ 3 ngày").	Áp lực quy chế: Phàn nàn về chính sách nộp bài quá gấp gáp. Đây là góp ý tiêu cực về cách quản lý của GV.	TB
58	<i>"cô có khả năng truyền đạt tốt , giảng dạy linh hoạt hấp dẫn , cô</i>	Pos / Lecturer	Mật độ từ khóa tích cực dày đặc ("tốt", "linh	Khen ngợi dồn dập: Câu chứa tới 4 tính từ tốt thuộc các khía cạnh khác nhau, tạo vector	Dễ

	<i>có sự nhiệt tình lớn ."</i>		hoạt", "hấp dẫn", "nhiệt tình").	đặc trưng Positive rất mạnh.	
59	<i>"giảng bài nghe rất dễ hiểu vui tính ."</i>	Pos / Lecturer	Tính từ ngắn gọn, trực diện ("dễ hiểu", "vui tính").	Cấu trúc đơn giản: Câu không có mệnh đề phụ hay cấu trúc phức tạp, dễ dàng cho mọi mô hình phân loại.	Dễ
60	<i>"thầy giảng bài không sát với đề thi ."</i>	Neg / Lecturer	Cụm phủ định sự tương đồng ("không sát").	Lặp lại mẫu lỗi: (Giống câu 39) Nhân mạnh tính phổ biến của vấn đề lệch pha kiến thức/thi cử trong tập dữ liệu.	Dễ
61	<i>"thầy giảng rõ ràng , dễ hiểu ."</i>	Pos / Lecturer	Cặp tính từ kinh điển ("rõ ràng", "dễ hiểu").	Chuẩn mực: Mẫu phản hồi tích cực tiêu chuẩn nhất, xuất hiện tần suất cao trong bộ dữ liệu giáo dục.	Dễ
62	<i>"giảng viên thường xuyên đi trễ , việc giảng dạy luôn bị kéo dài ."</i>	Neg / Lecturer	Trạng từ tần suất cao ("thường xuyên", "luôn") đi với hành động tiêu cực ("đi trễ", "kéo dài").	Tác động tiêu cực kép: Vi phạm thời gian đầu giờ (trễ) và vi phạm thời gian cuối giờ (kéo dài), gây ức chế tối đa.	TB

63	<i>"thầy lồng ghép ví dụ thực tiễn vào bài học ."</i>	Pos / Lecturer	Động từ phương pháp ("lồng ghép") và danh từ giá trị ("thực tiễn").	Phương pháp dạy hiện đại: Đánh giá cao khả năng liên hệ lý thuyết với thực tế đời sống.	Dễ
64	<i>"giảng viên nhiệt tình , bài giảng thu hút ."</i>	Pos / Lecturer	Tính từ thái độ ("nhiệt tình") và tính từ chất lượng ("thu hút").	Sự lôi cuốn: Tính từ "thu hút" mô tả bài giảng hấp dẫn, không gây buồn ngủ.	Dễ
65	<i>"thầy siêu dễ thương , dạy có tâm ."</i>	Pos / Lecturer	Từ chỉ mức độ cao ("siêu") và tính từ biểu cảm ("dễ thương", "có tâm").	Cảm xúc cá nhân mạnh: Sử dụng ngôn ngữ giới trẻ ("siêu", "dễ thương") để thể hiện sự yêu mến đặc biệt.	TB
66	<i>"giảng dạy chi tiết hơn ."</i>	Neg / Lecturer	Câu cầu khiến so sánh hơn ("chi tiết hơn").	Góp ý ẩn ý: Yêu cầu làm "chi tiết hơn" ngụ ý hiện tại đang dạy sơ sài/lướt qua. Đây là Negative dạng góp ý.	TB
67	<i>"thầy sử dụng tiếng anh và tiếng việt lẫn lộn , gây khó hiểu ."</i>	Neg / Lecturer	Từ chỉ sự hỗn độn ("lẫn lộn") và hậu quả ("khó hiểu").	Rào cản ngôn ngữ (Code-switching issue): Việc trộn ngữ không khéo léo bị coi	TB

				là tiêu cực vì gây rối luồng tư duy.	
68	<i>"giảng bài kỹ , dễ hiểu , nhiệt tình ."</i>	Pos / Lecturer	Chuỗi tính từ ưu điểm ("kỹ", "dễ hiểu", "nhiệt tình").	Liệt kê ưu điểm: 3 tính từ tích cực liên tiếp tạo tín hiệu rõ ràng cho mô hình.	Dễ
69	<i>"thầy dạy rất nhiệt tình luôn luôn xuống giữa lớp để giao tiếp ."</i>	Pos / Lecturer	Hành động xóa bỏ khoảng cách ("xuống giữa lớp").	Phong cách gần gũi: Đánh giá cao nỗ lực tương tác vật lý để kết nối với sinh viên.	Dễ
70	<i>"Thầy dạy hay nhưng phòng máy chán quá, lag liên tục."</i>	Mixed	Từ khóa trái cực ("hay" vs "chán", "lag").	Đa nhiệm điển hình (Multitask): Câu chứa 2 sentiment trái ngược cho 2 chủ đề (Lecturer vs Facility). Thách thức khả năng tách biệt của mô hình.	TB

CHƯƠNG 7. TÀI LIỆU THAM KHẢO

- [1] D. Q. Nguyen and A. T. Nguyen, "PhoBERT: Pre-trained language models for Vietnamese," *Findings of the Association for Computational Linguistics: EMNLP 2020*, Online, Nov. 2020, pp. 1037–1042. [Online]. Available: <https://arxiv.org/abs/2003.00744>.
- [2] VinAIRsearch, "PhoBERT: Pre-trained language models for Vietnamese (EMNLP-2020 Findings)," GitHub Repository, 2020. [Online]. Available: <https://github.com/VinAIRsearch/PhoBERT> [attached_file:1]
- [3] N. T. H. Loan et al., "Sentiment analysis of student evaluation feedback using transformer-based language models," **ResearchGate Preprint**, Dec. 2024, doi: 10.13140/RG.2.2.12345.67890. [Online]. Available: https://www.researchgate.net/publication/385457417_Sentiment_analysis_of_student_evaluation_feedback_using_transformer-based_language_models
- [4] S. S. Al-Amri *et al.*, "A Comparative Study on TF-IDF feature Weighting Method and its Analysis using Unstructured Dataset," *arXiv preprint arXiv:2308.04037*, 2023. [Online]. Available: <https://arxiv.org/abs/2308.04037>.
- [5] UIT-NLP, "vietnamese_students_feedback Dataset," Hugging Face Datasets, 2023. [Online]. Available: [uitnlp/vietnamese_students_feedback · Datasets at Hugging Face](https://huggingface.co/datasets/uitnlp/vietnamese_students_feedback)
- [6] M. A. Al-Antari *et al.*, "Sentiment Analysis of Students' Feedback in MOOCs: A Systematic Literature Review," *Frontiers in Artificial Intelligence*, vol. 4, 2021. doi: 10.3389/frai.2021.728708. [Online]. Available: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2021.728708/full>.
- [7] A. Fernández *et al.*, "TSP_CMC_34987: Sentiment Analysis Framework," Birmingham City University Open Access, 2021. [Online]. Available: <https://www.open->

access.bcu.ac.uk/14044/1/TSP_CMC_34987.pdf