

SENTIMENT AND TOPIC ANALYSIS OF VIETNAMESE UNIVERSITY STUDENTS' COURSE EVALUATIONS

Xử lý ngôn ngữ tự nhiên – CS221.Q13

GVHD: TS. Nguyễn Trọng Chính

Nguyễn Việt Thắng – 22521339

Nguyễn Bá Long – 23520880

Tô Đặng Minh Tuấn – 24521942





Nội dung chính



-  1. **Giới thiệu bài toán**
-  2. **Bộ dữ liệu**
-  3. **Tiền xử lý**
-  4. **Phương pháp và công nghệ**
-  5. **Phương pháp đánh giá**
-  6. **Kết quả thực nghiệm**
-  7. **Kết luận**

1. Giới thiệu bài toán

Lý do chọn đề tài



- Nhu cầu thực tiễn: Phản hồi của sinh viên là kênh thông tin quan trọng để nhà trường đánh giá và cải thiện chất lượng đào tạo.
- Hạn chế của phương pháp hiện tại: Khối lượng dữ liệu lớn (hàng chục nghìn mẫu mỗi kỳ) khiến việc xử lý thủ công trở nên quá tải, tốn kém và dễ mang tính chủ quan.
- Thách thức về dữ liệu: Ngôn ngữ sinh viên sử dụng rất đặc thù, chứa nhiều nhiễu (teencode, từ lóng, viết tắt, pha trộn tiếng Anh) mà các công cụ thống kê truyền thống không xử lý hiệu quả.

1. Giới thiệu bài toán



Mục tiêu

Tìm hiểu triển khai và so sánh hiệu quả giữa các mô hình Transformer (như PhoBERT, mBert) với mô hình máy học truyền thống (TF-IDF + Logistic Regression). Mục tiêu là tìm ra giải pháp tối ưu nhất để phân loại đồng thời cảm xúc và chủ đề, giúp nhà trường tự động hóa quy trình đánh giá chất lượng giảng dạy.

2. Bộ dữ liệu

Nguồn dữ liệu:

https://huggingface.co/datasets/uitnlp/vietnamese_students_feedback

- Quy mô & Nguồn gốc: Bộ dữ liệu gồm hơn 16.000 câu phản hồi của sinh viên, được gán nhãn thủ công với độ tin cậy cao (Inter-annotator agreement > 91% cho cảm xúc).
- Cấu trúc nhãn đa nhiệm: Mỗi mẫu dữ liệu bao gồm 2 nhãn song song:
 - Cảm xúc (3 lớp): Negative (0), Neutral (1), Positive (2).
 - Chủ đề (4 lớp): Lecturer (0), Training_program (1), facility (2), Others (3).



Dataset Viewer Auto-converted to Parquet </> API Embed Duplicate Data Studio



Split (3)
train · 11.4k rows

Search this dataset

sentence string · lengths	sentiment class label	topic class label
slide giáo trình đầy đủ .	2 positive	1 training_program
hiệt tình giảng dạy , gần gũi với sinh viên .	2 positive	0 lecturer
đi học đầy đủ full điểm chuyên cần .	0 negative	1 training_program
chưa áp dụng công nghệ thông tin và các thiết bị hỗ trợ cho việc giảng dạy .	0 negative	0 lecturer
thầy giảng bài hay , có nhiều bài tập ví dụ ngay trên lớp .	2 positive	0 lecturer
giảng viên đảm bảo thời gian lên lớp , tích cực trả lời câu hỏi của sinh viên , thường...	2 positive	0 lecturer
em sẽ nợ môn này , nhưng em sẽ học lại ở các	1 neutral	3 others

< Previous 1 2 3 ... 115 Next >

2. Bộ dữ liệu



2. Bộ dữ liệu



Phân tích ngữ liệu

- **Ngôn ngữ không chuẩn mực:** Sử dụng nhiều teencode (ko, lun), từ lóng (vl) và từ viết tắt (gv).
- **Hiện tượng lai ngữ & Ký hiệu:** Xuất hiện thuật ngữ tiếng Anh (support) và icon (<3) mang sắc thái cảm xúc mạnh.
- **Tính đa nhiệm:** Một phản hồi lồng ghép nhiều khía cạnh (Facility, Training Program), đòi hỏi mô hình phân loại đa nhãn.
- **Cấu trúc phi chuẩn:** Độ dài không đều, ngữ pháp tự do, thách thức các mô hình thống kê truyền thống.

"cô dạy nhiệt tình <3, gv tâm huyết, hướng dẫn đồ án chi tiết lắm lun."

"phòng máy nóng vl, wifi ko support nổi, slide môn học thì dở tệ."

3. Tiền xử lý

1. Làm sạch văn bản (Cleaning)

- Loại bỏ nhiễu kỹ thuật: dùng Regex để xóa thẻ HTML, URL và emoji.
- Chuẩn hóa khoảng trắng: loại bỏ khoảng trắng thừa và khoảng trắng ở đầu/cuối câu.

2. Chuẩn hóa ngôn ngữ sinh viên (Normalization)

- Chuyển về chữ thường (lowercase).
- Bung từ viết tắt (teencode) bằng từ điển ABBR
- (ví dụ: ko → không, gv → giảng viên, sv → sinh viên).

3. Tách từ tiếng Việt (Word Segmentation)

- Sử dụng underthesea để ghép các âm tiết thành từ có nghĩa
- (ví dụ: giảng viên → giảng_viên).
- Mục tiêu: giúp PhoBERT nhận diện đúng từ và thực thể, tránh xử lý từng âm tiết rời rạc.

4. Mã hóa đầu vào (Tokenization)


- Dùng AutoTokenizer để chuyển văn bản thành input_ids.
- Tạo attention_mask để phân biệt token thật và token đệm (padding).

5. Chuẩn bị nhãn (Label Encoding)

- Cảm xúc (Sentiment): mã hóa thành số
- (0: Negative, 1: Neutral, 2: Positive).
- Chủ đề (Topic): mã hóa One-Hot bằng to_onehot_topic cho bài toán đa nhãn.


4. Phương pháp và công nghệ

Sơ đồ tổng quan phương pháp nghiên cứu



4. Phương pháp và công nghệ

Sơ đồ hệ thống triển khai



4. Phương pháp và công nghệ



01 TF-IDF (Trích xuất đặc trưng):

- Chuyển đổi văn bản feedback thành vector số.
- Đánh trọng số cao cho các từ khóa quan trọng/đặc trưng, lọc bỏ các từ quá phổ biến không mang ý nghĩa.

02 Logistic Regression (Phân loại):

- Thuật toán học máy thống kê, đơn giản, tốc độ huấn luyện nhanh.
- Hiệu quả cao với dữ liệu văn bản thưa (sparse data) từ TF-IDF.

→ **Mục tiêu:** Thiết lập mức hiệu năng chuẩn để đánh giá sự cải thiện của các mô hình Deep Learning (PhoBERT, mBERT).

TF-IDF Vectorizer:

- ngram_range: (1, 2)
- max_features: 50,000
- min_df: 2

Phân loại (One-Vs-Rest):

- Estimator: Logistic Regression
- max_iter: 2,000
- Threshold: 0.5 (mặc định)

4. Phương pháp và công nghệ

PhoBERT

- PhoBERT: Mô hình Tiên phong cho NLP Tiếng Việt
- Quy mô lớn: Mô hình đơn ngữ đầu tiên dựa trên kiến trúc RoBERTa mạnh mẽ với hai phiên bản: Base và Large.
- Phương pháp: Được huấn luyện trên 20GB dữ liệu văn bản không nén. Khác biệt với quốc tế, PhoBERT xử lý dữ liệu ở cấp độ từ (Word-level) thay vì âm tiết, giúp mô hình hiểu sâu sắc ngữ nghĩa tiếng Việt.
- Hiệu năng: Vượt trội XLM-R, đạt chuẩn SOTA trên 4 tác vụ NLP: Gán nhãn từ loại, Phân tích cú pháp, Nhận diện thực thể và Suy luận ngôn ngữ.
- Mã nguồn mở: Tương thích Fairseq và Transformers.

Architecture

- Backbone: vinai/phobert-base
- Alpha (α): 1.0
- Dropout: 0.1

Training

- Learning rate: $1e-5$
- Batch size: 16
- Epochs: 5
- Weight decay: 0.01
- Early stopping patience: 2

Preprocessing & inference

- Wordsegmentation: Underthesea
- Max length: 256 tokens
- Best topic threshold: 0.35 – 0.45 (validation)

4. Phương pháp và công nghệ



mBERT: Khả năng "Zero-shot" Đa ngôn ngữ

- Tổng quan: Một mô hình đơn nhất được huấn luyện trước trên 104 ngôn ngữ từ Wikipedia.
- Khả năng đặc biệt: Thực hiện tốt Zero-shot cross-lingual transfer (Huấn luyện trên ngôn ngữ A, kiểm thử trên ngôn ngữ B mà không cần dữ liệu huấn luyện của B).
- Cơ chế: Không chỉ ghi nhớ từ vựng, M-BERT học được cấu trúc ngữ nghĩa chung, cho phép chuyển giao tri thức giữa các ngôn ngữ khác hệ chữ viết (ví dụ: Anh sang Nhật).
- Yếu tố ảnh hưởng: Hiệu quả chuyển giao tốt nhất giữa các ngôn ngữ có tương đồng về loại hình học (ví dụ: cùng trật tự Chủ ngữ-Động từ-Tân ngữ).

Architecture

- Backbone: bert-base-multilingual-cased
- Alpha (α): 1.0


Training

- Learning rate: $1e-5$
- Batch size: 16
- Epochs: 5
- Weight decay: 0.01

Preprocessing & inference

- Word segmentation: None (WordPiece)
- Best topic threshold: 0.45

4. Phương pháp và công nghệ



5. Phương pháp đánh giá – Chỉ số đánh giá

Chỉ số cho Sentiment (Multi-class Classification)

Dùng để đánh giá khả năng phân loại 3 mức độ cảm xúc (Negative, Neutral, Positive):

- Accuracy (Độ chính xác tổng thể): Tỷ lệ các dự đoán đúng trên tổng số mẫu.
- Precision (Độ chính xác): Khả năng mô hình không gán nhãn nhầm một mẫu âm tính thành dương tính.
- Recall (Độ triệu hồi): Khả năng mô hình tìm thấy tất cả các mẫu dương tính thực sự.
- F1-Score: Giá trị trung bình điều hòa giữa Precision và Recall, cực kỳ quan trọng vì tập dữ liệu UIT-VSFC thường bị mất cân bằng nhãn.

Chỉ số cho Topic (Multi-label Classification)

Do một câu có thể thuộc nhiều chủ đề (Lecturer, Program, Facility, Others), ta sử dụng:

- Micro F1-score: Tính toán dựa trên tổng số TP, FP, FN trên toàn bộ các nhãn.
- Macro F1-score: Tính F1 riêng cho từng nhãn rồi lấy trung bình cộng.
- Hamming Loss: Tỷ lệ các nhãn bị dự đoán sai (nhãn đúng bị bỏ lỡ hoặc nhãn sai bị gán vào).

5. Phương pháp đánh giá – Chỉ số đánh giá

1. Macro Averaging

- Cách tính: Tính Precision/Recall/F1 riêng biệt cho từng lớp rồi lấy trung bình cộng đơn thuần.
- Ý nghĩa: Coi trọng mọi lớp như nhau. Chỉ số này giúp đánh giá xem mô hình có học tốt các nhãn thiểu số (như nhãn Neutral hoặc Topic Others) hay không.

$$F1_{macro} = \frac{1}{N} \sum_{i=1}^N F1_i$$

2. Weighted Averaging

- Cách tính: Tính chỉ số cho từng lớp, sau đó nhân với trọng số là tỷ lệ xuất hiện (support) của lớp đó trong dữ liệu.
- Ý nghĩa: Phản ánh hiệu năng thực tế của mô hình trên phân phối dữ liệu thật. Nếu các lớp chiếm đa số có điểm cao, Weighted F1 sẽ rất cao.



5. Phương pháp đánh giá – Công cụ trực quan hóa

1. Confusion Matrix (Ma trận nhầm lẫn)

- Sử dụng `sns.heatmap` để vẽ ma trận cho Sentiment.
- Giúp nhận diện mô hình đang bị nhầm lẫn giữa cặp nhãn nào (ví dụ: Nhầm Neutral sang Positive).

2. Training & Validation Loss Curves

- Biểu đồ đường (Line plot) thể hiện sự thay đổi của hàm mất mát qua từng Epoch.
- Dùng để kiểm tra hiện tượng Overfitting (khi Training Loss giảm nhưng Val Loss bắt đầu tăng).

3. Classification Report Heatmap

- Trực quan hóa bảng kết quả Precision, Recall, F1 dưới dạng màu sắc để nhanh chóng tìm ra "điểm yếu" của mô hình (nhãn nào có màu nhạt/điểm thấp).

5. Phương pháp đánh giá

Cách thức nhóm vận hành việc đánh giá.

- **Phân chia dữ liệu:**

- Sử dụng tập Train/Validation/Test .
- Đánh giá trên tập Test hoàn toàn mới để đảm bảo tính khách quan.

- **Threshold Tuning:**

- Đối với bài toán Topic Analysis: Nhóm thực hiện tinh chỉnh ngưỡng xác suất để tối ưu hóa F1-score cho các nhãn có ít dữ liệu.

- **Error Analysis:**

- Không chỉ dựa vào con số, nhóm còn kiểm tra trực tiếp các câu mô hình đoán sai để tìm nguyên nhân.


6. Kết quả thực nghiệm



Mô hình	Sentiment F1 (Macro)	Topic F1 (Micro)	Hamming Loss (Tốt)
TF-IDF + OVR LR (Baseline)	N/A	0.8621	0.0691
PhoBERT (Multitask)	0.7911	0.8817	0.0603
mBERT (Multitask)	0.7927	0.8853	0.0584





6. Kết quả - đánh giá mô hình



Biểu đồ Loss (Training vs. Validation Loss)




6. Kết quả – đánh giá mô hình



Ma trận nhầm lẫn (Confusion Matrix) cho Sentiment



6. Kết quả – đánh giá mô hình



Biểu đồ tìm ngưỡng tối ưu cho Topic.

Biểu đồ cho thấy F1-micro tăng nhanh khi threshold tăng từ 0.1 đến 0.3 và đạt cực đại tại threshold = 0.45. Sau ngưỡng này, hiệu năng gần như không thay đổi. Do đó, threshold = 0.45 được lựa chọn làm ngưỡng tối ưu vì đạt cân bằng tốt giữa Precision và Recall, đồng thời cho Hamming Loss thấp và Jaccard score cao.

6. Kết quả – đánh giá mô hình



Chỉ số	PhoBERT	mBERT
F1-micro	0.8817	0.8853
F1-macro	0.7661	0.7703
F1-samples	0.8872	0.8896
Hamming Loss	0.0603	0.0584
Jaccard Index (Samples)	0.8811	0.8841

Nhãn (Topic)	PhoBERT	mBERT
Lecturer (Giảng viên)	0.9375	0.9407
Facility (Cơ sở vật chất)	0.9017	0.9091
Training Program (Chương trình)	0.7589	0.7626
Others (Khác)	0.4662	0.4689



Cả hai mô hình Transformer đều đạt hiệu năng ấn tượng với F1-micro xấp xỉ 88% (mBERT nhỉnh hơn PhoBERT 0.36%), cho thấy khả năng nhận diện xuất sắc các chủ đề có từ khóa đặc trưng dù vẫn còn thách thức ở các nhãn dữ liệu có độ nhiễu cao và mất cân bằng.

7. Kết Luận



Thành Công

- Mô hình Multi-task tối ưu: Xây dựng thành công hệ thống "2 trong 1", vừa phân loại Cảm xúc vừa nhận diện Chủ đề với độ chính xác cao (F1-micro ~88%).
- Lợi thế từ Transformer: PhoBERT và mBERT hiểu rất tốt ngôn ngữ sinh viên, đặc biệt xuất sắc ở các chủ đề Giảng viên và Cơ sở vật chất (F1 > 90%).
- Chiến lược Threshold Tuning: Tìm được ngưỡng tối ưu giúp cải thiện đáng kể hiệu năng cho bài toán đa nhãn so với việc dùng ngưỡng 0.5 mặc định.

Khó Khăn

- Mất cân bằng dữ liệu: Nhãn "Khác" (Others) có kết quả thấp ($F1 < 0.5$) do thiếu mẫu và nội dung quá đa dạng, gây nhiễu cho mô hình.
- Rào cản ngôn ngữ: Mô hình vẫn bị "đánh lừa" bởi các câu so sánh (ví dụ: "số hai không ai số một"), mỉa mai hoặc các từ ngữ mang tính cảm thán riêng của sinh viên.
- Nhầm lẫn sắc thái: Ranh giới giữa Trung tính (Neutral) và Tích cực/Tiêu cực còn mong manh, dẫn đến việc mô hình hay bị nhầm nhãn khi câu có từ khóa tích cực nhưng ý nghĩa thực tế lại khác.

7. Kết Luận


Hướng phát triển

Dữ liệu: Bổ sung dữ liệu thực tế chứa teencode, tiếng lóng và áp dụng Data Augmentation để tăng tính đa dạng, khắc phục sự thiếu hụt độ "nhiều" của dữ liệu LLM chuẩn mực.

Tối ưu hóa: Áp dụng kỹ thuật Chưng cất mô hình (Knowledge Distillation) hoặc Lượng tử hóa (Quantization) để nén nhẹ PhoBERT, giúp tăng tốc độ suy luận và tiết kiệm tài nguyên khi triển khai.

Mở rộng: Phát triển khả năng nhận diện khía cạnh ẩn (Implicit Aspect Detection) nhằm hiểu sâu các phản hồi tinh tế không chứa từ khóa chủ đề trực tiếp.





**THANK
YOU!**

