

Predicting Citation Trends in Computer Science Publications

CS313 - Data Mining and Applications

 **Group 8** 


Member



23520854	Dương Tấn Lộc
23520865	Phạm Tài Lộc
23520872	Nguyễn Thắng Lợi
23520880	Nguyễn Bá Long
23520937	Nguyễn Hoàng Minh
23520961	Võ Hoàng Minh
23521061	Trần Ngọc Cẩm Nguyên
23521075	Huỳnh Ngọc Nhân

Table of Contents

- 1- Introduction
- 2 - Data Crawling
- 3 - EDA & Feature Engineering
- 4 - Model Training
- 5 - Evaluation





Group 8

1 - Introduction

1 - Introduction

Đặt vấn đề

Trong giáo dục đại học, việc đánh giá chất lượng nghiên cứu khoa học hiện nay vẫn chủ yếu dựa trên các **chỉ số đánh giá** sau công bố, điển hình là **số lượt trích dẫn**.

Điều này gây khó khăn cho các trường đại học, khoa và viện nghiên cứu trong việc đánh giá sớm tiềm năng của các công trình, phân bổ nguồn lực hiệu quả, và định hướng chủ đề nghiên cứu cho người học.



1- Introduction

Mục tiêu




Xây dựng phương pháp dự đoán mức độ phổ biến của bài báo khoa học trong ngành Khoa học Máy tính cụ thể là **số lượt trích dẫn trong những năm kế tiếp** nhằm:

- Đánh giá tiềm năng của các công trình nghiên cứu.
- Hỗ trợ sinh viên, học viên và giảng viên lựa chọn đề tài có ảnh hưởng.
- Cung cấp thông tin phục vụ hoạch định chính sách và hợp tác nghiên cứu.





Group 8



2- Data Crawling



2 - Data Crawling

Data Introduction

Dữ liệu được tổng hợp từ arXiv và làm giàu bằng trích dẫn (Semantic Scholar/Google Scholar) cùng xếp hạng venue (CORE/SCImago). Mỗi dòng là một bài báo, gồm title/abstract và các chỉ số trích dẫn để phục vụ EDA và dự đoán.



SEMANTIC **SCHOLAR**



Hugging Face

2 - Data Crawling

Công cụ hỗ trợ

BeautifulSoup

Phân tích và trích xuất dữ liệu từ code HTML, hỗ trợ xử lý source HTML tĩnh (tìm kiếm, trích xuất nội dung từ các tag...).

 Selenium

Tự động hóa duyệt web, mô phỏng thao tác người dùng như click, nhập liệu, cuộn trang... kết hợp với BeautifulSoup để crawl dữ liệu.



Group 8



3 - EDA & Data Preprocessing



3 - EDA & Data Preprocessing

Dữ liệu tổng quan

15,959 rows


Mỗi dòng tương ứng một bài báo khoa học (arXiv_id), gồm title/abstract/categories và các metadata liên quan.

26 columns


Mỗi cột là một thuộc tính của bài báo: thông tin nội dung, thời gian công bố, venue/ranking và các chỉ số trích dẫn/phổ biến.

3 - EDA & Data Preprocessing

Topic-related	Metadata	Popularity in Application
title	venue_type	citing_datasets
abstract	citations_by_year	citing_collections
categories	influentialCitationCount	citing_spaces
primary_category	authors	github_stars
keywords	num_revisions	upvote
	num_pages	citing_model
	citations	
	citationCount	
	referenceCount	
	references	
	published_date	
	venue_ranking	



3 - EDA & Data Preprocessing




Nhận xét:

Biểu đồ cho thấy phân phối trích dẫn bị **lệch phải nặng**,
→ Dữ liệu bị lệch mạnh khiến trung bình sai lệch, khó quan sát xu hướng và làm giảm độ chính xác của mô hình.

Biểu đồ thể hiện phân phối citation_count

3 - EDA & Data Preprocessing



Biểu đồ thể hiện phân phối $\log_citation_count$

★ Phương pháp xử lí

log transform:


$\log(1 + \text{citationCount})$

- Giảm ảnh hưởng của các giá trị.
- Làm phân bố dữ liệu cân đối và gần chuẩn hơn [1].

→ Nhờ **log transform**, các mô hình thống kê/hồi quy hoạt động ổn định và chính xác hơn.

[1] Changyong, F. E. N. G., et al. "Log-transformation and its implications for data analysis." Shanghai archives of psychiatry 26.2 (2014): 105.

3 - EDA & Data Preprocessing




Phân bố số lượng citation theo venue_ranking
trước khi xử lí outliers

Nhận xét:

Citations (log-scale) tăng theo chất lượng venue: A*/A và Q1 có median cao hơn B/C, Q2–Q3. Nhóm **Other** có độ phân tán và outliers lớn nhất, cho thấy tính không đồng nhất/khả năng nhiều trong phân loại venue.

3 - EDA & Data Preprocessing



Phân bố số lượng citation theo venue_ranking
sau khi xử lý outliers

🌟 Phương pháp xử lý

Gán lại '**venue_ranking**' cho những bài có trích dẫn vượt trội trong cột 'Other' bằng nhóm có **median citations** gần nhất.

→ Giúp giảm sai lệch do phân loại chưa chính xác và duy trì tương quan hợp lý giữa venue_ranking và mức trích dẫn.

3 - EDA & Data Preprocessing

Phương pháp xử lí:

Trường dữ liệu	Vấn đề	Cách xử lý	Giải thích
num_pages	Có giá trị null	Loại bỏ bản ghi có num_pages null	Tránh đưa các mẫu thiếu thông tin cấu trúc cơ bản vào phân tích/mô hình.
github_stars	Thiếu rất nhiều	Fill = 0	Nếu không có metadata GitHub, giả định bài báo không public code hoặc không có stars.
venue_type	Thiếu	Fill = "preprint"	Thiếu venue thường là bài đăng dạng preprint trên arXiv.
venue_ranking	Thiếu	Fill = 0	Các venue chưa được xếp hạng gán 0 để phân biệt với các mức ranking khác.
arxiv_id	Trùng lặp	Drop duplicates theo arxiv_id	Giữ một bản ghi đại diện (keep first) để tránh “nhân đôi” dữ liệu.
title, abstract	Có thể thiếu	Fill = chuỗi rỗng khi tạo text features	Đảm bảo vectorizer chạy ổn định và không lỗi do NaN.
keywords	Thiếu rất nhiều	Không xử lý/dùng trong mô hình	Trong 2 file code hiện tại, keywords không được dùng để tạo đặc trưng → pipeline text dựa vào title và abstract. (Không có bước “drop keywords” trong code.)
primary_category, venue_type, venue_ranking...	Dữ liệu dạng phân loại	Label Encoding	Cách tiếp cận phổ biến

Data Mining


Text Mining – Topic discovery với BERTopic

Dữ liệu:

- Text-related Features: Title, Abstract

Objectives:


- Khai thác chủ đề tiềm ẩn từ dữ liệu văn bản (như tiêu đề và tóm tắt bài báo), nhằm hiểu cấu trúc nội dung và xu hướng nghiên cứu chi tiết hơn.



Text Mining - BERTopic

Kiến trúc chung

- **Embedding:** Sử dụng SentenceTransformer để chuyển đổi văn bản thành vector dạng số
- **UMAP:** Thuật toán giúp giảm chiều của vector
- **HDBSCAN:** Thuật toán tự động tìm ra các dữ liệu tương tự nhau rồi xếp thành 1 nhóm
- **Topic Representation:** Sử dụng kỹ thuật c-TF-IDF để tìm ra những từ khóa "đặc trưng nhất" cho từng nhóm



Text Mining - BERTopic

Cách thức thực hiện

- **Data split:**
 - Tách riêng feature dạng số và dạng text (title và abstract)
 - Chia dữ liệu thành 2 tập train (80%) và test (20%)
- **Text Features:**
 - Áp dụng BERTopic cho riêng title và abstract của tập train

Kết quả

BERTopic xác định có **83 chủ đề** cho title và **118 chủ đề** cho abstract

Text Mining - BERTopic

Cách thức thực hiện


- **Title:**

- TOPIC 0: (learning, bayesian, machine learning, machine, classification, inference, supervised, label, gradient, sparse)
- TOPIC 1: (neural, neural networks, deep, neural network, convolutional, networks, convolutional neural, deep neural, deep learning, network)
- TOPIC 2: (3d, pose, image, estimation, point, reconstruction, resolution, shape, depth, super)

- **Abstract:**


- TOPIC 0: (software, logic, code, program, proof, programming, semantics, systems, automata, testing)
- TOPIC 1: (graphs, graph, vertex, problem, vertices, approximation, log, algorithm, number, polynomial)
- TOPIC 2: (cloud, memory, computing, performance, storage, parallel, systems, data, cache, workloads)

Text Mining - BERTopic




Text Mining - BERTopic

Xu hướng phát triển Top 10 Chủ đề của TITLE (2012 - 2024)



Text Mining - BERTopic

**Sức hút trung bình của Top 10 Chủ đề qua các năm
(Dựa trên lượng trích dẫn nhận được trong từng năm)**



Text Mining - BERTopic

Feature engineering

- Khi phân nhóm BERTopic sẽ gán mỗi văn bản theo 1 chủ đề kèm theo tỉ lệ xác suất thuộc chủ đề đó
- Áp dụng One-hot-encoding lên các chủ đề kèm theo cột xác suất gán vào dữ liệu

title_81	title_prob	abstract_1	abstract_p
0	0.108885	1	0.006969
0	0.095321	0	0.264344
0	0.077833	0	0.4515
0	0.110947	0	1
0	1	1	0.078442
0	0.014637	0	0.09155
0	0.059614	0	0.242145
0	0.01692	0	0.182497
0	0.09129	0	0.086633

Data Mining

Temporal Data Mining


- **Dữ liệu:** Cấu trúc thời gian của trích dẫn (citations_by_year).
 - Tính tốc độ tăng trưởng (**Slope**) về số lượng công bố và trích dẫn của danh mục và chủ đề.
- Nắm bắt quy luật biến đổi thời gian để làm đầu vào cho mô hình RNN dự báo tầm ảnh hưởng.

category	slope_papers	slope_citations
cs.CV	9,55	1043,98
cs.LG	5,60	273,42
cs.CR	3,63	63,29
cs.CL	8,77	46,68
cs.NI	2,64	35,75
...	...	...

topic	slope_papers	slope_citations
54	0,27	64,78
2	6,57	64,74
5	2,94	48,96
48	1,52	31,34
116	0,57	28,62
...	...	...

Data Leakage

Để tránh Data Leakage (rò rỉ dữ liệu), chúng em chỉ xem xét khoảng thời gian từ **năm cần dự đoán (2020-2024)** trở về trước, các feature **'citationCount', 'citations_by_year', 'slope_papers_trend', 'slope_citations_trend'** được xử lý để không chứa thông tin trong các năm sau.



Kết quả

- Sau khi xử lý dữ liệu và feature engineering, dữ liệu mới gồm **237 cột**

```
print(f"Final Train Shape: {X_train_final_bt.shape}")  
print(f"Final Test Shape: {X_test_final_bt.shape}")
```

```
Final Train Shape: (11781, 237)  
Final Test Shape: (2946, 237)
```



Group 8



4 - Model Training



4 - Model Training


Mô hình RNN-based

- Simple RNN
- Long Short-Term Memory (LSTM)
- Gated Recurrent Unit (GRU)

4 - Model Training

Kiến trúc chung

- **Nhánh thứ nhất** dùng để xử lý chuỗi dữ liệu time series.
- **Nhánh thứ hai** dùng để xử lý các đặc trưng tĩnh.



6 - Model Training

Input

- **Dynamic Features:**
 - Lịch sử số lượt trích dẫn của bài báo theo từng năm từ 2012 đến 2019.
 - Được biểu diễn dưới dạng chuỗi thời gian, dùng để mô tả xu hướng tăng trưởng citation theo thời gian.
- **Static Features:**
 - Đặc trưng tĩnh của bài báo (chủ đề, số trang, tác giả...).

Target

Số lượng trích dẫn của các năm mục tiêu (2020 - 2024).



Group 8



5 - Evaluation




5 - Evaluation

Đánh giá khả năng dự đoán dài hạn





- Có học được xu hướng trích dẫn dài hạn
- Có thích nghi với sự thay đổi phân phối dữ liệu theo thời gian
- Hay chỉ phù hợp cho dự đoán ngắn hạn ngay sau thời điểm huấn luyện

Phương pháp đánh giá



5 - Evaluation





Sai số dự báo tăng dần theo thời gian do cơ chế đệ quy, khiến sai số của năm trước bị tích lũy và khuếch đại sang năm kế tiếp.



5 - Evaluation

Đánh giá RNN, LSTM, GRU trên tập test:

- **LSTM** cho kết quả đánh giá tốt nhất trên 4 metric từ 2021-2023 (thấp hơn GRU ở 2024)
- **MAE** tăng dần từ 3.2 → 7.8 qua các năm
- **R-squared**: giảm dần từ 0.99 → 0.75 cho thấy model nắm bắt được xu hướng chung của dữ liệu
- **RMSE**: 43.2 → 248.8 khá cao, cho thấy mô hình bị ảnh hưởng nặng nề bởi các sai số lớn từ nhóm bài báo có trích dẫn đột biến




5 - Evaluation


Đánh giá RNN, LSTM, GRU trên tập test:

- **RMSE:** tăng 43.2 → 248.8 khá cao, cho thấy mô hình bị ảnh hưởng nặng nề bởi các sai số lớn từ nhóm bài báo có trích dẫn đột biến

Comparison of Actual vs Predicted Citations for Top 4 Articles (2024)



Phân bố Sum of Squared Error (SSE) theo nhóm bài báo
Remaining 99%



Sum of square error (SSE) toàn bộ: **237,934.93**
SSE riêng nhóm top 1%: **215,098.24**
⚠️ Nhóm 1% bài báo có citation cao nhất đóng góp: 90.40% vào tổng lỗi.

5 - Evaluation

Phân tích xu hướng dự đoán

- Dự đoán của mô hình có xu hướng lệch thấp khi dự đoán dài hạn
- Giá trị dự đoán thường giảm nhanh hơn so với thực tế

Nguyên nhân




- Dữ liệu citation có phân phối lệch phải mạnh (right-skewed) → phần lớn bài báo có rất ít trích dẫn
- Mô hình học theo mẫu số đông, dù đã áp dụng log-transform và MSLE

Hệ quả


- Các bài có citation cao → thường bị đánh giá thấp.

Bias

- Mô hình thể hiện xu hướng thiên lệch giảm về gần 0, do bộ dữ liệu phần lớn các bài báo có số lượt trích dẫn thấp.



5 - Evaluation



Phân tích mức độ đóng góp của các đặc trưng (SHAP):

- **Yếu tố then chốt:** Lịch sử trích dẫn gần nhất (citations_2019) và tuổi đời bài báo (num_years_after_pub) là hai biến có tác động lớn nhất đến dự đoán
- **Tính tự hồi quy:** Mô hình phụ thuộc vào citations của quá khứ hơn là nội dung nghiên cứu.
- **Vai trò của Metadata:** Uy tín tác giả (h-index) và thứ hạng tạp chí (venue_ranking) có đóng góp nhưng thấp hơn lịch sử số lượng citation.
- **Thông tin ngữ nghĩa:** Các đặc trưng từ tiêu đề và tóm tắt bài báo có ảnh hưởng không lớn đến kết quả dự đoán của mô hình.

5 - Evaluation

- **Hiệu quả:** Cung cấp baseline ổn định cho dự đoán trích dẫn.
- **Thách thức:** Khó dự đoán các công trình có tác động đột phá.
- **Bản chất:** Mô hình dựa trên số citation trong quá khứ và metadata (tác giả, tiêu đề, tóm tắt) thay vì nội dung khoa học cốt lõi mà bài báo đóng góp.

→ Nên coi đây là một **nguồn thông tin dự đoán tham khảo**, hỗ trợ đánh giá xu hướng, thay vì coi đó là kết luận cuối cùng về tầm ảnh hưởng của nghiên cứu.



Group 8



Demo





Group 8

