




RAG-BASED LECTURE VIDEO Q&A SYSTEM

CS431.Q22 – Các kỹ thuật học sâu và ứng dụng
GVHD: TS. Nguyễn Vinh Tiệp


Group 10

Dương Thái Ý Nhi – 23521106
Nguyễn Bá Long – 23520880
Lương Quang Duy – 23520368



CONTENT

1. **PROBLEM STATEMENT**
2. **PROBLEM FORMULATION**
3. **SYSTEM METHODOLOGY**
4. **DATASET**
5. **EVALUATION**
6. **IMPLEMENTATION**



PROBLEM STATEMENT

Chương 3: Mạng Convolutional Neural Network (CNN)

Một số thành phần của mạng CNN - Part 2

5 / 9

[CS431 - Tuần 3] Nội dung

- Giới thiệu mạng...
- Slide
- Một số thành phần...
- Slide
- Một số thành phần...
- Slide
- Thực quan hóa...
- Thực quan hóa...
- Slide

Tầng activation – Hàm ReLU

- Trong CNN, tầng ReLU thường theo sau tầng convolution
- Ngoài ReLU, ta có thể dùng các hàm khác: sigmoid, tanh,...

huyền thần

lọc ~ thông tin đi cần thiết

$R(z) = \max(0, z)$

$z < 0$

INPUT CONVOLUTION + RELU POOLING CONVOLUTION + RELU POOLING FLATTEN CO FULL CONNECTION SOFTMAX

FEATURE LEARNING CLASSIFICATION

Thực hiện bởi Trường Đại học Công nghệ Thông tin, ĐHQG-HCM

Ôn tập kiến trúc mạng CNN và một số biến thể phổ biến hiện nay - Part 1

1 / 10

Ôn tập kiến trúc mạng CNN và một số biến thể phổ biến hiện nay - Part 1

LeCun, Yann, et al. "Gradient-based learning applied to document recognition." Proceedings of the IEEE, 1998.


Thực hiện bởi Trường Đại học Công nghệ Thông tin, ĐHQG-HCM

Ôn tập kiến trúc mạng CNN và một số biến thể phổ biến hiện nay - Part 1

1 / 10


Sử dụng mạng huấn luyện sẵn

9 / 10



PROBLEM FORMULATION

INPUT



- **Kho dữ liệu**

Tập hợp các video bài giảng thô $V=\{v1,v2,...,vN\}$ (gồm luồng hình ảnh (slide bài giảng) và luồng âm thanh (lời giảng viên) diễn ra liên tục theo trục thời gian.).

- **Truy vấn**

Ký hiệu là q , là một truy vấn được phát biểu dưới dạng ngôn ngữ tự nhiên từ phía sinh viên

Hệ thống phải trả về đồng thời 2 thành phần:


- **Câu trả lời (α)**

Một đoạn văn bản giải thích chính xác, mạch lạc và bám sát hoàn toàn vào ngữ cảnh bài giảng.

- **Tập nguồn tham chiếu (R)**

Ký hiệu là $R=\{(vk, tk)\}$, trong đó vk là định danh (ID) của video và tk là mốc thời gian (timestamp) cụ thể chứa nội dung tri thức được truy xuất.


OUTPUT



SYSTEM METHODOLOGY - RETRIEVAL AUGMENTED GENERATION (RAG)



RAG (Retrieval-Augmented Generation) là kỹ thuật kết hợp việc truy xuất dữ liệu từ các nguồn và mô hình sinh ngôn ngữ để tạo ra câu trả lời cho người dùng.

RAG Đảm bảo độ chính xác và cập nhật, tối ưu chi phí.




SYSTEM METHODOLOGY - PIPELINE


DATA PREPROCESSING & INDEXING



RETRIEVAL & ANSWER GENERATION



SYSTEM METHODOLOGY - PREPROCESS & INDEXING



Frames Extraction: 20s interval


Frame Deduplication: Structural similarity

Optical Character Recognition (OCR): Qwen/Qwen2-VL-2B-Instruct


Audio Extraction: ffmpeg

Automatic Speech Recognition (ASR): openai/whisper-large-v3

Merge & Refine




LLM refine: sửa lỗi OCR/ASR, chuẩn hóa thuật ngữ, trình bày rõ ràng bằng bullet points, giữ logic nối tiếp, và xuất ra Markdown đúng cấu trúc.




SYSTEM METHODOLOGY - PREPROCESS & INDEXING

Một chunk bao gồm:

```
{  
  • "chunk_id": "94a96fbc-7549-476b-a221-f26ef979558b",  
  • "video_id": "1a403451-02a2-4675-b725-99b24d7e700b",  
  • "video_name": "[CS431 - Các kĩ thuật học sâu và ứng dụng] Video 1.3.1 Ôn tập nền  
    tảng đại số tuyến tính (Part 1)",  
  • "timestamp": 0,  
  • "duration": 20,  
  • "content": "### Nội dung Slide\n\n* **Giới thiệu môn học**\n\n* Lịch sử hình thành  
    và thành tựu AI\n\n* **Ôn tập n..**\n"}  
}
```



● SYSTEM METHODOLOGY - RETRIEVAL & GENERATION



Guardrail Routing & Query Transformation

- Guardrail: Kiểm tra câu hỏi người dùng có liên quan đến bài học không.
- Query Transformation: Tạo tài liệu giả định (HyDE)

Hybrid Retrieval


- Semantic Search: Mô hình Nhúng (intfloat/multilingual-e5-large; BAAI/bge-m3; gemini-embedding-2-preview, AITeamVN/Vietnamese_Embedding).
- Keyword Search: BM25.
- Hợp nhất: Thuật toán RRF (Reciprocal Rank Fusion).

Cross-Encoder Reranking

- Mô hình Cross-Encoder: BAAI/bge-reranker-v2-m3

Generator


- gemini-2.5-flash-lite



DATASET

Hệ thống video bài giảng các kỹ thuật học sâu và ứng dụng lấy từ course CS431

10 chương học với nhiều thuật ngữ chuyên ngành, gồm 55 video bài giảng



DATASET

Kết quả xử lý dữ liệu: 757 chunks

▼ [CS431 - Các kỹ thuật học sâu và ứng dụng] Video 1.1 Giới thiệu môn học
ID: 9600cf72-a9e5-4ec9-9533-b1b49e661cb9

ID: 5b9d4eaa-0dab-4344-a9c9-e70041543f59

🕒 0:00

Nội dung Slide

- **CS431 - Các kỹ thuật học sâu và ứng dụng**
- **Giới thiệu môn học**
 - Giảng viên: TS. Nguyễn Vinh Tiếp
 - Khoa: Khoa học Máy tính
 - Thực hiện bởi: Trường Đại học Công nghệ Thông tin, ĐHQG-HCM

Lời giảng của Giảng viên

Chào mừng các bạn đến với môn học **CS431 - Các kỹ thuật học sâu và ứng dụng**.

Hôm nay chúng ta sẽ bắt đầu với bài học đầu tiên, bài mở đầu. Tôi xin tự giới thiệu, tôi là Nguyễn Minh Tiếp, hiện đang là Trưởng phòng Thí nghiệm Truyền thông Đa Phương Tiện tại Đại học Công nghệ Thông tin, Đại học Quốc gia TP.HCM.

Nội dung chính của bài học hôm nay sẽ gồm ba phần:

1. Giới thiệu tổng quan về môn học.
2. Lịch sử hình thành **trí tuệ nhân tạo (AI)** nói chung và **học sâu (Deep Learning)** nói riêng.
3. Thảo luận về một số thành tựu nổi bật của **AI** và **học sâu**.

EVALUATION - METRICS

Để đánh giá mô hình RAG có hoạt động tốt hay không, nhóm đánh giá mô hình thông qua các độ đo sau đây:

KHÂU TRUY XUẤT (RETRIEVAL METRICS)


Đánh giá khả năng tìm kiếm phân đoạn & mốc thời gian

- Precision: $\frac{|S_{gt} \cap S_{pred}|}{|S_{pred}|}$
- Recall: $\frac{|S_{gt} \cap S_{pred}|}{|S_{gt}|}$
- MAP: $AP = \frac{1}{|S_{gt}|} \sum_{k=1}^n (P@k \times rel(k))$

KHÂU TẠO SINH (GENERATION METRICS):

Đánh giá bằng Framework RAGAS (LLM-as-a-Judge)

- Faithfulness: Đảm bảo câu trả lời được sinh ra từ tài liệu truy xuất.
- Answer Relevance: Mức độ trả lời đúng trọng tâm câu hỏi.



EVALUATION – DATA PREPARATION

Tổng quan đánh giá: 90 câu hỏi – 9 chương (2-10)

Chương 4	[CS431 - Chương 4] Part 1_4_ Ôn tập kiến trúc mạng CNN và một số biến thể phổ biến hiện nay	Bản chất của phép biến đổi Depthwise Separable Convolution (DSC) trong kiến trúc mạng MobileNet bao gồm những bước cơ bản nào?	Phép biến đổi Depthwise Separable Convolution (DSC) trong mạng MobileNet được thực hiện thông qua hai bước cơ bản tách biệt nhau. Bước đầu tiên là Depthwise Convolution, trong đó mô hình sẽ áp dụng các bộ lọc một cách độc lập trên từng kênh (độ sâu) của feature map đầu vào rồi nối các kết quả lại. Bước thứ hai là Pointwise Convolution, hệ thống sẽ sử dụng các bộ lọc kích thước 1x1 để thực hiện phép tích chập bình thường nhằm thay đổi độ sâu của feature map đầu ra.	0:20, 1:20
	[CS431 - Chương 4] Part 1_4_ Ôn tập kiến trúc mạng CNN và một số biến thể phổ biến hiện nay	Trong kiến trúc mạng ResNet, việc cộng thêm dữ liệu đặc trưng gốc (x) vào kết quả đầu ra mang lại ý nghĩa gì theo lý thuyết về mật thông tin?	Theo lý thuyết về mật thông tin, thao tác cộng thêm đặc trưng gốc (x) vào đầu ra trong kiến trúc ResNet đóng vai trò cực kỳ quan trọng. Việc cộng này giúp mô hình kết hợp hài hòa giữa những đặc trưng mới vừa được rút trích và những đặc trưng nguyên bản ban đầu của dữ liệu. Sự kết hợp này làm cho luồng thông tin trở nên đầy đủ và phong phú hơn. Từ đó, nó giải thích được tính hiệu quả của ResNet trong việc tăng cường độ chính xác cho quá trình nhận diện.	9:40, 11:00
	[CS431 - Chương 4] Part 2_ Sử dụng mạng huấn luyện sẵn	Khi áp dụng chiến lược học chuyển tiếp (Transfer Learning), cách tiếp cận "sử dụng trực tiếp" có những ưu điểm và rủi ro gì đối với dữ liệu người dùng?	"Sử dụng trực tiếp" là cách tiếp cận ngây thơ và đơn giản nhất, trong đó người dùng lấy thẳng mô hình đã được huấn luyện trên tập dữ liệu lớn để nhận diện dữ liệu của mình, với điều kiện các nhãn phân loại trùng khớp nhau (như chó, mèo, ngựa). Tuy nhiên, rủi ro lớn nhất là dữ liệu thực tế ở khu vực của người dùng có thể mang những đặc điểm giống loài và phân bố khác với tập dữ liệu chuẩn. Do sự khác biệt này, mô hình có khả năng không đạt được độ chính xác cao như kỳ vọng ban đầu.	08:00, 08:20
	[CS431 - Chương 4] Part 2_ Sử dụng mạng huấn luyện sẵn	Trong phương pháp học chuyển tiếp, làm thế nào để tận dụng mạng CNN huấn luyện sẵn như một bộ rút trích đặc trưng kết hợp với thuật toán KNN?	Để tận dụng CNN làm bộ rút trích đặc trưng, người ta sẽ loại bỏ đi lớp phân lớp cuối cùng của mạng huấn luyện sẵn (ví dụ ResNet-50) và chỉ lấy vector đặc trưng (feature vector) được sinh ra từ giai đoạn trước đó. Với vector đặc trưng này, ta có thể kết hợp với các mô hình máy học khác như thuật toán K-Nearest Neighbors (KNN). Cụ thể, khi có một mẫu dữ liệu mới, hệ thống sẽ tính toán đặc trưng, tìm ra K điểm gần nhất trong không gian và dùng cơ chế biểu quyết (voting) dựa trên nhãn của các điểm đó để đưa ra kết luận.	02:20, 02:40, 03:40




EVALUATION RESULT


Model Embedding	Precision	Recall	MAP	Faithfulness	Ans. Relevancy
multilingual-e5-large	0.1655	0.6067	0.4640	0.9596	0.8882
gemini-embedding-2	0.1888	0.6885	0.4864	0.9496	0.8832
bge-m3	0.1544	0.5854	0.4427	0.9583	0.8371
Vietnamese_Embedding	0.1544	0.5740	0.4288	0.9625	0.7644

Nhận xét

- gemini-embedding-2 mạnh nhất về khả năng tìm kiếm.
- Vietnamese_Embedding có độ trung thực cao nhất nhưng khả năng truy xuất dữ liệu lại kém nhất trong bảng.
- Chỉ số Precision chung của các mô hình đều thấp, lý do số ground truth trong eval data khá ít chunks.
- generator ít bị ảo giác, câu trả lời chứa ít thông tin dư thừa.



IMPLEMENTATION



DEMO



THANK YOU



