

DashBot: Insight-Driven Dashboard Generation Based on Deep Reinforcement Learning

Tác giả gốc: Dazhen Deng, Aoyu Wu, Huamin Qu, Yingcai Wu

Giáo viên hướng dẫn: TS. Lương Ngọc Hoàng

Sinh viên thực hiện:

23520880	Nguyễn Bá Long
20521170	Nguyễn Quốc Đạt
23521355	Nguyễn Nhật Sơn

Trường Đại học Công nghệ Thông tin - ĐHQG-HCM

Ngày 16 tháng 7 năm 2026

Nội dung trình bày

1. Giới thiệu
2. Các nghiên cứu liên quan
3. Khảo sát sơ bộ & Yêu cầu thiết kế
4. Công thức hóa bài toán (MDP)
5. Thiết kế hàm phần thưởng
6. Thiết kế mô hình học sâu
7. Đánh giá
8. Thảo luận và Hạn chế
9. Kết luận

1.1 Bảng điều khiển phân tích và bài toán thực tế

- **Bảng điều khiển phân tích** là một công cụ phổ biến trong lĩnh vực Business Intelligence, giúp tổng hợp nhiều biểu đồ trên một màn hình để hỗ trợ việc khám phá và trực quan hóa dữ liệu dưới nhiều góc nhìn.
- Tạo dashboard hiệu quả đòi hỏi người dùng phải có:
 - Kiến thức chuyên sâu về phân tích và trực quan hóa dữ liệu
 - Chọn loại biểu đồ phù hợp và hiểu sâu sắc ý nghĩa của từng loại
 - Xem xét mối quan hệ tổng thể giữa các biểu đồ

⇒ Đây là quá trình thử và sai đòi hỏi kiến thức chuyên sâu về phân tích dữ liệu và các công cụ chuyên nghiệp như Tableau, Power BI.




Fig. 1. Screenshot of the DashBot Interface showing the generation of a dashboard named "Insights about wind in seattle-weather". The interface consists of a table view (A), a topic list (B), a chart editor (C), a canvas view (D), and a recommendation view (E).

1.2 Các công trình liên quan và hạn chế

- **Phương pháp sử dụng các quy tắc thiết kế trực quan hóa**

- APT, Show Me, CompassQL và Voyager sử dụng các quy tắc thiết kế trực quan hóa, kỹ thuật truy vấn, thống kê và thước đo nhận thức để tạo, lọc và xếp hạng biểu đồ.
- Các phương pháp này tận dụng tốt tri thức trực quan hóa đã có, nhưng thường tập trung vào việc sinh một biểu đồ đơn lẻ.

- **Phương pháp dựa trên ML**

- VizML, NL4DV, Data2Vis, DeepEye và KG4Vis học cách dự đoán và biến dữ liệu thành biểu đồ thông qua các mô hình như regression, seq2seq, learning-to-rank hoặc knowledge graph.
- Tuy nhiên, phần lớn vẫn nhắm đến hình ảnh đơn lẻ, nên chưa xét đầy đủ quan hệ giữa nhiều biểu đồ trong dashboard.

- **Phương pháp tạo hình ảnh trực quan đa góc nhìn**

- DataShot và Calliope trích xuất các data facts bằng chỉ số thống kê rồi sinh fact sheets hoặc data stories.
- ChartStory ghép nhiều biểu đồ thành dạng kể chuyện trực quan.
- MultiVision dùng Bi-LSTM để chấm điểm biểu đồ đơn lẻ, sau đó kết hợp các biểu đồ thành multiple-view visualization.

Tuy nhiên, điểm hạn chế chung là các phương pháp này chủ yếu sinh một biểu đồ đơn lẻ, nên chưa đủ cho phân tích dữ liệu đa chiều cần nhiều biểu đồ trong cùng dashboard.

1.3 Giải pháp đề xuất

Bài báo đề xuất dùng Deep Reinforcement Learning phù hợp cho bài toán này với 3 lý do chính:

- ❶ **Mô hình hóa trực quan tự nhiên** bằng cách Agent học qua việc khám phá môi trường, cơ chế này tương đồng với cách người dùng thực hiện khi phân tích và khám phá dữ liệu trực quan. Cách mô hình hóa này phù hợp với bản chất thử và sai của quá trình khám phá dữ liệu.
- ❷ **Tự học không cần dữ liệu gán nhãn** : Với môi trường, không gian hành động và hàm phần thưởng được thiết kế kỹ càng, agent liên tục tự huấn luyện và chạy trên nhiều dataset mà không cần bộ dữ liệu được gán nhãn trước.
=> Giải quyết được điểm yếu lớn nhất của phương pháp dựa trên ML về hạn chế dữ liệu.
- ❸ **Gợi ý trực tuyến**: Hỗ trợ chuyển đổi linh hoạt giữa chế độ tự động và điều khiển tay. Khi người dùng chỉnh sửa dashboard, agent tạo sinh ra gợi ý tiếp theo dựa trên thay đổi đó một cách nhanh chóng.

2. Học tăng cường trong Trực quan hóa

Trong reinforcement learning, agent học cách chọn hành động trong một môi trường để đạt tổng phần thưởng tích lũy cao nhất. Các phương pháp như Q-learning phù hợp với không gian trạng thái và hành động nhỏ, nhưng gặp hạn chế khi observation space và action space trở nên phức tạp.

Một số nghiên cứu trước đã áp dụng RL hoặc MDP cho các tác vụ trực quan hóa cụ thể:

- **MobileVisFixer**: tối ưu bố cục trực quan hóa trên thiết bị di động.
- **Bako et al.** gợi ý cú pháp D3 trong quá trình tạo visualization.
- **Tang et al. (PlotThread)** sử dụng RL để tạo bố cục storyline.
- **Shi et al., Wei et al.**: dự đoán thao tác chỉnh sửa biểu đồ tiếp theo.

Khác với các hướng trên, bài báo này tập trung vào bảng điều khiển hay dashboard, một dạng hình ảnh trực quan đa góc nhìn có không gian thiết kế lớn hơn.

Do đó, bài toán không chỉ là tối ưu bố cục hoặc dự đoán thao tác chỉnh sửa, mà là mô hình hóa toàn bộ quá trình sinh dashboard thành một bài toán học tăng cường.

3.1 Nghiên cứu cơ sở

Để thiết kế một hệ thống đề xuất hiệu quả, nghiên cứu này tiến hành một khảo sát cơ sở nhằm tìm hiểu thực trạng thiết kế bảng điều khiển phân tích hiện nay và rút ra các yếu tố thiết kế cho hệ thống đề xuất.

Thu thập dữ liệu

- Các bảng điều khiển có số lượt thích cao nhất được thu thập từ thư viện chính thức của Tableau và Microsoft Power BI.
- Không phải tất cả ví dụ trong thư viện đều là bảng điều khiển; một số là áp phích hoặc đồ họa thông tin.
- Vì vậy, các bảng điều khiển được lọc thủ công từ thư viện.
- Kết quả cuối cùng gồm 40 bảng điều khiển từ Tableau và 50 bảng điều khiển từ Power BI.

Tiêu chí phân tích

- Các bảng điều khiển được phân tích từ góc độ trình bày trực quan và trình bày dữ liệu.
- Dựa trên các hướng dẫn thiết kế của trực quan hóa đa khung nhìn, một thiết kế tốt cần xét các nguyên tắc: **đa dạng**, **bổ trợ**, **phân rõ** và **tối giản**.

3.1 Kết quả khảo sát


Đa dạng

- Nghiên cứu phân tích mức độ đa dạng của các loại biểu đồ được dùng để biểu diễn các cột dữ liệu.
- Mỗi bảng điều khiển thường có nhiều khung nhìn; mỗi khung nhìn có thể gồm một hoặc nhiều biểu đồ hoặc thành phần, như văn bản hoặc bảng.
- Biểu đồ cột thường là loại biểu đồ được dùng nhiều nhất.
- Tiếp theo là biểu đồ đường, bản đồ và biểu đồ vành khuyên.
- Thành phần văn bản được dùng để tóm tắt phát hiện trong biểu đồ hoặc hiển thị các chỉ số chính.


Tối giản

- Tối giản hướng đến việc giảm số lượng khung nhìn nhưng vẫn giữ tính hiệu quả và khả năng biểu đạt.
- Phần lớn bảng điều khiển gồm 3-6 khung nhìn.
- Chỉ một số ít bảng điều khiển có nhiều hơn 8 khung nhìn.


(A) Dashboard Component Types



(B) Dashboard View Number



(C) Component Type Diversity



3.1 Kết quả khảo sát

Bổ trợ và phân rã

- **Bổ trợ:** các biểu đồ hỗ trợ nhau để thể hiện nhiều góc nhìn khác nhau của cùng một tập dữ liệu. Hai khung nhìn được xem là bổ trợ khi chúng trực quan hóa các cột dữ liệu khác nhau.
- **Phân rã:** dữ liệu phức tạp được phân tích bằng nhiều biểu đồ, chẳng hạn chia nhỏ dữ liệu hoặc áp dụng các phép tổng hợp khác nhau trên cùng một cột dữ liệu.

Phát hiện từ khảo sát

- Rất ít bảng điều khiển có các khung nhìn bổ trợ theo nghĩa các biểu đồ dùng những cột dữ liệu hoàn toàn khác nhau.
- Phần lớn bảng điều khiển tập trung vào một số cột dữ liệu chính.
- Trong 96.7% bảng điều khiển được khảo sát, tất cả khung nhìn đều liên quan đến một hoặc hai cột dữ liệu.

==> Một bảng điều khiển nên xoay quanh một chủ đề, tức cột dữ liệu chính. Các biểu đồ được cấu hình xung quanh chủ đề đó để khám phá phát hiện, đồng thời cần đủ đa dạng nhưng tránh quá nhiều biểu đồ.

3.2 Yêu cầu thiết kế

Các nguyên tắc thiết kế cho 1 hệ thống đề xuất dành cho bảng điều khiển

- DC1 - Tự động sinh ra các bảng điều khiển hợp lệ:** Dashboard phải có nhiều biểu đồ với các loại thành phần văn bản và bảng khác nhau (đa dạng biểu đồ). Các biểu đồ phải tuân thủ các quy tắc hiệu quả đối với loại dữ liệu.
- DC2 - Hỗ trợ khám phá thông tin dữ liệu một cách chủ động :** Ngoài việc hiển thị dữ liệu bằng các mã hóa trực quan phù hợp, hệ thống phải nhận ra các thông tin dữ liệu như tương quan cao hay phân phối theo thời gian, đồng thời ưu tiên chọn các biểu đồ có nghĩa.
- DC3 - Cho phép thao tác trực tiếp trên các đề xuất:** Người dùng được phép điều chỉnh bảng điều khiển trực tiếp và hệ thống cung cấp giao diện cho phép người dùng tùy chỉnh bảng điều khiển theo sở thích và thêm các biểu đồ mới.
- DC4 - Hỗ trợ đề xuất trực tuyến trong quá trình khám phá:** Các chỉnh sửa trên bản điều khiển phản ánh sở thích của người dùng, từ đó cung cấp điều kiện bổ sung cho các gợi ý. Hệ thống tạo các đề xuất ngay sau khi có thay đổi để đảm bảo hiệu quả tương tác.

4.1 Tiến trình quyết định Markov (MDP)

Quá trình sinh dashboard được mô hình hóa thành **Markov Decision Process**:

$$P = \{(s_i, a_i, p_i, r_i) \mid i \in [1, T]\} \quad (1)$$

- T : tổng số bước của quá trình khám phá
- $s_i \in \mathcal{S}$: trạng thái (state) tại bước i - cấu hình dashboard hiện tại
- $a_i \in \mathcal{A}$: hành động (action) được agent chọn từ action space $\mathcal{A}$
- $p_i \in \mathbb{R}^{|\mathcal{A}|}$: vector xác suất các hành động tại bước i
- $r_i \in \mathbb{R}$: phần thưởng tức thời sau khi thực hiện a_i tại s_i

Mục tiêu RL: Agent tối đa hóa tổng phần thưởng tích lũy (*return*):

$$R = \sum_{i=1}^T \gamma^{i-1} r_i, \quad \gamma = 1$$

MDP phù hợp với bài toán này vì chất lượng hành động có thể được đánh giá định lượng tại mỗi bước thông qua reward functions.

4.2 Không gian trạng thái

Dựa trên kết quả khảo sát, quá trình sinh dashboard được mô hình hóa là quá trình xác định **key column** (topic) từ dataset, rồi thiết lập chuỗi các biểu đồ để khám phá insights xung quanh topic đó.

Không gian trạng thái $\mathcal{S}$

Agent quyết định hành động tiếp theo dựa trên toàn bộ cấu hình dashboard hiện tại. Do đó, không gian trạng thái liệt kê mọi tổ hợp biểu đồ hợp lệ:

$$\mathcal{S} = \{ \{ chart_j \mid j \in [0, n] \} \mid n \in [0, N] \} \quad (2)$$

- $chart_j$: một biểu đồ hợp lệ đơn lẻ trong dashboard
- n : số lượng biểu đồ đang có trên dashboard tại thời điểm hiện tại
- N : số lượng biểu đồ tối đa được phép (giới hạn để tránh quá tải)

Ý nghĩa

⇒ Trạng thái $s_i = \text{tập hợp}$ tất cả các biểu đồ đang hiển thị trên dashboard tại bước i , không phải một biểu đồ đơn lẻ.

4.3 Không gian hành động

Từ một trạng thái, agent tiếp tục khám phá design space bằng cách chọn hành động:

$$\mathcal{A} = \{change, add, remove, terminate\} \quad (3)$$

Không gian hành động $\mathcal{A}$


- **change**: đổi key column sang cột khác, tất cả biểu đồ hiện có sẽ cập nhật theo key column mới
- **add**: thêm một biểu đồ mới vào vùng trống trong dashboard
- **remove**: xóa một biểu đồ đang có trên dashboard
- **terminate**: kết thúc phiên khám phá, finalize dashboard hoàn chỉnh

Tham số cho hành động *add*

Agent phải chỉ định đầy đủ:

- 1 Mark type: bar / line / point / boxplot
- 2 X field: chọn cột dữ liệu cho trục X
- 3 X aggregate: bin / count / sum / mean / max / none
- 4 Y field: chọn cột dữ liệu cho trục Y
- 5 Y aggregate: count / sum / mean / max / none
- 6 Color field (tùy chọn)

4.4 Minh họa quá trình khám phá



Ví dụ trong Hình bên trên mô tả một phiên khám phá trên dataset *cars*, với key column ban đầu là **mpg**. Tác tử lần lượt thực hiện các hành động:

- **Change:** đổi key column từ *mpg* sang *acceleration*, các biểu đồ hiện có được cập nhật theo key column mới để giữ tính nhất quán.
- **Add:** thêm một biểu đồ mới bằng cách cấu hình các tham số cụ thể: mark type là *bar chart*, *x* = *acceleration* (bin), *y* = *mpg* (mean).
- **Remove:** xóa một biểu đồ không còn phù hợp với trạng thái dashboard hiện tại.
- **Terminate:** kết thúc quá trình khám phá và xác định dashboard cuối cùng.

5.1 Hàm phần thưởng

Định nghĩa phần thưởng

Phần thưởng tại bước i được xác định bằng mức thay đổi chất lượng dashboard giữa hai trạng thái liên tiếp:

$$r_i = f(s_i, a_i) = cr_i - cr_{i-1} \quad (4)$$

- cr_i : điểm chất lượng tổng hợp của dashboard tại trạng thái hiện tại
- cr_{i-1} : điểm chất lượng tổng hợp của dashboard ở trạng thái trước đó

Ý nghĩa

- Dashboard được xây dựng theo từng bước thông qua chuỗi hành động của tác tử.
- Phần thưởng phản ánh mức độ cải thiện chất lượng dashboard sau mỗi hành động.
- Nếu dashboard tốt hơn trạng thái trước, phần thưởng dương; ngược lại phần thưởng âm.

Điểm chất lượng tổng hợp (cr) được tính từ hai thành phần:

- **Presentation Rewards** dùng để đánh giá chất lượng trình bày.
- **Insight Rewards** dùng để đánh giá giá trị phân tích dữ liệu.

5.2 Phần thưởng hình thức - Diversity Reward

Mục tiêu

Khuyến khích mô hình dùng đa dạng loại biểu đồ, nhưng theo nguyên tắc hiệu suất giảm dần để tránh sinh ra quá nhiều loại biểu đồ gây rối mắt.

Công thức Diversity Reward

$$dr(s_i, a_i) = 1 - \exp\left(-\frac{\alpha \cdot C_{used}}{C_{total}}\right) \quad (5)$$

- C_{used} : số loại biểu đồ hiện đang sử dụng trong dashboard
- C_{total} : tổng số loại biểu đồ được phép (bar, line, point, boxplot)
- α : tham số điều chỉnh tốc độ giảm dần

Đặc điểm: Điểm thưởng tăng theo mức độ đa dạng, nhưng tốc độ tăng giảm dần khi số loại biểu đồ tiếp tục tăng và cũng được áp dụng cho mức độ đa dạng của các cột dữ liệu được trực quan hóa.

5.2 Phần thưởng hình thức - Parsimony Reward

Mục tiêu

Khuyến khích số lượng biểu đồ gần với giá trị mong muốn và giảm điểm khi số lượng biểu đồ tiếp tục tăng.

Công thức Parsimony Reward

$$pr(s_i, a_i) = \begin{cases} \sin\left(\frac{\pi}{2} \cdot \frac{n}{n_{best}}\right), & n \in [0, n_{best}] \\ \sin\left(\frac{\pi}{2} \cdot \left(1 + \frac{n - n_{best}}{n_{max} - n_{best}}\right)\right) & \end{cases} \quad (6)$$

- n : số biểu đồ hiện tại n_{best} : số biểu đồ lý tưởng n_{max} : tối đa cho phép
- Với ($n \leq n_{best}$): hàm sin tăng từ 0 lên 1 thì sẽ điểm tăng dần khi thêm biểu đồ đến mức lý tưởng
- Với ($n > n_{best}$): hàm sin tiếp tục từ 1 giảm về 0 và bị phạt khi vượt quá mức tốt nhất, về 0 khi đến n_{max}

Đặc điểm: Điểm thưởng đạt cực đại tại n_{best} và giảm dần khi số lượng biểu đồ vượt quá giá trị này.

5.3 Phần thưởng nội dung - Insight Rewards

Insight được phân loại theo số cột dữ liệu liên quan, với điểm thưởng tăng dần:

Loại insight	Ý nghĩa	Ví dụ
Insight 1 cột	Mô tả đặc trưng thống kê cơ bản của 1 cột	Distribution hay phân phối của một biến định lượng
Insight 2 cột	Khám phá quan hệ giữa 2 cột	Trend, Correlation, Top/Bottom k
Insight nhiều cột	Nhận ra liên kết gián tiếp qua nhiều biểu đồ.	Co-correlation, Comparison

- Thang điểm 1,2,3 khuyến khích tác tử tìm các mẫu hình phức tạp hơn thay vì chỉ vẽ biểu đồ phân phối đơn giản.
- Điểm insight chỉ được tính khi dữ liệu vượt qua ngưỡng thống kê quy định.

5.3 Phần thưởng nội dung - Bảng định nghĩa Insight

Insight	Định nghĩa và điều kiện
distribution	$A \in \mathcal{Q}$: trực quan hóa A bằng histogram với bin count
trend	$A \in \mathcal{Q}$, $B \in \mathcal{T}$: vẽ A theo thời gian B bằng line chart
correlation	$A \in \mathcal{Q}$, $B \in \mathcal{Q}$: vẽ A theo B bằng line/scatter; hệ số tương quan vượt ngưỡng
top/bottom k	$A \in \mathcal{N}$, $B \in \mathcal{Q}$: hiển thị k thực thể đứng đầu/cuối của A theo B
co-correlation	$A, B, C \in \mathcal{Q}$: tồn tại mối tương quan giữa (A, B) và (A, C) , suy ra quan hệ bắc cầu
comparison	$A \in \mathcal{N}$, $B \in \mathcal{Q}$: có cả top- k và bottom- k về A theo B

$\mathcal{Q}$: quantitative (định lượng) $\mathcal{T}$: temporal (thời gian) $\mathcal{N}$: nominal (định danh)

- Mỗi insight có điều kiện rõ ràng về kiểu cột (Q/T/N) và về ngưỡng thống kê/ threshold cần đạt.
- Ví dụ: Correlation chỉ được cộng điểm khi hệ số Pearson giữa cột A và cột B thực sự vượt threshold.
- Điều này đảm bảo agent không thể làm giả insight, do đó dữ liệu phải có mẫu thật sự.
- Các nghiên cứu trước xét insight trong từng biểu đồ đơn lẻ hoặc 2 biểu đồ liền kề, còn DashBot xét quan hệ giữa bất kỳ 2 biểu đồ nào trong dashboard.

5.4 Tổng hợp phần thưởng (Combined Reward)

Combined Reward

Tất cả thành phần được gộp qua tổng có trọng số để tạo điểm chất lượng tổng hợp cr_i :

$$cr_i = w_1 \sum_{c \in \{col, vis\}} dr_i^c + w_2 \cdot pr_i + w_3 \sum_{c \in \{insights\}} ir_i^c \quad (7)$$


- $w_1 = w_2 = 0.33$: trọng số cho presentation rewards (diversity và parsimony)
- $w_3 = 0.1$: trọng số cho insight rewards

Lý do chọn các trọng số này

- $w_1, w_2 = 0.33$: presentation rewards có phạm vi $[0, 1]$, cần trọng số đủ lớn để agent *ưu tiên sinh dashboard hình thức hợp lệ trước*, không bỏ qua diversity và parsimony
- $w_3 = 0.1$: insight rewards cộng dồn rất nhanh (và1, và2, và3 cho mỗi insight tìm thấy trong mỗi chart), trọng số nhỏ giúp *ngăn signal quá mạnh* gây mất ổn định trong quá trình huấn luyện

Phần thưởng tức thời cuối cùng: $r_i = cr_i - cr_{i-1}$ (delta reward)

6.1 Khung mô hình - Thuật toán A3C



Sơ đồ luồng tương tác giữa tác tử (agent) và môi trường (environment)

Hàm mất mát của thuật toán A3C

$$L(s_i, p_i) = \underbrace{(R - v(s_i))^2}_{\text{Sai số Critic}} - \underbrace{\log(p_i) \cdot A(s_i)}_{\text{Policy Gradient}} - \underbrace{H(p_i)}_{\text{Entropy Bonus}} \quad (9)$$

- **Mạng Actor và Critic:** Actor dự đoán xác suất hành động p_i . Critic ước tính giá trị trạng thái $v(s_i)$ để làm cơ sở tối ưu hóa cho Actor
- **Hàm lợi thế:** $A(s_i) = R - v(s_i)$ đo lường mức độ chênh lệch giữa phần thưởng tích lũy thực tế (R) so với kỳ vọng (v)
- **Entropy Bonus $H(p_i)$:** Khuyến khích tác tử tích cực khám phá không gian an toàn, tránh hội tụ sớm hoặc lặp lại hành động vô nghĩa
- **Cơ chế bất đồng bộ:** Nhiều tác tử độc lập huấn luyện song song giúp mạng hội tụ nhanh và ổn định hơn

6.2 Xây dựng đặc trưng Dashboard

Mạng nơ-ron cần dữ liệu số. Dashboard được biểu diễn qua 3 bước:

Bước A - Column features (Hình 4A):


- Data type (Q/N/T), ID, name
- Min value, cardinality
- Skewness, Gini impurity, entropy
- (Dựa trên phương pháp của VizML)

Bước B - Chart features (Hình 4B):

- Dựa trên ngữ pháp **Vega-Lite**
- Mark type: one-hot (bar/line/point/boxplot)
- Visual channels (x, y, color): có dùng không, field nào
- Field feature = đặc trưng của dữ liệu **sau transform**, không phải cột gốc (ví dụ: "mean US Gross by Major Genre" $\neq$ cột "US Gross")

Bước C - Dashboard features (Hình 4C):

- Gom chart features của tất cả biểu đồ
- Thêm context: key column và tất cả columns trong dataset
- Tối đa 10 cột; pad zeros nếu dataset ít cột hơn
- Kết quả: $e_i \in \mathbb{R}^{n \times l}$
 - n = số chart hiện tại
 - l = chiều dài chart features (có context)




6.3 Kiến trúc mạng Agent - Bi-LSTM và Shared Embedding

Yêu cầu 1: Học quan hệ giữa các biểu đồ

- Sử dụng **Bi-LSTM** (Hình 4E).
- Học mối quan hệ giữa các biểu đồ trong dashboard.
- Thứ tự biểu đồ được xáo trộn ngẫu nhiên khi huấn luyện.
- Đầu ra được kết hợp thành **shared embedding** (Hình 4F).

Yêu cầu 2: Ước lượng giá trị trạng thái

- Shared embedding được đưa vào lớp FC-value.
- Dự đoán giá trị trạng thái $v(s_i)$ (Hình 4G).



6.3 Kiến trúc mạng Agent

Yêu cầu 3: Dự đoán các tham số có phụ thuộc lẫn nhau

Cơ chế

- Các khối phân loại được sắp xếp tuần tự, mỗi khối dự đoán một hành động hoặc tham số.
- Đầu vào gồm shared embedding và intermediate embedding từ khối trước.
- Intermediate embedding được truyền tiếp cho khối kế tiếp.
- Đầu ra là phân phối xác suất qua softmax.

Lý do sử dụng

- Các tham số của biểu đồ phụ thuộc lẫn nhau.
- Quyết định ở bước sau cần dựa trên kết quả của bước trước.
- Paper so sánh với DashBot-ind. (các khối độc lập) để đánh giá thiết kế này.

6.4 Lấy mẫu có ràng buộc - Động cơ

Vấn đề

Nếu lấy mẫu trực tiếp từ các phân phối xác suất, agent có thể sinh ra các cấu hình không hợp lệ:

- Áp dụng phép tổng hợp cho cột dữ liệu không phù hợp.
- Chọn các tham số mâu thuẫn với nhau.
- Tham chiếu đến cột dữ liệu không tồn tại.

Cách tiếp cận trước đây: DashBot-pen.

- Các hành động không hợp lệ bị gán phần thưởng âm.
- Cách làm này bổ sung thêm một mục tiêu tối ưu ngoài mục tiêu tìm kiếm các biểu đồ có giá trị phân tích.

Quan sát thực nghiệm

- Trong quá trình huấn luyện, giá trị return của DashBot-pen. tăng ở giai đoạn đầu nhưng giảm về sau (Hình 6).
- Kết quả cho thấy việc sử dụng penalty reward không phải là giải pháp phù hợp để xử lý các ràng buộc cấu hình.

6.4 Lấy mẫu có Ràng buộc

Vấn đề: Mạng có thể sinh cấu hình biểu đồ không hợp lệ do 3 nguyên nhân:

- Dataset có số cột khác nhau $\Rightarrow$ có thể chọn cột không tồn tại
- Action khác nhau kích hoạt nhánh tham số khác nhau (ví dụ: action change không cần cấu hình chart)
- Vi phạm ngữ pháp rendering: ví dụ tính *mean* trên cột chữ (nominal)

Cách cũ (phạt điểm âm): Gán $r = -k$ khi sinh biểu đồ sai. Kết quả: tác tử giảm sinh biểu đồ sai, nhưng *cân bằng* giữa điểm phạt và thưởng insight rất khó, cuối cùng làm giảm hiệu năng.


Giải pháp: Mask trước Softmax

Dựa trên luật visualization, gán $-\infty$ cho các lựa chọn vi phạm **trước khi** tính Softmax. Xác suất của mọi lựa chọn không hợp lệ bị ép về 0. Tác tử chỉ lấy mẫu trong không gian an toàn.

Quan trọng: Áp mask trước Softmax đảm bảo Entropy $H(p_i)$ vẫn được tính hợp lệ cho backpropagation - điều mà phạt điểm âm không đảm bảo được.

6.4 Minh họa cơ chế lấy mẫu có ràng buộc

Ví dụ: Tác tử thêm một biểu đồ mới với cột dữ liệu chính là *horsepower*



❶ Khối A (Cột dữ liệu chính):

Tất cả logit bị che bởi mặt nạ và nhận giá trị $-\infty \rightarrow$ chọn giá trị giả "NA" vì cột dữ liệu chính đã được cố định.

❷ Khối B (Loại biểu đồ):

Mọi lựa chọn đều hợp lệ $\rightarrow$ tác tử chọn biểu đồ cột.

❸ Khối C (Trường dữ liệu trục Y):

Cột *horsepower* bị loại bỏ $\rightarrow$ tác tử chọn *origin*.

❹ Khối D (Phép tổng hợp):

Các phép *mean* và *max* bị loại bỏ vì *origin* là cột dữ liệu phân loại $\rightarrow$ chỉ còn lựa chọn "không tổng hợp".

Kết quả: Mọi biểu đồ được sinh ra đều hợp lệ. Tác tử chỉ lựa chọn trong không gian hành động hợp lệ mà không cần sử dụng cơ chế phạt (DashBot-pen.).

6.5 Giao diện và tương tác DashBot

Giao diện gồm 5 thành phần chính:

- **A - Bảng dữ liệu:** tải tệp CSV; xem danh sách cột dữ liệu, kiểu dữ liệu và dữ liệu dạng bảng.
- **B - Danh sách chủ đề:** hiển thị các bảng điều khiển tương ứng với các cột dữ liệu chính khác nhau, được sắp xếp theo giá trị đánh giá; khi di chuột sẽ hiện thông tin thay đổi.
- **C - Trình chỉnh sửa biểu đồ:** chỉnh sửa trực tiếp loại biểu đồ, các trường dữ liệu trên trục và màu sắc; thêm hoặc xóa biểu đồ.
- **D - Vùng hiển thị:** hiển thị các biểu đồ do mô hình tạo ra; các trực quan hóa dạng văn bản tóm tắt thống kê quan trọng được đặt ở phía trên; bố cục được sắp xếp theo luật định sẵn.
- **E - Vùng gợi ý:** hiển thị các biểu đồ được đề xuất sau khi người dùng chỉnh sửa.

Quy trình hoạt động:

- 1 Tải tệp CSV, tác tử tự động khám phá dữ liệu (tối đa **50 bước** cho mỗi bảng điều khiển, tổng cộng **1000 bước**).
- 2 Nhiều bảng điều khiển với các cột dữ liệu chính khác nhau được tạo và hiển thị trong danh sách chủ đề.
- 3 Người dùng chọn một bảng điều khiển để xem.
- 4 Sau khi người dùng chỉnh sửa biểu đồ, tác tử tiếp tục khám phá thêm $k = 200$ bước và đưa ra các gợi ý mới.

7.1 Ví dụ Dashboard (1) - Seattle Weather






Fig. 1. Screenshot of the DashBot Interface showing the generation of a dashboard named "Insights about wind in seattle-weather". The interface consists of a table view (A), a topic list (B), a chart editor (C), a canvas view (D), and a recommendation view (E).

Topic: wind (gió) trong dữ liệu Seattle weather

- **Chart 1:** scatter plot nhiệt độ tối thiểu vs gió => ngày gió mạnh nhất thường là ngày mưa (điểm đỏ tập trung bên phải)
- **Chart 2:** phân phối gió theo loại thời tiết => tỷ lệ ngày mưa *tăng* khi gió tăng
- **Chart 3:** boxplot gió theo thời tiết => median gió ngày mưa cao hơn drizzling/foggy/sunny
- **Chart 4:** biến thiên gió theo ngày tháng
- **Chart 5** (người dùng tự thêm): top ngày có gió mạnh nhất
- **Chart 6** (DashBot tự gợi ý sau khi người dùng thêm Chart 5): top ngày có gió nhỏ nhất => tạo **Comparison insight** hoàn chỉnh

7.1 Ví dụ Dashboard (2 & 3) - Cars & Movies



Dashboard A - Cars, topic: Horsepower

- C1: boxplot horsepower theo số cylinders
- C2-5: correlations âm với mpg và acceleration; correlations dương với weight và displacement
- C6: overview horsepower theo năm sản xuất

Dashboard B - Movies, topic: US Gross

- C1 & 2: mean US Gross theo major genres và MPAA ratings
- C3: directors có US Gross cao nhất (top-k)
- C4 & 5: US Gross theo IMDB rating và Rotten Tomato rating - so sánh 2 hệ thống đánh giá
- C6: scatter plot correlation US Gross - production budget

7.2 Thiết lập thực nghiệm

Mục tiêu: Đánh giá đóng góp của từng thành phần trong DashBot, gồm thuật toán A3C, cơ chế dự đoán tuần tự và cơ chế lấy mẫu có ràng buộc.


Thiết lập thực nghiệm thực tế

- **Phần cứng:** Kết hợp huấn luyện trên Google Colab (Tesla T4 GPU) và máy cá nhân CPU
- **Dữ liệu:** 27 tập dữ liệu dạng bảng từ Vega Datasets
- **Huấn luyện:** Huấn luyện liên tục trong 500.000 bước (steps) cho mỗi biến thể
- **Đánh giá:** Kết quả phân tích thu được từ lượt huấn luyện đầy đủ của từng mô hình
- Vùng tô mờ biểu diễn độ lệch chuẩn trượt (rolling std, window = 10) thể hiện độ biến động của điểm số trong quá trình học

Các mô hình được so sánh

- **DashBot:** Mô hình đầy đủ (A3C và dự đoán tuần tự và không chế ràng buộc)
- **DQN:** Thay A3C bằng Deep Q-Network trên cùng một kiến trúc tác tử
- **DashBot-ind.:** Loại bỏ khối dự đoán tuần tự (các tham số biểu đồ dự đoán độc lập)
- **DashBot-pen.:** Thay cơ chế không chế ràng buộc bằng cơ chế phạt điểm (penalty) khi chọn cấu hình không hợp lệ

7.2 Ablation Study



A3C vs DQN:

- DQN **không** đạt được mức tăng ổn định trong suốt quá trình
- Nguyên nhân: DQN không xử lý tốt không gian hành động quá lớn và nhiều chiều

Sequential vs Independent (DashBot-ind.):

- DashBot-ind. tăng đều nhưng hội tụ ở mức thấp hơn DashBot (≈ 1.7)
- DashBot hội tụ nhanh hơn với ít training steps hơn
- Lý do: Mô hình tuần tự học được mối quan hệ ngữ cảnh giữa các thuộc tính biểu đồ

Constrained vs Penalty (DashBot-pen.):

- Return ban đầu rất thấp (≈ 0 do liên tục chọn các cấu hình lỗi)
- Return tăng trưởng cực kỳ chậm và hội tụ ở mức thấp nhất (≈ 0.5)
- Lý do: Việc học luật gián tiếp qua điểm phạt (penalty) kém hiệu quả hơn nhiều so với cơ chế tạo mặt nạ ràng buộc

7.2 Ablation Study - Chi tiết kết quả trên 27 tập dữ liệu

Tập dữ liệu	Insight	Reward		Tập dữ liệu	Insight	Reward		Tập dữ liệu	Insight	Reward
anscombe	6	2.31		flights-2k	9	3.07		obesity	0	0.90
barley	5	2.14		gapminder	9	3.07		ohlc	14	4.48
birdstrikes	10	3.27		gapminder-health	7	2.57		penguins	11	3.58
burtin	10	3.29		github	1	1.07		population	3	1.39
cars	26	8.05		global-temp	1	0.81		seattle-weather	9	3.07
co2-concentration	4	1.71		iowa-electricity	3	1.50		sp500	1	1.00
crimea	4	1.67		jobs	9	3.06		stocks	3	1.50
disasters	3	1.61		la-riots	10	3.28		unemployment	7	2.47
driving	6	2.31		movies	14	4.48		weather	10	3.28

- **Thời gian xử lý trung bình:** Đạt 125,6 giây mỗi tập dữ liệu khi chạy trên cấu hình CPU thông thường (tối ưu hóa dưới 15,4 giây trên cấu hình đồ họa GPU).
- **Độ tương quan:** Những tập dữ liệu chứa nhiều thuộc tính phong phú (như *cars*) giúp hệ thống phát hiện nhiều insight hơn, dẫn đến điểm thưởng chất lượng (Reward) cao hơn.

7.3 Khảo sát người dùng - Thiết lập thực nghiệm

Mô hình đối chứng: MultiVision [Wu et al., 2021] là mô hình dịch thuật và trực quan hóa dữ liệu tiên tiến nhất thời điểm đó.

Đối tượng tham gia (P1-P10):

- **Số lượng:** 10 chuyên gia dữ liệu (4 nữ, 6 nam).
- **Kinh nghiệm:** > 2 năm làm việc chuyên sâu với Python/R/Excel/SPSS.
- **Lĩnh vực:** Thống kê, hóa học, CS, tài chính, kinh tế.


Dữ liệu thực nghiệm:

- 5 tập dữ liệu mẫu từ Vega Datasets gồm: *cars, jobs, penguins, weather, movies*.
- Tổng số lượt đánh giá: 50 lượt (10 người × 5 tập dữ liệu).

Quy trình khảo sát:

- Hiển thị ẩn danh hai dashboard trên cùng một giao diện để tránh thiên kiến.
- Người tham gia đánh giá dựa trên 4 tiêu chí cốt lõi sau 50 phút trải nghiệm.
- Áp dụng giao thức phát biểu suy nghĩ tự do để ghi nhận phản hồi trực tiếp.

7.3 Khảo sát người dùng



Thiết lập thực nghiệm (Nguồn paper Dashbot): 10 chuyên gia $\times$ 5 tập dữ liệu $\rightarrow$ 50 lượt đối chứng độc lập (200 ratings)

Kết quả bình chọn ưu tiên cho DashBot (trên tổng số 50 lượt):

- **Độ sâu thông tin:** 44/50 (88%) $\Rightarrow$ trích xuất mẫu hình sắc nét
- **Dễ hiểu:** 42/50 (84%) $\Rightarrow$ nhờ cấu trúc chủ đề Key Column
- **Chất lượng tổng:** 39/50 (78%) $\Rightarrow$ tổ chức phối hợp biểu đồ hợp lý
- **Tính thẩm mỹ:** 38/50 (76%) $\Rightarrow$ trực quan hóa đa dạng, vừa vặn

$\Rightarrow$ **Kết luận:** DashBot áp đảo hoàn toàn MultiVision trên cả 4 tiêu chí đánh giá cốt lõi.

8. Thảo luận và Hướng cải thiện

- **Mở rộng tập hàm phần thưởng (Reward Functions):**

- Chưa xét độ hiệu quả hiển thị của biểu đồ đơn lẻ và cấu trúc bố cục. Giải pháp: Tích hợp cơ sở tri thức Draco.
- Chưa khai thác ngữ nghĩa tiêu đề cột, dễ dẫn đến kết quả hiển nhiên. Giải pháp: Chuẩn hóa khoảng cách tương quan qua cấu trúc ngữ nghĩa.
- Cần bổ sung chỉ số thống kê phân phối (Shapiro-Wilk, độ lệch, độ nhọn) và áp dụng thị giác máy tính nhận diện điểm nhiễu, phân cụm trực quan.

- **Đánh giá trong kịch bản thực tế:**

- Là hệ thống thử nghiệm khái niệm, giới hạn loại biểu đồ, bố cục và thiếu khả năng tùy biến phong cách so với Tableau hay Power BI.
- Thách thức về khả năng mở rộng trước dữ liệu lớn hàng ngàn cột; đòi hỏi bổ sung các thao tác biến đổi bảng nâng cao.

- **Biến đổi dữ liệu bổ sung và Tính tương tác:**

- Mới dừng lại ở tổng hợp cơ bản và trích xuất top/bottom k . Cần mở rộng tham số Vega-Lite hỗ trợ chồng lớp, phân mảnh và giảm mật độ hiển thị (binning/sampling).
- Chưa hỗ trợ tương tác do chưa mô hình hóa luồng dữ liệu động phục vụ thao tác lọc chéo.

9. Kết luận và Hướng nghiên cứu tương lai

4 đóng góp chính của bài báo:

- ➊ **Preliminary study:** phân tích 90 dashboards thực tế (Tableau và Power BI), rút ra các design considerations cụ thể cho recommendation system
- ➋ **RL formulation:** công thức hóa bài toán sinh dashboard thành MDP với reward functions đánh giá đồng thời tính biểu cảm và sự sâu sắc
- ➌ **Novel agent network:** Bi-LSTM và sequential classification blocks và constrained sampling - giảm đáng kể khả năng sinh cấu hình biểu đồ không hợp lệ. trong không gian lớn
- ➍ **Ablation study và User study:** xác nhận tính hiệu quả của từng thành phần và được người tham gia đánh giá cao hơn MultiVision trên bốn tiêu chí trong user study

Ý nghĩa: Mở ra hướng nghiên cứu về visualization recommendation không cần large-scale human-labeled training data - giải quyết điểm nghẽn lớn nhất của các ML-based methods.

Hướng tương lai: Mở rộng cho glyph/data stories; model data flow cho interactivity; kết hợp visual patterns; inverse RL để tích hợp user feedback.



D. Deng, A. Wu, H. Qu, Y. Wu.

DashBot: Insight-Driven Dashboard Generation Based on Deep Reinforcement Learning.
arXiv:2208.01232v3 [cs.HC], Sep 2022.



A. Wu et al.

MultiVision: Designing Analytical Dashboards with Deep Learning Based Recommendation.



V. Mnih et al.

Asynchronous Methods for Deep Reinforcement Learning.



Q. Shi et al.

Calliope: Automatic Visual Data Story Generation from a Spreadsheet.



A. Satyanarayan et al.

Vega-Lite: A Grammar of Interactive Graphics.

Q & A

Xin cảm ơn thầy và các bạn đã lắng nghe!